



—— 人工智能原理与算法 ——

第12章-不确定性的量化

中科院自动化研究所 朱翔昱

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

- **不确定性下的动作**
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.1 不确定性下的动作-不确定性概述

■ 智能体与不确定性


- 现实世界中，由于部分可观测性、非确定性和对抗者的存在，真实世界中的智能体需要处理不确定性（uncertainty）。智能体可能永远都无法确切地知道它现在所处的状态，也无法知道一系列动作之后结束的位置。



12.1 不确定性下的动作-不确定性概述

■ 问题求解及逻辑智能体的不确定性处理

- 追踪信念状态 (belief state) ——所有它可能处于的世界状态的集合的表示。
- 生成应变规划——处理在执行期间传感器报告的每种可能的意外情况。



不确定事件只会少量发生的情况是可行的

12.1 不确定性下的动作-不确定性概述

■ 信念状态和应变规划的缺点：

- 无论可能性多么低，智能体都必须考虑传感器观测到的每种可能解释。这导致信念状态中可能存有大量不太可能发生的情况，进而导致信念状态非常庞大。
- 一个要处理每种情况的应变规划必须考虑任何不太可能的情况，因此最终可能变得任意大。
- 有时，可以保证达成目标的规划可能并不存在，但智能体必须行动。因此智能体必须有某种方式比较这些规划的优劣。

12.1 不确定性下的动作-不确定性概述

- 示例1. 自动驾驶出租车—Agent目标：将乘客按时送到机场
 - 规划 A_{90} ：在飞机起飞前90分钟出门，以合理的速度驶向机场。
 - 该规划存在问题：即使距离机场仅8公里，逻辑智能体也不能完全确定地得出“ A_{90} 规划能将我们及时送到机场”的结论。
 - 只能得出一个较弱结论：只要汽车不抛锚，没有被卷入交通事故，道路没有封闭，没有陨石砸中汽车等， A_{90} 规划就能将我们及时送到机场。
- 现实世界充满不确定性！
- 常识上 A_{90} 是一个合理的规划。



12.1 不确定性下的动作-不确定性概述

■ 示例1.自动驾驶出租车—Agent目标：将乘客按时送到机场

- 规划 A_{90} ：在飞机起飞前90分钟出门，以合理的速度驶向机场。
- 该规划存在问题：即使距离机场仅8公里，逻辑智能体也不能完全确定地得出“ A_{90} 规划能将我们及时送到机场”的结论。
- 只能得出一个较弱结论：只要汽车不抛锚，没有被卷入交通事故，道路没有封闭，没有陨石砸中汽车等， A_{90} 规划就能将我们及时送到机场。

做出正确的动作：

1. 考虑各种目标的相对重要性。
2. 考虑他们的可实现性。



12.1 不确定性下的动作-不确定性概述

■ 示例2：诊断一名牙科病人的牙痛 (toothache)

□ 使用逻辑方法：规则 $Toothache \Rightarrow Cavity$

- ▶ 该规则存在问题：不是所有的牙痛都是因为蛀牙，有可能是牙龈疾病、牙龈脓肿、或者其他问题：

$$Toothache \Rightarrow Cavity \vee GumProblem \vee Abscess \dots$$

- ▶ 为了使这条规则正确，必须给出一个几乎无限长的可能问题的列表。

□ 改成果因果规则： $Cavity \Rightarrow Toothache$

- ▶ 也不正确，并非所有蛀牙都会引起牙痛。
- ▶ 需要在逻辑上穷举，在规则的左边加上蛀牙引发牙痛的所有所需条件。



12.1 不确定性下的动作-不确定性概述

■ 示例2：诊断一名牙科病人的牙痛 (toothache)

□ 逻辑处理医疗诊断问题失败原因：

- ▶ **惰性 (laziness)**：为确保规则没有例外情况，所需列出的完整前提和结论的工作量太大，并且这样的规则也难以使用。
- ▶ **理论无知 (theoretical ignorance)**：医学在这个领域没有完备的理论。
- ▶ **实践无知 (practical ignorance)**：即使我们知道所有的规则，对于特定的病人，我们可能也无法得到结论，因为不是所有需要的检测都已经完成或者能够被完成。

□ 牙痛和蛀牙之间的联系在任一方向都不是一个严格的逻辑结论

- ▶ 医学领域的典型情况，法律、商业、设计、汽修、园艺、年代推断等领域也是如此

12.1 不确定性下的动作-不确定性概述

- 智能体的知识至多只能提供对相关语句的**信念度**
- **处理信念度的主要工具是概率论。**
- 概率论与逻辑的对比：
 - 逻辑和概率论的**本体论**承诺是相同的——世界是由在特定情况下成立或不成立的事实构成的。
 - 逻辑和概率论的**认识论**承诺是不同的——逻辑智能体相信每个命题或对或错或不做评价，而概率智能体有着 0（语句必定为假）和 1（语句必定为真）之间的数值信念度。

概率论提供了应对因惰性与无知而产生的不确定性的方式

12.1 不确定性下的动作-不确定性与理性决策

■ 再探示例1，考虑以下问题：

- 假设规划 A_{90} 让我们有97%的机会赶上航班，这意味着这个规划是一个理性的选择吗？
- 如果非常厌恶错过航班，那么在机场的长时间等待是值得的，或许选择 A_{180} ； A_{1440} 是一个提前24小时出门的规划，这个规划怎么样呢？
- 为了做出这些选择，**Agent**必须在各种规划的不同结果之间有所**偏好**，包括Agent是否按时到达机场、在机场等待多长时间等。



12.1 不确定性下的动作-不确定性与理性决策

■ 效用理论

- 智能体必须在各种规划的不同可能结果 (outcome) 中有所偏好 (preference)
- 效用 (utility) : **有用的量**, 表示偏好。
- 效用理论认为每个状态 (或者状态序列) 对智能体有一定程度的效用, 智能体偏好效用更高的状态。



偏好是非常个性, 非常主观的东西, 你可以说一个偏好墨西哥胡椒泡泡糖的智能体是古怪的, 但不能说他是不理性的。

《哈利波特》中的怪味豆

12.1 不确定性下的动作-不确定性与理性决策

■ 决策论 (decision theory)

- 理性决策的通用理论，由效用表示的偏好与概率相结合，指导智能体的动作。
- 基本思想：智能体是理性的，当且仅当它选择平均所有可能结果后生成最高期望效用的动作——**最大期望效用 (MEU) 原则**。
- 每个动作都会产生一个信念状态集合，每个信念状态都有一个效用，那么期望效用就是所有信念状态根据发生概率的加权和。

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.2 基本概率记号

- 概率论是探讨**各种世界的可能性**有多大的理论
- 世界的建模：
 - 概率论中，所有可能世界的集合称为样本空间 Ω ，其中的元素为一个可能世界，用 ω 表示。
 - 这些可能事件是互斥的和穷举的——两个可能世界不能相同，每个可能世界都应考虑在内。
 - 例：掷两个（可区分的）骰子，一共需要考虑 36 个可能世界：(1, 1)、(1, 2).....(6, 6)



12.2 基本概率记号

■ 可能性的建模：

- 一个完全指定的概率模型为每个可能世界赋予一个数值概率 $P(\omega)$ 。
- **概率论基本公理**规定：每个可能世界具有一个 0 到 1 之间的概率，并且样本空间中的可能世界的总概率为 1：

$$\text{对任一 } \omega, 0 \leq P(\omega) \leq 1 \text{ 且 } \sum_{\omega \in \Omega} P(\omega) = 1$$

- 例：假设每个骰子是公平的且骰子间不会相互干扰，则每个可能世界 $(1, 1)$ 、 $(1, 2)$ $(6, 6)$ 的概率是 $1/36$ 。如果骰子是非公平的，则一些世界拥有更高的概率，一些世界的概率更低，但它们的和仍然为 1

12.2 基本概率记号

■ 事件 (event)

- 概率断言和查询往往不是关于某个特定可能世界的，而是关于它们的集合的。
- 例：我们可能询问两个骰子点数之和等于 11 的概率、点数相同的概率等。在概率论中，这些集合被称为**事件**。
- 事件成立的概率（或者叫命题成立的概率）等于其中每个可能世界的概率的和。

$$P(\phi) = \sum_{\omega \in \phi} P(\omega)$$

$$\text{例: } P(\text{Total} = 11) = P(5,6) + P(6,5) = 1/18$$

12.2 基本概率记号

■ 条件概率 and 后验概率

- 像 $P(\text{Total} = 11)$ 和 $P(\text{doubles})$ 这样的概率被称为**无条件概率**或者**先验概率 (prior probability, priors)**
- 大多数情况下, 我们会有一些已经透露的信息, 通常称为**证据 (evidence)**
- 我们感兴趣的是给定第一个骰子是 5 的前提下两个骰子点数相同的**条件概率 (conditional probability)** 或者**后验概率 (posterior probability, posteriors)**。这个概率写作 $P(\text{doubles} \mid \text{Die1} = 5)$

12.2 基本概率记号

■ 条件概率 and 后验概率

- 条件概率是利用如下无条件概率定义的：对任意命题 a 和 b ：

$$P(a | b) = \frac{P(a \wedge b)}{P(b)} \quad \text{当 } P(b) > 0 \text{ 时成立。}$$

- 例如：

$$P(\text{doubles} | \text{Die}_1 = 5) = \frac{P(\text{doubles} \wedge \text{Die}_1 = 5)}{P(\text{Die}_1 = 5)}$$

- 可改写为**乘积法则**：

$$P(a \wedge b) = P(a | b)P(b)$$

乘积法则是联合概率分布和条件概率分布两种概率形式的一个桥梁

12.2 基本概率记号

■ 随机变量：

- 因子化表示使用（变量/值）对来表示可能世界。
- 概率理论中变量称为随机变量，变量的名字以大写字母开头。如 Total 和 Die
- **值域（range）**：变量能取得所有可能值组成的集合。Total 的值域是 $\{2, \dots, 12\}$ ，Die 的值域是 $\{1, \dots, 6\}$ 。布尔变量的值域是 $\{\text{true}, \text{false}\}$ 。
- **变量也可以有无限值域**，如离散的（如整数），或连续的（如实数）
- 对于任何具有有序值域(ordered domain)的变量，可以允许类似 $\text{NumberOfAtomsInUniverse} \geq 10^{70}$ 这样的不等式

12.2 基本概率记号

■ 概率分布：

- 如果为随机变量的每个可能的值分配了一个概率，则定义了一个概率分布。

$$P(\text{Weather} = \text{sun}) = 0.6$$

- 例如天气：

$$P(\text{Weather} = \text{rain}) = 0.1$$

$$P(\text{Weather} = \text{cloud}) = 0.29$$

$$P(\text{Weather} = \text{snow}) = 0.01$$

$$P(\text{Weather}) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

■ 概率密度函数：

- 对于连续变量，因为有无限多的值，不可能把整个分布写成向量。可以定义随机变量的取值 x 的概率为以 x 为参数的函数，它通常被称为概率密度函数（PDF）

- 例如中午的温度均匀地分布在 $18 \sim 26^\circ\text{C}$ 的信念可表示为：

$$P(\text{NoonTemp} = x) = \text{Uniform}(x; 18\text{C}, 26\text{C})$$

12.2 基本概率记号

- 包含排除原理：一个命题的概率等于1减去它的否命题的概率：

$$\begin{aligned}
 P(\neg a) &= \sum_{\omega \in \neg a} P(\omega) \\
 &= \sum_{\omega \in \neg a} P(\omega) + \sum_{\omega \in a} P(\omega) - \sum_{\omega \in a} P(\omega) \\
 &= \sum_{\omega \in \Omega} P(\omega) - \sum_{\omega \in a} P(\omega) \\
 &= 1 - P(a)
 \end{aligned}$$

- 容斥原理：

对任一 ω , $0 \leq P(\omega) \leq 1$ 且 $\sum_{\omega \in \Omega} P(\omega) = 1$

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.3 使用完全联合分布进行推断

- 使用完全联合分布作为“知识库”，从中可以得到所有问题的答案。
 - 问题求解智能体的知识库：世界状态，动作，动作后果
 - 逻辑智能体知识库：语句集
 - 概率智能体的知识库：完全联合分布

$$P(Cavity, Toothache)$$

- 一个概率推断 (probabilistic inference) 的典型：给定观测证据时，为每个查询 (query) 命题计算后验概率。

$$P(Cavity|toothache)$$

12.3 使用完全联合分布进行推断

- 示例3：一个包含 3 个布尔变量 Toothache、Cavity 和 Catch 的问题域。

- 完全联合分布是一个 $2 \times 2 \times 2$ 的表。



$$P(\text{Toothache}, \text{Catch}, \text{Cavity})$$

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 计算任何命题的概率的直接方式：简单地识别出命题为真的可能世界，然后把概率相加。

$$P(\text{cavity} \vee \text{toothache}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$$

12.3 使用完全联合分布进行推断

■ 示例3:

	<i>toothache</i>		<i>¬toothache</i>	
	<i>catch</i>	<i>¬catch</i>	<i>catch</i>	<i>¬catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
<i>¬cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- **边缘概率推断**: 计算变量子集或单个变量的分布, 如

$$P(cavity) = 0.108 + 0.012 + 0.072 + 0.008 = 0.2$$

- 一般称为边缘化或求和消元
- 对于任何变量集合 Y 和 Z , 可以写出如下一般边缘化规则:

$$P(Y) = \sum_z P(Y, Z = z)$$

- 例如对Cavity做边缘化:

$$\begin{aligned}
 P(Cavity) &= P(Cavity, toothache, catch) + P(Cavity, toothache, \neg catch) \\
 &\quad + P(Cavity, \neg toothache, catch) + P(Cavity, \neg toothache, \neg catch) \\
 &= \langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle + \langle 0.072, 0.144 \rangle + \langle 0.008, 0.576 \rangle \\
 &= \langle 0.2, 0.8 \rangle
 \end{aligned}$$

12.3 使用完全联合分布进行推断

■ 示例3:

	<i>toothache</i>		<i>¬toothache</i>	
	<i>catch</i>	<i>¬catch</i>	<i>catch</i>	<i>¬catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
<i>¬cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 用 $P(Y | z)P(z)$ 代替式中的 $P(Y, z)$ ，得到如下**条件化 (conditioning)** 规则：

$$P(Y) = \sum_z P(Y | z)P(z)$$

12.3 使用完全联合分布进行推断

■ 示例3:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 条件概率推断：给定牙痛的证据，可以计算蛀牙概率：

$$\begin{aligned}
 P(\text{cavity} \mid \text{toothache}) &= \frac{P(\text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\
 &= \frac{0.108+0.012}{0.108+0.012+0.016+0.064} = 0.6
 \end{aligned}$$

- 给定牙痛的证据，没有蛀牙的概率（相加为1）：

$$\begin{aligned}
 P(\neg \text{cavity} \mid \text{toothache}) &= \frac{P(\neg \text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\
 &= \frac{0.016+0.064}{0.108+0.012+0.016+0.064} = 0.4
 \end{aligned}$$

- 合并：

$$\begin{aligned}
 P(\text{Cavity} \mid \text{toothache}) &= \alpha P(\text{Cavity}, \text{toothache}) \\
 &= \alpha [P(\text{Cavity}, \text{toothache}, \text{catch}) + P(\text{Cavity}, \text{toothache}, \neg \text{catch})] \\
 &= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] = \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle
 \end{aligned}$$

12.3 使用完全联合分布进行推断

■ 示例3:

	<i>toothache</i>		<i>¬toothache</i>	
	<i>catch</i>	<i>¬catch</i>	<i>catch</i>	<i>¬catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
<i>¬cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- **通用推断流程：**从查询单变量 X （例子中的 *Cavity*）的情况开始。
- 令 E 表示证据变量列表（这个例子中只有 *Toothache*）， e 表示它们的观测值， Y 表示剩余未观测变量（这个例子中只有 *Catch*）。
- 查询 $P(X | e)$ 可以计算为：

$$P(X | e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

数学形式很清晰，但实际操作困难

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.4 独立性

■ 再探示例3:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 通过增加第四个变量 *Weather* 来扩展牙医诊断问题的完全联合分布。完全联合分布变成了 $P(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather})$ ，拥有 $2 \times 2 \times 2 \times 4 = 32$ 个条目，使用乘积法则化简：

$$\begin{aligned}
 &P(\text{toothache}, \text{catch}, \text{cavity}, \text{cloud}) \\
 &= P(\text{cloud} \mid \text{toothache}, \text{catch}, \text{cavity}) P(\text{toothache}, \text{catch}, \text{cavity})
 \end{aligned}$$

- 显然，牙疼不会影响天气

$$P(\text{cloud} \mid \text{toothache}, \text{catch}, \text{cavity}) = P(\text{cloud})$$

$$P(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather}) = P(\text{Toothache}, \text{Catch}, \text{Cavity}) P(\text{Weather})$$

12.4 独立性

■ 再探示例3:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 可以将4 个变量的 32 个元素的表分解为一个 8 元素的表和一个 4 元素的表。




图 12-4 使用绝对独立性将一个大的联合分布分解成小分布的两个例子。(a) 天气和牙齿问题是独立的。(b) 抛硬币是独立的

12.4 独立性

■ 再探示例3:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

图 12-3 *Toothache*、*Cavity*、*Catch* 世界的完全联合分布

- 上例使用的性质叫**独立性 (independence)**，也叫边缘独立性 (marginal independence) 或绝对独立性 (absolute independence)。

- 命题 *a* 和 *b* 独立，则满足：

$$P(a | b) = P(a) \text{ 或 } P(b | a) = P(b) \text{ 或 } P(a \wedge b) = P(a) P(b)$$

- 变量组 *X* 和 *Y* 独立，则满足：

$$P(X | Y) = P(X) \text{ 或 } P(Y | X) = P(Y) \text{ 或 } P(X, Y) = P(X) P(Y)$$

12.4 独立性

■ 独立性总结：

- 好处：当独立性断言可用时，它可以减少域表示的大小，降低推断问题的复杂性。
- 局限性：通过独立性清晰地分离整个变量集的情况非常少见。无论两个变量之间存在多么间接的联系，独立性都无法成立。

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.5 贝叶斯法则及其应用

■ 贝叶斯法则的推导

- 乘积法则可以写成两种形式：

$$P(a \wedge b) = P(a | b)P(b) \text{ 和 } P(a \wedge b) = P(b | a)P(a)$$

- 联立两式右侧，除以 $P(a)$ ，得到**贝叶斯法则**：

$$P(b | a) = \frac{P(a | b)P(b)}{P(a)}$$

- 多值变量，更一般的贝叶斯法则可以用记号**P**写成如下形式：

$$P(Y | X) = \frac{P(X | Y)P(Y)}{P(X)}$$

表面上看，好像用三个概率去计算了一个概率，
但是他将因果关系进行了替换对调

12.5 贝叶斯法则及其应用

■ 贝叶斯法则的推导

- 引入背景证据 e 为条件的更通用的版本：

$$P(Y | X, e) = \frac{P(X | Y, e)P(Y | e)}{P(X | e)}$$

- 现实世界中，我们把一些未知原因（cause）的结果（effect）视为证据，并想要确定导致这个结果的原因，贝叶斯法则为：

$$\underbrace{P(\text{cause} | \text{effect})}_{\text{诊断}} = \frac{\overbrace{P(\text{effect} | \text{cause})}^{\text{因果}} P(\text{cause})}{P(\text{effect})}$$

12.5 贝叶斯法则及其应用

■ 示例4:

- 医生知道脑膜炎在 70% 的情况下会导致病人颈部僵硬。医生也知道一些无条件事实：病人患有脑膜炎的先验概率是 $1/50000$ ，而病人颈部僵硬的先验概率是 1%。
- 令 s 表示病人颈部僵硬的命题， m 表示病人患有脑膜炎的命题，则：

$$P(s | m) = 0.7$$

$$P(m) = 1/50\,000$$

$$P(s) = 0.01$$

$$P(m | s) = \frac{P(s | m)P(m)}{P(s)} = \frac{0.7 \times 1/50\,000}{0.01} = 0.0014$$

- 也就是说，期望700个有脖子僵硬症状的病人中只有不到1个人患有脑膜炎。

12.5 贝叶斯法则及其应用

■ 为什么一个方向的条件概率而不知道另一个方向的：

- 在示例4中，在脑膜炎领域，也许医生**经验性地**知道，每 5000 例颈部僵硬的病例中必然包含 1 例患有脑膜炎；也就是说，在从症状到病因的诊断方向上，医生有定量信息。这样的医生不需要使用贝叶斯法则。
- 但是，**诊断知识通常比因果知识更加脆弱**。如果突然流行脑膜炎，脑膜炎的无条件概率 $P(m)$ 就会上升。直接使用脑膜炎流行前病人的统计观测得出诊断概率 $P(m | s)$ 的医生不知道如何更新这个概率值，但从其他 3 个值来计算 $P(m | s)$ 的医生将会看到 $P(m | s)$ 会随着 $P(m)$ 成比例上升。最重要的是，**因果信息 $P(s | m)$ 不受疾病流行的影响，因为它仅仅反映脑膜炎的运作方式**。使用这种直接因果或基于模型的知识，提供了使概率系统在真实世界中可行所需的关键的健壮性。

12.5 贝叶斯法则及其应用-合并证据



■ 如果有两项或多项证据会发生什么？

- 如果病人不仅牙痛，还在牙齿上卡了一个钢针，她会得出什么结论？
- 由完全联合分布可以得出：

$$P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) = \alpha \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle$$

- 但是不能推广到变量较多的情况。可以使用贝叶斯法则重新表述问题：

$$P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) = \alpha P(\text{toothache} \wedge \text{catch} \mid \text{Cavity})P(\text{Cavity})$$

	toothache		$\neg$ toothache	
	catch	$\neg$ catch	catch	$\neg$ catch
cavity	0.108	0.012	0.072	0.008
$\neg$ cavity	0.016	0.064	0.144	0.576

图 12-3 Toothache、Cavity、Catch 世界的完全联合分布

12.5 贝叶斯法则及其应用-合并证据


■ 如果有两项或多项证据会发生什么？

- 如果 Toothache 和 Catch 是独立的就好了。
- 引入条件独立性（如果给定蛀牙的存在与否，这两个变量就是独立的）：

$$P(\text{toothache} \wedge \text{catch} \mid \text{Cavity}) = P(\text{toothache} \mid \text{Cavity})P(\text{catch} \mid \text{Cavity})$$

- 表达了给定 Cavity 时 toothache 和 catch 的条件独立性。
- 可以得到蛀牙的概率：

$$\begin{aligned} &P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) \\ &= \alpha P(\text{toothache} \mid \text{Cavity})P(\text{catch} \mid \text{Cavity})P(\text{Cavity}) \end{aligned}$$



Cavity 分隔了 Toothache 和 Catch，因为他是两者的直接原因。

12.5 贝叶斯法则及其应用-合并证据

■ 条件独立性

- 一般定义：给定第三个变量 Z ，两个变量 X 和 Y 的条件独立性：

$$P(X, Y | Z) = P(X | Z)P(Y | Z)$$

- 等价形式：

$$P(X | Y, Z) = P(X | Z) \text{ 和 } P(Y | X, Z) = P(Y | Z)$$

- 条件独立性断言也允许完全联合分布分解成许多小分布：

$$\begin{aligned} &P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}) \\ &= P(\textit{Toothache}, \textit{Catch} | \textit{Cavity})P(\textit{Cavity}) \\ &= P(\textit{Toothache} | \textit{Cavity})P(\textit{Catch} | \textit{Cavity})P(\textit{Cavity}) \end{aligned}$$

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界



12.6 朴素贝叶斯模型

■ 朴素贝叶斯模型

- ▣ 牙科的例子阐释了一种常见的模式，其中单个原因直接影响许多结果，给定原因时，所有这些结果都是条件独立的。此时，完全联合分布可以写作：

$$P(Cause, Effect_1, \dots, Effect_n) = P(Cause) \prod_i P(Effect_i | Cause)$$

- ▣ 这样的概率分布叫作朴素贝叶斯（Naive Bayes）模型。



12.6 朴素贝叶斯模型

■ 模型推导：

- 观测到的结果 $E = e$ ，剩余变量 Y 是未观测的。可采用从联合分布进行推断的标准方法：

$$P(Cause | e) = \alpha \sum_y P(Cause, e, y)$$

- 得：

$$\begin{aligned} P(Cause | e) &= \alpha \sum_y P(Cause) P(y | Cause) \left(\prod_j P(e_j | Cause) \right) \\ &= \alpha P(Cause) \left(\prod_j P(e_j | Cause) \right) \sum_y P(y | Cause) \\ &= \alpha P(Cause) \prod_j P(e_j | Cause) \end{aligned}$$

- 将**原因的先验概率**乘以在**给定原因时结果的条件概率的累积**；然后将结果归一化。

12.6 朴素贝叶斯模型

■ 使用朴素贝叶斯进行文本分类

- 文本分类任务：给定一个文本，判断它属于预先定义的类别集合中的哪个。这里“原因”是 Category 变量，“结果”也就是“证据”“用 HasWord_i 建模某些关键词的出现与否。



12.6 朴素贝叶斯模型

■ 使用朴素贝叶斯进行文本分类

□ 考虑从报纸文章中选取的以下两个例句：

- ▶ Stocks rallied on Monday, with major indexes gaining 1% as optimism persisted over the first quarter earnings season. (由于对第一季度财报的乐观情绪的持续，周一股票反弹，主要股指上涨 1%。)
- ▶ Heavy rain continued to pound much of the east coast on Monday, with flood warnings issued in New York City and other locations. (周一暴雨继续袭击东海岸大部分地区，纽约市和其他地区发布了洪水警报。)

□ 具体目标任务：把每个句子分入一个 Category——报纸的主要板块：news (新闻)、sports (体育)、business (商业)、weather (天气) 和 entertainment (娱乐)。

12.6 朴素贝叶斯模型

■ 使用朴素贝叶斯进行文本分类

$$P(Cause) \prod_i P(Effect_i | Cause)$$

- 使用朴素贝叶斯模型解决：朴素贝叶斯模型包含先验概率 $P(\text{Category})$ 和条件概率 $P(\text{HasWord}_i | \text{Category})$ 。
 - ▶ 例如，如果 9% 的文章是关于天气的，我们设 $P(\text{Category} = \text{weather}) = 0.09$ 。类似地， $P(\text{HasWord}_i | \text{Category})$ 被估计为每类文章中包含单词 i 的比例；或许 37% 关于商业的文章中含有编号为 6 的单词“股票”，所以 $P(\text{HasWord}_6 = \text{true} | \text{Category} = \text{business})$ 设置为 0.37。
- 为了对一篇新文章进行分类，需要检查哪些单词出现在了文章中，获得类别上的后验概率分布。如果只需预测一个类别，选取后验概率最大的那类。

12.6 朴素贝叶斯模型

■ 缺陷：

- 使用朴素贝叶斯模型假设单词在文章中独立出现，频率由文章类别决定。这种独立性假设在实践中显然是不成立的。
 - ▶ 例如，短语 “first quarter” 在商业（或体育）文章中出现得更加频繁，超过用 “first” 的概率和 “quarter” 的概率的乘积计算得出的概率。
- 对独立性的违背通常意味着最终的后验概率会比真实情况更接近 1 或 0。换句话说，该模型对自己的预测过于自信。

■ 优势：


- 但是，即使有这些错误，模型对可能**类别的排序**往往也是相当准确的。
- 为了朴素贝叶斯模型广泛应用于语言测定、文档检索、垃圾邮件过滤和其他分类任务。（后验概率的相对值更重要）

- 不确定性下的动作
- 基本概率记号
- 使用完全联合分布进行推断
- 独立性
- 贝叶斯法则及其应用
- 朴素贝叶斯模型
- 重游 wumpus 世界

12.7 重游 wumpus 世界

■ Wumpus世界（简化）

- 某些房间是**无底洞**，任何人漫游到这些房间都会被无底洞吞噬。
- 在与无底洞直接相邻的方格内，Agent 能感知到**微风**




12.7 重游 wumpus 世界

■ 智能体的传感器只提供了世界的部分信息

- 智能体在[1,2]和[2,1]都感知到了微风。
- 那么3个未访问但可达的方格 [1, 3]、[2, 2] 和 [3, 1]，每个都可能包含无底洞。

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

(a)



(b)

逻辑推断只能返回：
[1, 3]、[2, 2] 和 [3, 1] 都可能含有无底洞，那么智能体无法做出决策。

图 12-5 (a) 在 [1, 2] 和 [2, 1] 发现微风后，智能体被困住了——没有安全区域可以探索。(b) 对关于 [1, 3] 的查询，方格划分为 *known*、*frontier* 和 *other*

12.7 重游 wumpus 世界

■ 问题描述。

- 目标：计算 $[1,3]$ 方格中含有无底洞的概率。
- 给定无底洞性质：
 - ▶ 每个无底洞会让所有相邻方格有微风
 - ▶ 除 $[1, 1]$ 以外，所有其他方格拥有无底洞的概率是 0.2




图 12-5 (a) 在 $[1, 2]$ 和 $[2, 1]$ 发现微风后，智能体被困住了——没有安全区域可以探索。(b) 对关于 $[1, 3]$ 的查询，方格划分为 *known*、*frontier* 和 *other*

12.7 重游 wumpus 世界

■ 流程：

- 设定随机变量
- 写出完全联合概率分布
- 使用独立性简化完全联合概率分布
- 对当前问题指定证据
- 写出查询公式

12.7 重游 wumpus 世界

■ 确定需要的随机变量集合。

- 每个方格设定一个布尔变量 P_{ij} ，当且仅当方格 $[i, j]$ 确实含有一个无底洞时变量为真。
- 设定布尔变量 B_{ij} ，当且仅当方格 $[i, j]$ 有微风时变量为真；我们只为观测到的方格设置这些变量；在这个例子中是 $[1, 1]$ 、 $[1, 2]$ 和 $[2, 1]$ 。

■ 指定完全联合分布 P

- 由乘积法则：

$$P(P_{1,1}, \dots, P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1}) = P(B_{1,1}, B_{1,2}, B_{2,1} \mid P_{1,1}, \dots, P_{4,4})P(P_{1,1}, \dots, P_{4,4})$$

- 第一项是给定无底洞的配置时，微风的配置的条件概率分布；如果和无底洞相邻，它的值为 1，否则为 0。第二项是无底洞的配置的先验概率。每个方格独立于其他方格，以 0.2 的概率包含无底洞。

12.7 重游 wumpus 世界

■ 确定需要的随机变量集合。

- 每个方格设定一个布尔变量 P_{ij} ，当且仅当方格 $[i, j]$ 确实含有一个无底洞时变量为真。
- 设定布尔变量 B_{ij} ，当且仅当方格 $[i, j]$ 有微风时变量为真；我们只为观测到的方格设置这些变量；在这个例子中是 $[1, 1]$ 、 $[1, 2]$ 和 $[2, 1]$ 。

■ 指定完全联合分布 P

- 由乘积法则：

$$P(P_{1,1}, \dots, P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1}) = P(B_{1,1}, B_{1,2}, B_{2,1} \mid P_{1,1}, \dots, P_{4,4})P(P_{1,1}, \dots, P_{4,4})$$

- 右边（先验概率）利用绝对独立性分解：

$$P(P_{1,1}, \dots, P_{4,4}) = \prod_{i,j=1,1}^{4,4} P(P_{i,j})$$

12.7 重游 wumpus 世界


■ 问题求解

- 给定证据：证据包括在每个被访问的方格中是否观测到微风，以及每个这样的方格没有包含无底洞的事实。

$$b = \neg b_{1,1} \wedge b_{1,2} \wedge b_{2,1} \quad \text{known} = \neg p_{1,1} \wedge \neg p_{1,2} \wedge \neg p_{2,1}$$

- 查询：给定到目前为止的观测，方格 [1, 3] 含有无底洞的可能性是多大？

$$P(P_{1,3} \mid \text{known}, b)$$



12.7 重游 wumpus 世界

■ 问题求解


- 从完全联合分布中对各条目求和。令 unknown 表示除已知方格和查询方格 [1, 3] 外的其他方格变量 $P_{i,j}$ 的集合，可得：

$$P(P_{1,3} | known, b) = \alpha \sum_{unknown} P(P_{1,3}, known, b, unknown)$$

- 令 frontier 表示与已访问方格相邻的无底洞变量（除了查询方格）。令 other 表示其他未知方格的无底洞变量，有：

$$unknown = frontier \cup other$$


这有助于我们使用条件独立性，因为 (1,2) (2,1) 的微风仅与相邻方格相关



12.7 重游 wumpus 世界

■ 问题求解

- 可发现：给定 known、frontier 和 query 变量，观测到的微风条件独立于其他变量
- 把查询公式改写成另一种形式：




$$\begin{aligned}
 &P(P_{1,3} \mid \text{known}, b) \\
 &= \alpha \sum_{\text{unknown}} P(P_{1,3}, \text{known}, b, \text{unknown}) \quad [\text{根据式 (12-23)}] \\
 &= \alpha \sum_{\text{unknown}} P(b \mid P_{1,3}, \text{known}, \text{unknown}) P(P_{1,3}, \text{known}, \text{unknown}) \quad (\text{乘积法则}) \\
 &= \alpha \sum_{\text{frontier}} \sum_{\text{other}} P(b \mid \text{known}, P_{1,3}, \text{frontier}, \text{other}) P(P_{1,3}, \text{known}, \text{frontier}, \text{other}) \\
 &= \alpha \sum_{\text{frontier}} \sum_{\text{other}} P(b \mid \text{known}, P_{1,3}, \text{frontier}) P(P_{1,3}, \text{known}, \text{frontier}, \text{other})
 \end{aligned}$$

12.7 重游 wumpus 世界

■ 问题求解

□ 求和与内移：



$$P(P_{1,3} | known, b)$$

$$= \alpha \sum_{frontier} P(b | known, P_{1,3}, frontier) \sum_{other} P(P_{1,3}, known, frontier, other)$$

$$P(P_{1,3} | known, b)$$

$$= \alpha \sum_{frontier} P(b | known, P_{1,3}, frontier) \sum_{other} P(P_{1,3}) P(known) P(frontier) P(other)$$

$$= \alpha P(known) P(P_{1,3}) \sum_{frontier} P(b | known, P_{1,3}, frontier) P(frontier) \sum_{other} P(other)$$


$$= \alpha' P(P_{1,3}) \sum_{frontier} \boxed{P(b | known, P_{1,3}, frontier)} P(frontier)$$

当微风的观测与其他变量一致时，条件概率为1，否则为0

12.7 重游 wumpus 世界

■ 问题求解

□ 求和与内移:



$$P(P_{1,3} | known, b)$$

$$= \alpha \sum_{frontier} P(b | known, P_{1,3}, frontier) \sum_{other} P(P_{1,3}, known, frontier, other)$$

$$P(P_{1,3} | known, b)$$

$$= \alpha \sum_{frontier} P(b | known, P_{1,3}, frontier) \sum_{other} P(P_{1,3}) P(known) P(frontier) P(other)$$

$$= \alpha P(known) P(P_{1,3}) \sum_{frontier} P(b | known, P_{1,3}, frontier) P(frontier) \sum_{other} P(other)$$

$$= \alpha' P(P_{1,3}) \sum_{frontier} P(b | known, P_{1,3}, frontier) P(frontier)$$

仅 2^2 项求和
仅跟6个方格有关



标准公式

$$P(P_{1,3} | known, b) = \alpha \sum_{unknown} P(P_{1,3}, known, b, unknown)$$

2^{13} 项求和
跟所有方格有关

12.7 重游 wumpus 世界

■ 指定完全联合分布 P

□ 代入模型和它们相关的先验概率 $P(\text{frontier})$:




图 12-6 对边界变量 $P_{2,2}$ 和 $P_{3,1}$ 的一致模型，显示每个模型的 $P(\text{frontier})$ 。(a) $P_{1,3} = \text{true}$ 的 3 个模型，说明有两个或三个无底洞。(b) $P_{1,3} = \text{false}$ 的两个模型，说明有一个或两个无底洞

$$P(P_{1,3} \mid \text{known}, b) = \alpha' \langle 0.2(0.04 + 0.16 + 0.16), 0.8(0.04 + 0.16) \rangle \approx \langle 0.31, 0.69 \rangle$$

很容易计算(2,2)有无底洞的概率是86%，这一概率很明确地告诉智能体选(1,3)比选(2,2)要好。相反，逻辑智能体只能告诉智能体(1,3)和(2,2)都无法确定有没有无底洞，无法判定哪个更危险

本章小结

- 不确定性的产生是由于惰性和无知。在复杂的、非确定性的或部分可观测的环境中，不确定性是不可避免的
- 概率表达了智能体无法对一个语句的真值做出明确的判断。概率概括了智能体对于证据的信念。
- 智能体遵循决策论规划行为，决策论结合了智能体的信念和偏好，将最大期望效用的动作定义为最佳动作。
- 基本的概率记号包括简单命题和复杂命题上的先验概率（或无条件概率）和后验概率（或条件概率）
- 概率公理约束逻辑相关命题的概率。违背公理的智能体在某些情况下的行为必定是不理性的。

本章小结

- 完全联合概率分布为随机变量的每种完整赋值指定了概率。通常，完全联合概率分布过于庞大，但如果其可用时，它可以用于回答查询，只需简单地将其中与查询命题对应的可能世界的条目相加即可。
- 随机变量子集间的绝对独立性允许将完全联合分布分解成小的联合分布，极大地降低它的复杂度。
- 贝叶斯法则允许通过已知的条件概率去计算未知条件概率，将诊断方向上的条件概率（难以建模）转换为因果方向上的条件概率（人类更容易建模）。
- 朴素贝叶斯模型假设给定单原因变量时，所有结果变量具有条件独立性。模型大小随结果个数线性增长。

课程作业

■ 对于下面的每个断言，或者证明其为真，或者给出一个反例

□ *If $P(a|b, c) = P(b|a, c)$, then $P(a|c) = P(b|c)$*

□ *If $P(a|b, c) = P(a)$, then $P(b|c) = P(b)$*

□ *If $P(a|b) = P(a)$, then $P(a|b, c) = P(a|c)$*

■ 证明乘法规则的条件化版本：

□ $P(X, Y|e) = P(X|Y, e)P(Y|e)$

历史与趣闻

- 概率论是作为一种分析机会博弈的方法而被发明的。大约在公元 850 年，印度数学家马哈维拉卡里亚描述了如何设置一组不会输的赌局（现在称为荷兰赌）。在欧洲，第一个重要的系统性分析是吉罗拉莫·卡尔达诺在 1565 年前后提出来的。那时，由于 1654 年布莱兹·帕斯卡和皮埃尔·费马之间一段著名的通信所产生的一系列结果，概率论已经被确立为一门数学学科。
- 第一本出版的概率教材是惠更斯在 1657 年完成的 *On Reasoning in a Game of Chance*。约翰·阿巴思诺特在他翻译的惠更斯的这本书的序言中描述了“惰性与无知”的不确定性观点：“一个骰子，在有了明确的力和方向时，是不可能不落在确定的某一面的。只是我不知道是什么样的力和方向使它落在确定的某一面，所以我把它叫作机会，这样称呼只不过是缺乏艺术。”

历史与趣闻

- 关于概率数值的来源和状态一直存在着无休止的争论。
- **频率主义者 (frequentist)** 认为数值只能来源于实验：如果我们检测 100 个人，发现其中 10 个人有蛀牙，则我们可以说蛀牙的概率大约是 0.1。在这个观点里，断言“蛀牙概率是 0.1”的意思是，0.1 是在无限多个样本的极限下应观测到的比例。
- **客观主义者 (objectivist)** 的观点是，概率是宇宙的真实面貌，是物体以某种方式行动的倾向，而不仅仅是对观察者的信念度的描述。例如，一枚公平的硬币正面朝上的概率是 0.5 这一事实是硬币本身的倾向。在这个观点中，频率测量是在试图观测这些倾向。大多数物理学家同意量子现象客观上是概率性的。

历史与趣闻

- **主观主义者 (subjectivist)** 的观点是将概率描述为一种刻画智能体信念的方式，而不具有任何外部物理意义。主观贝叶斯学派观点允许任何对命题归因自洽的先验概率，但坚持在证据到达后进行适当的贝叶斯更新。
- 托马斯·贝叶斯 (Thomas Bayes, 1702—1761) 引入了关于条件概率的推理规则，这一规则在他死后以他的名字命名 (Bayes, 1763)。贝叶斯只考虑了均匀先验的情况，是拉普拉斯独立发展了先验概率的一般情况。自从 20 世纪 60 年代以来，贝叶斯概率推理就在人工智能中得到使用，特别是医疗诊断领域。

历史与趣闻

- 自从 20 世纪 50 年代以来，基于联合分布的朴素贝叶斯模型就已经在模式识别领域的文献中得到了广泛的研究（Duda and Hart, 1973）。从马龙（Maron, 1961）的工作开始，信息检索领域也经常在意无意间用到这种方法。
- 多明戈斯和帕扎尼（Domingos and Pazzani, 1997）为朴素贝叶斯推理即使在明显违反独立性假设的领域也能取得惊人成功提供了一解释。
 - ▶ 朴素贝叶斯分类器虽然假设特征独立，但实际上，它能够处理不同特征之间的相关性，因为它基于训练数据中的统计信息来估计条件概率。这意味着，即使存在一些特征之间的相关性，分类器可以从训练数据中学到这些关联，并在预测时考虑它们，尽管它的基本假设是特征独立的。

THANKS

Q & A