



人工智能原理与算法

第13章-概率推理

中科院自动化研究所 朱翔昱

- **前章：概率论中的基本要素，完全联合概率分布可以用于回答任何查询，独立性和条件独立性用于简化概率表示。**
- **本章：介绍一种系统方法，以贝叶斯网络(Bayesian Network) 更好地表示这些随机变量间的关系（独立性），以及如何用贝叶斯网络自然高效地进行推断。**

- **不确定域的知识表示**
- **贝叶斯网络**
- **条件分布的高效表达**
- **贝叶斯网络中的精确推理**
- **贝叶斯网络中的近似推理**

13.1 不确定域的知识表示

- 完全联合概率分布作为知识库可以回答任何关于域的问题，但同时其规模会随着变量数量的增长而变得非常大。此外，逐个指定可能世界的概率是不自然的（需要采集稀有数据）。
- 变量之间的独立性和条件独立性关系可以极大减少为定义联合分布而需要指定的概率的数量。

$$P(X|Y) = P(X) \text{ 或 } P(Y|X) = P(Y) \text{ 或 } P(X, Y) = P(X) P(Y)$$


$$P(X, Y|Z) = P(X|Z)P(Y|Z) \quad P(X|Y, Z) = P(X|Z) \text{ 和 } P(Y|X, Z) = P(Y|Z)$$

- 变量之间的依赖关系可以用图结构（Graph）来表示。

13.1 不确定域的知识表示

- **概率图模型 (probabilistic graphical model) 是用图(Graph) 来表示随机变量之间条件相关性的概率模型**
 - 根据边的性质不同, 可以将概率图模型分为两类:
 - **有向概率图模型**
代表性的有向概率图模型为贝叶斯网络 (Bayesian network)
 - **无向概率图模型**
代表性的无向图模型为马尔科夫网络 (Markov network) , 又称马尔科夫随机场 (Markov Random Field) 。

13.1 不确定域的知识表示



13.1 不确定域的知识表示

- 贝叶斯网络是一个有向图，其中每个结点都标注了定量的概率信息：
 - 每个节点对应一个随机变量，它可以是离散的，也可以是连续的。
 - 有向链路或箭头连接成对的节点。如果有从节点 X 指向节点 Y 的箭头，则称 X 是 Y 的一个父节点。图中没有有向环，因此它是一个有向无环图。
 - 每个结点 X_i 关联概率分布 $P(X_i | Parents(X_i))$ ，我们使用有限的参数量化父节点对该节点的影响。

13.1 不确定域的知识表示

■ 简单例子




图 13-1 一个简单的贝叶斯网络，其中 *Weather* 独立于其他 3 个变量，*Toothache* 和 *Catch* 在给定 *Cavity* 时条件独立

1. 描述的包含变量 *Toothache*、*Cavity*、*Catch* 和 *Weather*，对应四个结点。
2. *Weather* 独立于其他变量；
3. 给定 *Cavity* 时，*Toothache* 和 *Catch* 条件独立。

13.1 不确定域的知识表示

■ 例子





图 13-2 一个典型的贝叶斯网络，所示为其拓扑结构和条件概率表。在条件概率表中，字母 B 、 E 、 A 、 J 和 M 分别代表 *Burglary*、*Earthquake*、*Alarm*、*JohnCalls* 和 *MaryCalls*

- 家里安装了一个防盗警报器，可以探测入室盗窃，但它偶尔会被小型地震触发。
- 你还有两位邻居John和Mary，他们承诺，如果他们听到警报就给你打电话。John几乎总能在听到警报的时候给你打电话，但是，Mary平时喜欢听喧闹的音乐，因此经常完全错过了警报。
- 现在给定他们是否打过电话的证据，我们希望估计入室盗窃的概率。

13.1 不确定域的知识表示


■ 例子



- 入室盗窃和地震直接影响警报器报警的概率，但John和Mary是否打电话只依赖报警器。
- John和Mary不会直接察觉到入室盗窃，不会注意到小型地震，也不会在打电话之前互相商量。

13.1 不确定域的知识表示


■ 例子



- 网络中没有与Mary当前正在听喧闹音乐或John被其他噪声干扰相对应的节点。这些因素被归结到从Alarm到JohnCalls和MaryCalls的链路相关联的不确定性中。这展示了操作中的惰性与无知

13.1 不确定域的知识表示

■ 例子



相比于完全联合概率，1个大表格被分成5个小表格，有效简化

- 不确定域的知识表示
- 贝叶斯网络
- 条件分布的高效表达
- 贝叶斯网络中的精确推理
- 贝叶斯网络中的近似推理

13.2 贝叶斯网络-构造贝叶斯网络

■ 贝叶斯网络的语义

- 贝叶斯网络的语法由**每个结点都附加一些局部概率信息的有向无环图**组成。


- 包含有n个随机变量 $(x_1, x_2, \dots, x_n)$ 的完全联合分布可以表示为：

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i \mid \text{parents}(X_i))$$

- 完全联合概率分布的每一项都由可以贝叶斯网络中**局部条件分布的乘积**表示。因此贝叶斯网络也可以用于回答任何查询。

13.2 贝叶斯网络-构造贝叶斯网络

■ 贝叶斯网络的语义



将联合分布中的一些条目相乘（使用单个字母表示变量）

$$\begin{aligned}
 P(j, m, a, \neg b, \neg e) &= P(j \mid a)P(m \mid a)P(a \mid \neg b \wedge \neg e)P(\neg b)P(\neg e) \\
 &= 0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 = 0.000628
 \end{aligned}$$

13.2 贝叶斯网络-构造贝叶斯网络

■ 构造贝叶斯网络

$$\begin{aligned} \text{乘积法则: } & P(X_1, \dots, X_n) \\ &= P(X_n | X_{n-1}, \dots, X_1) P(X_{n-1}, \dots, X_1) \end{aligned}$$

- 首先考虑链式法则:

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_n | X_{n-1}, \dots, X_1) \dots P(X_2 | X_1) P(X_1) \\ &= \prod_{i=1}^n P(X_i | X_{i-1}, \dots, X_1) \end{aligned}$$

- 贝叶斯网络断言: 对于网络中的每个变量 X_i , 倘若 $Parents(X_i) \subseteq \{X_{i-1}, \dots, X_1\}$, 则:

$$P(X_i | X_{i-1}, \dots, X_1) = P(X_i | Parents(X_i))$$

- 只有在给定父节点, 每个节点条件独立于节点顺序中的其他前驱节点时, 贝叶斯网络才是问题域的正确表示。 **贝叶斯网络的构造, 需要经验与实验。**

13.2 贝叶斯网络-构造贝叶斯网络

■ 构造贝叶斯网络

1. **结点(Nodes)**: 首先确定建模域所需的变量集合, 再对它们**进行排序**, 得到 $\{X_1, \dots, X_n\}$ 。任何排序的顺序都是可行的, 但是如果变量的顺序是原因先于结果的, 那么产生的网络会更紧凑。
2. **边(Links)**: i 从1到 n , 循环执行:
 - 从 $X_1, \dots, X_{i-1}$ 中选择 X_i 的 **父结点的最小集合**, 使得公式 $P(X_i | X_{i-1} \dots, X_1) = P(X_i | Parents(X_i))$ 得到满足;
 - 为每个父节点插入一条从父节点到 X_i 的链路;
 - 条件概率表(CPTs): 记录条件概率表 $P(X_i | Parents(X_i))$ 。

13.2 贝叶斯网络-构造贝叶斯网络


■ 构造的合法性

- 每个结点只与前面的结点相连，这种构建方法保证了网络是无环的。（**保证为有向无环图**）
- 它不包含冗余的概率值，确保产生一致的网络。（**保证概率公理**）
- 此时，知识工程师或者专家不可能创建一个违反概率公理的贝叶斯网络。构造结果一定合法（但不一定紧致）

13.2 贝叶斯网络-构造贝叶斯网络

■ 举例：选择MaryCalls最小父节点

- 变量 MaryCalls 肯定被是否有 Burglary 或 Earthquake 影响，但这些影响不是直接的。



- 直觉上，对这个域的知识告诉我们，这些事件只通过它们对警报器的结果来影响玛丽打电话的行为。
- 给定警报器的状态，约翰是否打电话对玛丽的打电话行为没有影响。因此认为以下条件独立命题是成立的：

$$P(\text{MaryCalls} | \text{JohnCalls}, \text{Alarm}, \text{Earthquake}, \text{Burglary}) = P(\text{MaryCalls} | \text{Alarm})$$

13.2 贝叶斯网络-紧致性与结点排序


■ 贝叶斯网络的紧致性

- 贝叶斯网络除了是问题域的一种完备且无冗余的表示之外，通常还比完全联合概率分布**紧致**得多，从而能够处理具有许多变量的域。
- **紧致性指局部结构化**：局部结构化系统中，每个子组件仅与有限数量的其他组件直接交互，而与组件总数无关。局部结构化在复杂度上的增长速度通常是线性的而非指数级别的。

13.2 贝叶斯网络-紧致性与结点排序

■ 贝叶斯网络的复杂度


- 每个随机变量最多受到 k 个其他随机变量的直接影响，其中 k 是某个常数；
- 假设问题中存在 n 个布尔变量，由于指定条件概率表所需的信息数量最多是 2^k 个数值，因此整个网络可以用 $2^k \cdot n$ 个数值指定，而联合分布本身包含 2^n 个数值；
- 假设 $n=30$ ，每个结点有 $k=5$ 个父节点，则确定一个贝叶斯网络仅需要960个数值，但确定一个完全联合分布需要超过10亿个数值。



13.2 贝叶斯网络-紧致性与结点排序

■ 贝叶斯网络的复杂度

- 为一个全连接网络（每个变量，其所有前驱结点都作为父结点的网络）指定条件概率表所需的信息量和以表的形式指定联合概率分布所需的信息量同样多。
- 通常会忽略变量之间微弱的依赖关系，简化模型。通过增加网络额外的复杂性以获得精度上的一点点提高并不值得。




如果发生大地震，那么John和Mary即使听到警报也不会打电话来，因为他们会认为地震才是导致警报的原因。那么是否增加从Earthquake到JohnCalls和MaryCalls的链路（这样就扩大了表格）

13.2 贝叶斯网络-紧致性与结点排序

■ 构造时的结点排序


- **结点顺序的重要性：**即使在局部结构化的域内，也只能在结点顺序选择合适的情况下得到一个紧凑的贝叶斯网络
- **理想的顺序：原因先于结果**
- **成功的顺序：**按照 Earthquake, Burglary, Alarm, JohnCalls, MaryCalls, 的顺序添加结点。
- **糟糕的顺序：**按照 MaryCalls, JohnCalls, Alarm, Burglary, Earthquake的顺序添加结点。



13.2 贝叶斯网络-紧致性与结点排序

糟糕的顺序: MaryCalls -> JohnCalls -> Alarm -> Burglary -> Earthquake


1. 添加 MaryCalls: 无父节点。
2. 添加 JohnCalls: 如果 Mary 打了电话, 这可能意味着警报器触发了, 这让 John 更有可能去打电话。因此, JohnCalls 需要 MaryCalls 作为父节点。
3. 添加 Alarm: 显然, 如果两个人都打了电话, 警报器被触发的可能性比只有一个人或者没有人打电话更大, 所以需要把 MaryCalls 和 JohnCalls 都作为父节点。
4. 添加 Burglary: 入室抢劫主要取决于报警器, 如果已经知道了警报器的状态, 则 John 或 Mary 的电话可能告知他们失误的信息, 而不是入室盗窃的信息。



13.2 贝叶斯网络-紧致性与结点排序



糟糕的顺序: MaryCalls -> JohnCalls -> Alarm -> Burglary -> Earthquake

5. 添加Earthquake: 如果警报器被触发, 则更可能发生了地震。但是, 如果我们知道确实发生了入室盗窃, 那么就可以解释警报器的行为, 使得发生地震的概率只会比正常情况稍高一点。反过来说, 如果没有发生入室盗窃, 那么发生地震的概率就会显著上升。因此, 需要 Alarm 和Burglary 都作为父节点。



13.2 贝叶斯网络-紧致性与结点排序

■ 构造时的结点排序




- 得到的网络比原始网络多了两条链路，并且需要13个条件概率而非10个。
- **一些链路表示的关系十分脆弱，概率建模困难且不自然（诊断vs.因果）。**
- 如果坚持使用因果模型，则最终需要指定的数值更少，并且条件概率会更容易建模。

13.2 贝叶斯网络-紧致性与结点排序

■ 构造时的结点排序

- 最糟糕的情况：与联合概率完全相同（31个概率）
- 没有表明所有的条件独立性关系，因此最终指定了许多不必要的数值。




最糟糕的顺序： MaryCalls -> JohnCalls -> Burglary -> Earthquake -> Alarm

13.2 贝叶斯网络-条件独立性性质

■ 条件独立性的“非子孙”性质：


- 给定父结点，一个结点条件独立于其他祖先结点
- 更一般：**给定父结点**，每个变量条件独立于它的**非子孙结点**



给定父节点（浅紫色区域中所示的 U_i ），节点 X 条件独立于它的非子孙节点（例如， Z_{ij} ）

13.2 贝叶斯网络-条件独立性性质

■ 条件独立性的“非子孙”性质：




给定 Alarm 的值，变量 JohnCalls 独立于 Burglary、Earthquake 和 MaryCalls。

13.2 贝叶斯网络-条件独立性性质

■ 条件独立性的“非子孙”性质：


- 给定一个变量的父结点、子结点和子结点的父结点（马尔科夫毯），其条件独立于网络中所有其他结点



给定它的马尔可夫毯（浅紫色区域），节点 X 条件独立于网络中的所有其他节点。

13.2 贝叶斯网络-条件独立性性质

■ 条件独立性的“非子孙”性质：



给定Alarm和Earthquake后, Burglary独立于JohnCalls及MaryCalls

13.2 贝叶斯网络-条件独立性性质

■ 利用“非子孙”性质：

- 通常会对条件独立性有这样的问题：给定第三个集合 Z ，节点集合 X 是否条件独立于另一个集合 Y ？
- d分离法：
 - 只考虑包含 X 、 Y 、 Z 和它们祖先的祖先子图。
 - 道德化：每个节点的父节点两两相连；用无向链路替换所有有向链路。
 - 在得到的道德图中，如果 Z 阻塞了所有 X 和 Y 之间的路径，则 Z d 分离 X 和 Y 。那样的话，给定 Z 时， X 将条件独立于 Y 。

13.2 贝叶斯网络-条件独立性性质


□ d分离法:

- 只考虑包含 X、Y、Z 和它们祖先的祖先子图。
- 道德化：每个节点的父节点两两相连；用无向链路替换所有有向链路。
- 在得到的道德图中，如果 Z 阻塞了所有 X 和 Y 之间的路径，则 Z d 分离 X 和 Y。那样的话，给定 Z 时，X 将条件独立于 Y。

X: JohnCalls, MaryCalls

Y: Burglary, Earthquake

Z : Alarm



- 概率图模型
- 贝叶斯网络
- 条件分布的高效表达
- 贝叶斯网络中的精确推理
- 贝叶斯网络中的近似推理

13.2 条件分布的高效表达

■ 概率表的缺陷：

- 即使最大父结点数量 k 很小，为一个节点填充条件概率表也需要 $O(2^k)$ 个数据，而确定这个表格还需要大量的经验和数据。




- 条件概率可能存在某种规律，即符合某种特殊类型的标准分布/正则分布（canonical distribution），该分布只需**少量参数**即可完全描述条件概率，而不需要指定完整的表格。



- **通过指定该条件概率的类型，并提供该类型所需的一些参数来指定完整的表——比起提供数目呈指数增长的条件分布表更加高效。**

13.2 条件分布的高效表达

■ 概率表的缺陷：



- 举例：指定一个高斯分布
 - 给出从-100到+100的所有概率值。（条件概率表）
 - 指定标准值和方差。（指定参数）

13.2 条件分布的高效表达-确定性关系

■ 确定性关系：

- 一个确定性结点的取值完全能够由其父结点的取值确定，没有任何不确定性。
- 逻辑关系：父结点Canadian(加拿大人)，US(美国人)，Mexican(墨西哥人)与子结点NorthAmerican(北美人)之间的关系就是，子结点是其全部父结点的析取 ($\Rightarrow$)。
- 数值关系：
 - 年末水库中的储水量是原始水量加上流入量（河流、径流、降水）减去流出量（放水、蒸发、渗漏）
 - 汽车的最优价格是区域内每个经销商的最低价格
- 使用编程语言来指定确定性关系



13.2 条件分布的高效表达-噪声逻辑

■ 不确定性关系：噪声逻辑关系

- 噪声或（noisy-OR）关系，它是逻辑或的推广：
 - 逻辑或关系指一系列原因中，每个原因都可能导致结果。
 - **噪声或模型为每个父结点导致子结点为真的能力引入了不确定性——父结点与子结点之间的因果关系有可能被抑制。**
- **例子：**在命题逻辑中当且仅当Cold（感冒）、Flu（流感）、或者Malaria（疟疾）为真，我们说Fever（发烧）为真。

$$\text{Cold} \vee \text{Flu} \vee \text{Malaria} \Rightarrow \text{Fever}$$

引入噪声后：病人可能得了感冒却没有发烧的症状。

13.2 条件分布的高效表达-噪声逻辑

■ 不确定性关系：噪声逻辑关系

□ 噪声或模型的两个假设：

- 首先，假设所有可能的原因都已列出。
- 其次，假设每个父结点的**抑制**独立于其他父结点的**抑制**
 - 例如，无论什么原因抑制了疟疾引起发烧（疟疾抗体），它都独立于抑制流感引起发烧的原因（流感抗体）。

- 给定这些假设，发烧为假当且仅当其**所有为真的父结点都被抑制**，这种情况的概率等于每个父结点的抑制概率的乘积。


Cold $\vee$ Flu $\vee$ Malaria $\nrightarrow$ Fever

13.2 条件分布的高效表达-噪声逻辑

■ 不确定性关系：噪声逻辑关系

- 如果随机变量满足噪声或关系，那么子节点为假当且仅当其**所有为真的父结点都被抑制**，这种情况的概率等于每个父结点的抑制概率的乘积：
- 父节点的抑制概率：父节点发生，子节点没有发生的概率

贝叶斯网络



条件概率

$$P(x_i \mid \text{parents}(X_i)) = 1 - \prod_{\{j; X_j = \text{true}\}} q_j$$

$$q_{\text{cold}} = P(\neg \text{fever} \mid \text{cold}, \neg \text{flu}, \neg \text{malaria}) = 0.6$$

$$q_{\text{flu}} = P(\neg \text{fever} \mid \neg \text{cold}, \text{flu}, \neg \text{malaria}) = 0.2$$

$$q_{\text{malaria}} = P(\neg \text{fever} \mid \neg \text{cold}, \neg \text{flu}, \text{malaria}) = 0.1$$

13.2 条件分布的高效表达-噪声逻辑

<i>Cold</i>	<i>Flu</i>	<i>Malaria</i>	$P(\text{fever} \cdot)$	$P(\neg \text{fever} \cdot)$
<i>f</i>	<i>f</i>	<i>f</i>	0.0	1.0
<i>f</i>	<i>f</i>	<i>t</i>	0.9	0.1
<i>f</i>	<i>t</i>	<i>f</i>	0.8	0.2
<i>f</i>	<i>t</i>	<i>t</i>	0.98	$0.02 = 0.2 \times 0.1$
<i>t</i>	<i>f</i>	<i>f</i>	0.4	0.6
<i>t</i>	<i>f</i>	<i>t</i>	0.94	$0.06 = 0.6 \times 0.1$
<i>t</i>	<i>t</i>	<i>f</i>	0.88	$0.12 = 0.6 \times 0.2$
<i>t</i>	<i>t</i>	<i>t</i>	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

图 13-5 $P(\text{Fever} | \text{Cold}, \text{Flu}, \text{Malaria})$ 的完整条件概率表，假设噪声或模型使用的 3 个 q 值用粗体表示

$$q_{\text{cold}} = P(\neg \text{fever} | \text{cold}, \neg \text{flu}, \neg \text{malaria}) = 0.6$$

$$q_{\text{flu}} = P(\neg \text{fever} | \neg \text{cold}, \text{flu}, \neg \text{malaria}) = 0.2$$

$$q_{\text{malaria}} = P(\neg \text{fever} | \neg \text{cold}, \neg \text{flu}, \text{malaria}) = 0.1$$

一个依赖于 k 个父节点的变量的噪声逻辑关系可以用 $O(k)$ 个参数而非 $O(2^k)$ 来描述


13.2 条件分布的高效表达-连续变量

■ 包含连续变量的贝叶斯网络：


- 离散化：将所有可能的取值划分到固定的区间集合中
 - 温度可以分为3类：（ $< 0^{\circ}\text{C}$ ）、（ $0 \sim 100^{\circ}\text{C}$ ）和（ $> 100^{\circ}\text{C}$ ）
- 定义一族标准的概率密度函数
 - 高斯（或称正态）分布函数，每个变量可以用均值和方差来指定
- 非参数化表示——用一组实例隐式地定义条件分布，每个实例包含父结点和子结点变量的特定取值



离散化




高斯



非参数

13.2 条件分布的高效表达-连续变量


- 混合贝叶斯网络：同时包含离散随机变量和连续随机变量的网络。
 - 给定离散或连续父节点的连续变量的条件分布
 - 给定连续父节点的离散变量的条件分布



13.2 条件分布的高效表达-连续变量

■ 例子：一个简单的混合贝叶斯网络

- 顾客根据水果的价格购买一些水果，而价格又取决于收成（harvest）数目和政府的补贴（subsidy）政策是否在进行。




- 离散变量 (Subsidy 和 Buys)
- 连续变量 (Harvest 和 Cost)



13.2 条件分布的高效表达-连续变量

■ 情况1：父节点连续+离散，子节点连续



□ 考虑 $P(\text{Cost}|\text{Harvest}, \text{Subsidy})$

- 对于离散的父节点Subsidy，通过枚举的方式处理。
- 对于连续的父节点Harvest，使用高斯分布，并指定价格cost的分布是依赖于收成harvest的函数，最常见选择线性函数。

$$P(c|h, \text{subsidy}) = \mathcal{N}(c; a_t h + b_t, \sigma_t^2) = \frac{1}{\sigma_t \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t} \right)^2}$$

$$P(c|h, \neg \text{subsidy}) = \mathcal{N}(c; a_f h + b_f, \sigma_f^2) = \frac{1}{\sigma_f \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{c - (a_f h + b_f)}{\sigma_f} \right)^2}$$

Cost 的条件分布通过命名线性高斯分布并提供参数 a_t 、 b_t 、 σ_t 、 a_f 、 b_f 与 σ_f 得以指定

13.2 条件分布的高效表达-连续变量

■ 情况1：父节点连续+离散，子节点连续




图 13-7 (a) 和 (b) 分别显示了 *Subsidy* 为真与假时，*Cost* 作为 *Harvest* 的函数的概率分布。(c) 所示为 $P(\text{Cost} | \text{Harvest})$ ，它由 *Subsidy* 两种情况的概率求和得到


- 在每种情况下， c 相对于 h 的斜率都是负的，因为价格随着收成的增加而下降。
- 有补贴的时候，价格更低（偏左），无补贴的时候，价格更高（偏右）

13.2 条件分布的高效表达-连续变量

■ 情况2：父节点连续，子节点离散

□ 考虑 $P(\text{Buys}|\text{Cost})$

- 如果价格低，顾客就会购买。
- 如果价格高，顾客就不会购买。
- 如果价格处于某个中间区域，购买的概率会平稳变化
- 换句话说，条件分布表现得像一个“软”阈值函数



13.2 条件分布的高效表达-连续变量

■ 情况2：父节点连续，子节点离散



□ 标准正态分布的积分构造软阈值

$$\Phi(x) = \int_{-\infty}^x \mathcal{N}(s; 0, 1) ds$$

- $\Phi(x)$ 是 x 的增函数，但购买的概率随着价格增加而降低，故需要对函数进行翻转：

$$P(\text{buys} \mid \text{Cost} = c) = 1 - \Phi((c - \mu) / \sigma)$$

- 价格阈值出现在 μ 附近，阈值区间的宽度正比于 σ ，购买的概率随着价格上涨而降低。




13.2 条件分布的高效表达-连续变量

■ 情况2：父节点连续，子节点离散

- 使用逻辑斯蒂函数构造软阈值
- 逻辑斯蒂函数 $1/(1 + e^{-x})$ 将任意的x映射到0-1之间

$$P(buys | Cost = c) = 1 - \frac{1}{1 + e^{-\frac{4}{\sqrt{2\pi}} \cdot \frac{c - \mu}{\sigma}}}$$




- logit 事实上“尾部”更长。通常更适合实际场景
- 逻辑斯蒂函数有时在数学上更容易处理
- 在机器学习中有广泛的应用。

13.2 条件分布的高效表达-连续变量

■ 总结：混合贝叶斯网络


- 离散->连续：枚举法，每个离散值一个概率分布
- 连续->连续：线性高斯分布，均值为父节点的线性函数
- 连续->离散：软阈值函数，Logit



13.2 条件分布的高效表达-真实案例

■ 案例：汽车保险

- 根据投保人和投保车辆信息，决定收取的保险费用。



13.2 条件分布的高效表达-真实案例

■ 案例：汽车保险

□ 输出节点（索赔）

- Medical Cost: 医疗索赔
- Liability Cost: 诉讼索赔
- Property Cost: 失窃索赔

□ 输入节点（信息）

- 个人信息：年龄、驾龄、驾驶记录、诚信
- 车辆信息：品牌、型号、制造年份、安全措施
- 驾驶情况：年度驾驶里程、是否有车库

□ 中间节点（隐变量）

- 使网络具有合理的稀疏性以及可管理参数数量，使因果关系更加明晰。





图 13-9 用于评估汽车保险申请的贝叶斯网络

13.2 条件分布的高效表达-真实案例


■ 案例：汽车保险



- 中间节点：社会经济类别(SocioEcon)，对申请人社会属性的一个综合评估。
- 父节点Age：年龄越大，经济和社会地位可能越高。
- 子节点RiskAdversion：投保人的抗风险能力
- 子节点ExtraCar：是否有其他车辆
- 子节点MakeModel：车辆品牌

13.2 条件分布的高效表达-真实案例


■ 案例：汽车保险



- 中间节点：RiskAdversion，申请人抗风险能力
- 父节点Age：年龄越大，越谨慎。
- 父节点SocioEcon：某些社会角色具有更高的风险意识
- 子节点DrivingBehavior：驾驶风格
- 子节点AntiTheft：是否安装防盗设备

13.2 条件分布的高效表达-真实案例

■ 案例：汽车保险



- 中间节点：Accident，发生事故的可能
- 父节点Mileage：年度质检
- 父节点DrivingBehavior：驾驶风格
- 子节点MedicalCost：医疗保险额
- 子节点LiabilityCost：索赔保险额

13.2 条件分布的高效表达-真实案例

■ 案例：汽车保险




图 13-9 用于评估汽车保险申请的贝叶斯网络

- 中间节点（隐变量）使得输入节点（申请人的客观信息）和输出节点（索赔额）的逻辑关系更加清晰。

- 概率图模型
- 贝叶斯网络
- 条件分布的高效表达
- 贝叶斯网络中的精确推理
- 贝叶斯网络中的近似推理

13.3 贝叶斯网络中的精确推理

- 概率推理系统的基本任务：给定一些观测到的事件(event)，通常是一组证据变量(evidence variable)的赋值，计算一组查询变量(query variable)的后验概率分布。

- 例：在入室盗窃的贝叶斯网络中，观察到了事件：JohnCalls=true且MaryCalls=true，问出现盗贼的概率是多少？

$$P(\text{Burglary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}) = \langle 0.284, 0.716 \rangle$$

13.3 贝叶斯网络中的精确推理

- 概率推理系统的**基本任务**：给定一些观测到的事件(event)，通常是一组**证据变量**(evidence variable)的赋值，计算一组**查询变量**(query variable)的后验概率分布。
- 为了简化表示，每次只考虑一个查询变量
 - X 代表查询变量
 - E 代表证据变量 $E_1, \dots, E_m$ 的集合， e 是一个特定的观测事件
 - Y 代表隐变量 $Y_1, \dots, Y_l$
 - 完整的变量集合是 $\{X\} \cup E \cup Y$
 - 一个典型的查询是求后验概率分布 $P(X|e)$

13.3 贝叶斯网络中的精确推理

■ 精确推理的方法

□ 枚举推理

- 基于完全联合概率分布推断

□ 变量消元法

- 快速方法

13.3 贝叶斯网络精确推理-枚举推理

■ 通过枚举进行推理

- 前一章提到，任何条件概率都可以通过对完全联合分布的项求和来计算：

$$P(X | e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

- $P(X, e, y)$ 可以写作网络中条件概率的乘积，因此可以根据通过计算贝叶斯网络中条件概率的乘积之和回答查询。

13.3 贝叶斯网络精确推理-枚举推理


■ 通过枚举进行推理

□ 考虑查询

$P(\text{Burglary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true})$

- 查询的隐变量是Earthquake与Alarm，使用变量的首字母简化表达式，得到：

$$P(B \mid j, m) = \alpha P(B, j, m) = \alpha \sum_e \sum_a P(B, j, m, e, a)$$




13.3 贝叶斯网络精确推理-枚举推理

■ 通过枚举进行推理

- 仅考虑Burglary=true, 利用条件概率乘积, 可以得到

$$P(b | j, m) = \alpha \sum_e \sum_a P(b)P(e)P(a | b, e)P(j | a)P(m | a)$$

$$P(b | j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a | b, e)P(j | a)P(m | a)$$



- 通过依次循环中间变量, 并在循环时用条件概率表表项的乘积来计算。
- 对于每个求和, 需要对中间变量的可能的值进行循环。

13.3 贝叶斯网络精确推理-枚举推理

■ 通过枚举进行推理

- 仅考虑Burglary=true, 利用条件概率乘积, 可以得到

$$P(b \mid j, m) = \alpha \sum_e \sum_a P(b) P(e) P(a \mid b, e) P(j \mid a) P(m \mid a)$$

$$P(b \mid j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a \mid b, e) P(j \mid a) P(m \mid a)$$

- 这个表达式需要对4项 (e, a遍历) 进行求和, 每一项都是通过5个概率相乘计算得到。
- 在最坏的情况下 (几乎所有变量都是中间变量), 需要对几乎所有的变量求和, 直接实现的复杂性是 $O(n2^n)$ 。
- 是否有加速手段?

13.3 贝叶斯网络精确推理-枚举推理

■ 通过枚举进行推理

$$P(b | j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a | b, e) P(j | a) P(m | a)$$





图 13-10 式 (13-5) 所示表达式的结构。计算过程自顶向下，沿着每条路径将值相乘，并在“+”节点上求和。注意 j 和 m 的路径重复

13.3 贝叶斯网络精确推理-枚举推理

■ 通过枚举进行推理



重复计算，存在冗余

13.3 贝叶斯网络中的精确推理

■ 精确推理的方法

□ 枚举推理

- 基于完全联合概率分布推断

□ 变量消元法

- 快速方法

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元算法

- 通过消除枚举算法中的重复计算，算法效率可以得到极大的改进。
- 基本思想：在计算一次之后保存结果供后续使用（存储+查表）
- 变量消元算法：
 - 从下式**右到左**的顺序计算，在计算过程中**存储中间结果**，对每个变量的求和只计算**包含该变量的部分**

$$P(B|j, m) = \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) P(j|a) P(m|a)$$



$$P(B|j, m) = \alpha \underbrace{P(B)}_{f_1(B)} \sum_e \underbrace{P(e)}_{f_2(E)} \boxed{\sum_a \underbrace{P(a|B, e)}_{f_3(A, B, E)} \underbrace{P(j|a)}_{f_4(A)} \underbrace{P(m|a)}_{f_5(A)}}$$



从右到左

13.3 贝叶斯网络精确推理-变量消元

■ **变量消元算法**

$$P(B|j,m) = \alpha \underbrace{P(B)}_{f_1(B)} \sum_e \underbrace{P(e)}_{f_2(E)} \sum_a \underbrace{P(a|B,e)}_{f_3(A,B,E)} \underbrace{P(j|a)}_{f_4(A)} \underbrace{P(m|a)}_{f_5(A)}$$

□ **概率的矩阵表示：** 每个因子是一个由其参数变量的值为索引的矩阵。

- 例如： $P(j|a)$ 和 $P(m|a)$ 的因子 $f_4(A)$ 和 $f_5(A)$ 只依赖A，因此它们是二元向量：

$$f_4(A) = \begin{pmatrix} P(j|a) \\ P(j|\neg a) \end{pmatrix} = \begin{pmatrix} 0.90 \\ 0.05 \end{pmatrix}$$

$$f_5(A) = \begin{pmatrix} P(m|a) \\ P(m|\neg a) \end{pmatrix} = \begin{pmatrix} 0.70 \\ 0.01 \end{pmatrix}$$

- 例如： $P(a|B,e) = f_3(A,B,E)$ 是一个2x2x2表格，即给定A,B,E的值作为索引，即可查找 $P(a|B,e)$ 的值

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元算法

- 用因子矩阵替换概率，可以将查询表达式写作：

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

“ $\times$ ”是逐点乘积算子(后面介绍)

- 两个因子的逐点乘积的结果是产生一个包含两个因子所有变量的新因子
- 从右到左，计算因子矩阵。
- 遇到求和符号，则将右侧所有因子矩阵进行逐点乘积，得到新的因子。新的因子中，不包含求和的因子。(变量消元)
- 最后到最左侧生成包含解的因子，即查询概率。

13.3 贝叶斯网络精确推理-变量消元

■ **变量消元算法** $P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$

1. 首先, 计算 f_3 , f_4 和 f_5 , 并从 f_3 , f_4 和 f_5 的乘积中求和消元 A , 得到一个新的2x2因子 $f_6(B, E)$, 其索引范围是 B 与 E :

$$\begin{aligned} f_6(B, E) &= \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A) = (f_3(a, B, E) \times f_4(a) \\ &\times f_5(a)) + (f_3(\neg a, B, E) \times f_4(\neg a) \times f_5(\neg a)) \end{aligned}$$

- 利用这些因子, 可以将查询表达式写作:

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times f_6(B, E)$$

13.3 贝叶斯网络精确推理-变量消元

■ **变量消元算法**
$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times f_6(B, E)$$

2. 然后从 f_2 和 f_6 的乘积中求和消元 E ，得到2x1因子 $f_7(B)$

$$\begin{aligned} f_7(B) &= \sum_e f_2(E) \times f_6(B, E) \\ &= f_2(e) \times f_6(B, e) + f_2(\neg e) \times f_6(B, \neg e) \end{aligned}$$

• 剩下表达式：

$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$

3. 消元完毕，获得最终查找表

- $f_1(B)$ 和 $f_7(B)$ 都是2x1因子，点积且归一化后为一个2x1的表格，包含 $B=\text{true}$ 和 $B=\text{false}$ 两种情况，对 $P(B|j, m)$ 的查询可以直接查表获得

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元算法

□ 上述过程有两个基本的计算操作：

- 求两个因子的逐点乘积
- 从因子的乘积中求和消元一个变量

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$



$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times f_6(B, E)$$



$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元的复杂度——逐点乘积

- 设两个因子 f 和 g 的逐点乘积生成了一个新因子 h ，它的变量是 f 与 g 中变量的并集，**元素由这两个因子中相应元素的乘积给出**。假设这两个因子的公共变量是 $Y_1, \dots, Y_k$ ，则有：

$$\begin{aligned} & f(X_1, \dots, X_j, Y_1, \dots, Y_k) \times g(Y_1, \dots, Y_k, Z_1, \dots, Z_l) \\ &= h(X_1, \dots, X_j, Y_1, \dots, Y_k, Z_1, \dots, Z_l) \end{aligned}$$

- 如果所有变量都是二值的，则 f 和 g 分别有 2^{j+k} 和 2^{k+l} 个条目，逐点乘积有 2^{j+k+l} 个条目
- 逐点乘积获得的矩阵比任何被乘的矩阵有更多的变量，并且矩阵的规模与变量的数量呈**指数关系**。

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元的复杂度——逐点乘积

X	Y	$f(X, Y)$	Y	Z	$g(Y, Z)$	X	Y	Z	$h(X, Y, Z)$
t	t	0.3	t	t	0.2	t	t	t	$0.3 \times 0.2 = 0.06$
t	f	0.7	t	f	0.8	t	t	f	$0.3 \times 0.8 = 0.24$
f	t	0.9	f	t	0.6	t	f	t	$0.7 \times 0.6 = 0.42$
f	f	0.1	f	f	0.4	t	f	f	$0.7 \times 0.4 = 0.28$
						f	t	t	$0.9 \times 0.2 = 0.18$
						f	t	f	$0.9 \times 0.8 = 0.72$
						f	f	t	$0.1 \times 0.6 = 0.06$
						f	f	f	$0.1 \times 0.4 = 0.04$

图 13-12 逐点乘积示例: $f(X, Y) \times g(Y, Z) = h(X, Y, Z)$

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元的复杂度——求和消元

- 从因子矩阵的乘积中求和消元一个变量是通过依次取该变量的每个值得到的子矩阵相加来完成的
 - 例如，为了从 $h(X, Y, Z)$ 中求和消元 X ，写作

$$h_2(Y, Z) = \sum_x h(x, Y, Z)$$

$$= h(x, Y, Z) + h(\neg x, Y, Z)$$

$$= \begin{pmatrix} 0.06 & 0.24 \\ 0.42 & 0.28 \end{pmatrix} + \begin{pmatrix} 0.18 & 0.72 \\ 0.06 & 0.04 \end{pmatrix} = \begin{pmatrix} 0.24 & 0.96 \\ 0.48 & 0.32 \end{pmatrix}$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元的复杂度——求和消元

□ 求和消元的技巧

- 任何不依赖于待求和消元的变量的因子都可以移到求和符号之外

$$\sum_x f(X, Y) \times g(Y, Z) = g(Y, Z) \times \sum_x f(X, Y)$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性

- 使用贝叶斯网络对完全联合概率展开时，不同的求和顺序，计算量不同：

- 排序1：左e右a（先对a求和，再对e求和）

$$P(B|j, m) = \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) P(j|a) P(m|a)$$

- 排序2：左a右e（先对e求和，再对a求和）

$$P(B|j, m) = \alpha P(B) \sum_a P(j|a) P(m|a) \sum_e P(a|B, e) P(e)$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性

- 不同的变量排序会产生不同的中间因子。
- 前述例子先消元A再消元E。如果换一种方式，计算过程变成：

原:
$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

新:
$$P(B|j, m) = \alpha f_1(B) \times \sum_a f_4(A) \times f_5(A) \times \sum_e f_2(E) \times f_3(A, B, E)$$

计算过程中将产生新的因子 $f_6(A, B)$

$f(A, B)$ 和 $f(B, E)$ 的矩阵大小可能差异非常大，取决于A,B,E可能取值范围

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性

- 变量消元的时间和空间要求是由算法运行过程中构造的**最大因子的规模**决定的。(矩阵包含几个随机变量)
- 这又由变量的消元顺序和网络的结构决定。
- 确定最优排序是困难的，但可以使用启发式方法
 - 贪心法：消除那些使下一个被构造的因子规模最小的变量
 - 在计算之前，先找到每个变量消元所需计算的最大的中间矩阵（只计算矩阵的大小），选一个矩阵最小的变量消元。

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性——消去叶节点

- 再考虑一种特殊情况：


$P(\text{JohnCalls} | \text{Burglary} = \text{true})$ ，像之前方法一样，写出嵌套求和式：

$$P(J|b) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(J|a) \sum_m P(m|a) = 1$$

- 变量M与查询无关。
- 可以删除任何非查询变量或非证据变量的叶结点。反复进行这一过程，提高变量消元算法效率。
- 在大型查询任务中，不是所有变量都与查询相关，比如保险网络中，可以删去大量无关变量。

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性——消去叶节点



推断目标：计算边际概率 $P(x_5)$

$$P(x_1, x_2, x_3, x_4, x_5)$$

$$= P(x_1)P(x_2 \mid x_1)P(x_3 \mid x_2)P(x_4 \mid x_3)P(x_5 \mid x_3)$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性——消去叶节点

- 假设随机变量均为离散型变量

$$\begin{aligned}
 P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1, x_2, x_3, x_4, x_5) \\
 &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2 | x_1)P(x_3 | x_2)P(x_4 | x_3)P(x_5 | x_3) \\
 &= \sum_{x_3} P(x_5 | x_3) \sum_{x_4} P(x_4 | x_3) \sum_{x_2} P(x_3 | x_2) \sum_{x_1} P(x_1)P(x_2 | x_1) \\
 &= \sum_{x_3} P(x_5 | x_3) \sum_{x_4} P(x_4 | x_3) \sum_{x_2} P(x_3 | x_2) m_{12}(x_2),
 \end{aligned}$$

下标*i*表示此项是对 x_i 求和的结果，下标*j*表示此项中剩下的其他变量

13.3 贝叶斯网络精确推理-变量消元

■ 变量排序和变量相关性——消去叶节点

□ 重复变量消去，得到

$$P(x_5) = \sum_{x_3} P(x_5 | x_3) \sum_{x_4} P(x_4 | x_3) m_{23}(x_3)$$


对 x_4 的求和与 m_{23} 无关

$$= \sum_{x_3} P(x_5 | x_3) m_{23}(x_3) \sum_{x_4} P(x_4 | x_3)$$

x_4 为非查询非证据叶节点，属于无关变量，直接删去

$$= \sum_{x_3} P(x_5 | x_3) m_{23}(x_3)$$

$$= m_{35}(x_5)$$



13.3 贝叶斯网络精确推理-变量消元

■ 变量消元算法的优缺点——优点

- 通过利用乘法对加法的分配律，使用变量消去把**多个变量**的积的求和问题，转化为对**部分变量**交替求积和求和的问题。
- 这种转化使得每次的求和与求积运算**限制在局部，仅与部分变量有关**，从而简化了计算。**在保险网络中，变量消元比枚举快1000倍。**

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$



$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times f_6(B, E)$$




$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$

13.3 贝叶斯网络精确推理-变量消元

■ 变量消元算法的优缺点——缺点

- 贝叶斯网络中精确推断的复杂性高度依赖于网络的结构，仅适用于树形结构的图模型（两个节点只有一条无向路径）
- 树结构中精确推断所需的时间和空间复杂性与网络规模呈线性关系。
- 对于多连通网络（两个节点有多条无向路径），最坏情况下，变量消元仍然有着指数量级的时间复杂性和空间复杂性。
- 贝叶斯网络的精确推断是NP难的



- 概率图模型
- 贝叶斯网络
- 条件分布的高效表达
- 贝叶斯网络中的精确推理
- 贝叶斯网络中的近似推理

13.4 贝叶斯网络近似推理

- 因为大型网络中精确推断的难处理，产生了近似推断方法。
- 随机采样算法，也称为蒙特卡洛（MonteCarlo）算法，它能提供近似的答案，且准确性取决于生成的样本数。
- 原理：
 - 基于贝叶斯网络中的概率**生成随机事件并计数**这些随机事件。
 - 有了足够的样本，可以以任意的精度恢复真实概率分布。
 - 在大多数情况下，生成一个符合证据的样本，要比直接计算符合证据的概率容易的多。


13.4 贝叶斯网络近似推理

■ 蒙特卡洛算法

- 按抽样调查法（采样）求取统计值（计数）来推定未知特性量（随机变量）的计算方法。
- 特别适用于一些解析法难以求解甚至不可能求解的问题

■ 两个算法家族

- **直接采样**
- 马尔科夫链采样



13.4 贝叶斯网络近似推理-直接采样

■ 直接采样法

- 基本要素是根据已知概率分布生成样本。
- 在概率分布上，生成样本方式是随机数生成器。
 - 真实世界的采样：一个无偏差硬币，通过手工抛掷观察处于正面还是反面。
 - 概率分布的采样：一个关于硬币的概率分布 $P(\text{Coin}) = \langle 0.5, 0.5 \rangle$ 。给定一个 $[0, 1]$ 区间上均匀分布的随机数发生器，就可以对单个变量的任何分布进行采样。


13.4 贝叶斯网络近似推理-直接采样

■ 示例：草坪洒水

- 描述玛丽在草坪上的日常工作：每天早上，她会检查天气；如果是阴天，她通常不会打开洒水器；如果洒水器开着，或者那天下雨了，草坪就会湿。

□ 随机变量：

- Cloudy: 阴天
- Sprinkler: 洒水器
- Rain: 下雨
- WetGrass: 草坪打湿



13.4 贝叶斯网络近似推理-直接采样

■ 示例：草坪洒水


- 按照拓扑顺序依次采样每个变量，采样的概率分布取决于已经赋给该变量父结点的值：

- 从 $P(\text{Cloudy}) = \langle 0.5, 0.5 \rangle$ 中采样 Cloudy, 返回true;
- 从 $P(\text{Sprinkler} | \text{Cloudy} = \text{true}) = \langle 0.1, 0.9 \rangle$, 返回false;
- 从 $P(\text{Rain} | \text{Cloudy} = \text{true}) = \langle 0.8, 0.2 \rangle$ 中采样, 返回true;
- 从 $P(\text{WetGrass} | \text{Sprinkler} = \text{false}, \text{Rain} = \text{true}) = \langle 0.9, 0.1 \rangle$ 中采样 WetGrass, 返回true。

- 返回事件[true, false, true, true]

Cloudy: 阴天, Sprinkler: 洒水器

Rain: 下雨, WetGrass: 草坪打湿



13.4 贝叶斯网络近似推理-直接采样

■ 直接采样法的原理

- 令 $S_{ps}(x_1, \dots, x_n)$ 为算法生成的一个特定事件的概率
- 生成该事件的过程中，每个采样步骤只依赖于父节点的值，因此事件 $(x_1, \dots, x_n)$ 发生的概率等价于：

$$S_{ps}(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- 根据贝叶斯网络的性质：

$$S_{ps}(x_1, \dots, x_n) = P(x_1, \dots, x_n)$$

$(x_1, \dots, x_n)$ 发生的概率符合贝叶斯网络完全联合概率分布

13.4 贝叶斯网络近似推理-直接采样

■ 直接采样法的原理

- 理论依据：假设有 N 个直接采样算法产生的样本，令 $N_{ps}(x_1, \dots, x_n)$ 为特定事件 $(x_1, \dots, x_n)$ 在样本集中出现的次数。我们期望**这个数字与总数的比例在极限意义下收敛于真实概率**：

$$\lim_{N \rightarrow \infty} \frac{N_{ps}(x_1, \dots, x_n)}{N} = S_{ps}(x_1, \dots, x_n) = P(x_1, \dots, x_n)$$

- 例如，考虑前面生成的事件：[true, false, true, true]，这个事件的采样概率是

$$S_{ps}(\text{true}, \text{false}, \text{true}, \text{true}) = 0.5 \times 0.9 \times 0.8 \times 0.9 = 0.324$$

在 N 很大的极限下，我们期望32.4%的样本发生这个事件

13.4 贝叶斯网络近似推理-直接采样

■ 直接采样法的原理

- 后续使用约等于 ($\approx$) 表达的是, 使用采样算法估计的概率在大样本极限下变得逐渐精确。这样的估计被称为一致的。
- 使用 $\hat{P}$ (读作 “P-hat”, “P帽”) 表示估计概率
- **部分事件**: 我们可以为任何**被部分指定的事件** $x_1, \dots, x_m$ 产生的概率给出一个估计, 其中 $m \leq n$:

$$P(x_1, \dots, x_m) \approx N_{PS}(x_1, \dots, x_m) / N$$

- 事件的概率可以估计为采样过程所产生的所有完整事件中与部分事件相匹配的比例。
- 举例来说, 如果我们从洒水器网络中生成了1000个样本, 其中511个满足Rain = true, 则估计的下雨概率 $\hat{P}(\text{Rain} = \text{true}) = 0.511$ 。

13.4 贝叶斯网络近似推理-直接采样

■ 计算条件概率：拒绝采样

- 拒绝采样可以用于计算后验概率，也就是确定 $P(X|e)$
- 拒绝采样算法的过程：
 - 首先，它从网络指定的先验概率中生成样本。
 - 然后，它拒绝所有与证据不匹配的样本。
 - 最后，在剩余样本中通过计数 $X = x$ 的频次得到估计

$$\hat{P}(X = x | e)$$

13.4 贝叶斯网络近似推理-直接采样

■ 计算条件概率：拒绝采样

function REJECTION-SAMPLING(X, e, bn, N) **returns** 一个 $P(X|e)$ 的估计

inputs: X , 查询变量

e , 证据 E 的观测值

bn , 一个贝叶斯网络

N , 生成的样本总数

local variables: C , X 每个值的计数向量, 初始为0

for $j = 1$ **to** N **do**

$x \leftarrow \text{PRIOR-SAMPLE}(bn)$

if x 与 e 一致 **then**

$C[j] \leftarrow C[j] + 1$, 其中 x_j 是 X 在 x 中的值

return NORMALIZE(C)

图 13-17 贝叶斯网络中给定证据时回答查询的拒绝采样算法

对应流程：首先，它从网络指定的先验概率中生成样本。然后，它拒绝所有与证据不匹配的样本。最后，通过计数 $X = x$ 在剩余样本中的频次得到估计 $\hat{P}(X = x | e)$

13.4 贝叶斯网络近似推理-直接采样

■ 计算条件概率：拒绝采样

- 理论依据：令 $\hat{P}(X|e)$ 为算法返回的估计分布，根据算法原理：

$$\hat{P}(X|e) = \alpha N_{ps}(X, e) = \frac{N_{ps}(X, e)}{N_{ps}(e)}$$

$N_{ps}(X, e)$ ：当样本与证据一致时，每个X值的样本计数向量。

- 根据 $P(x_1, \dots, x_m) \approx N_{ps}(x_1, \dots, x_m)/N$,


$$\hat{P}(X|e) = \frac{N_{ps}(X, e)}{N_{ps}(e)} \approx \frac{P(X, e)}{P(e)} = P(X|e)$$

拒绝采样给出了后验概率的一个一致估计

13.4 贝叶斯网络近似推理-直接采样

■ 计算条件概率：拒绝采样

- 使用 100 个样本估计 $P(\text{Rain} | \text{Sprinkler} = \text{true})$
- 假设 100 个样本中，由 73 个满足 $\text{Sprinkler} = \text{false}$ ，因此被拒绝；
- 有 27 个满足 $\text{Sprinkler} = \text{true}$ ，这 27 个中的 8 个满足 $\text{Rain} = \text{true}$ ，19 个满足 $\text{Rain} = \text{false}$ 。因此， $P(\text{Rain} | \text{Sprinkler} = \text{true}) \approx \text{Normalize}(\langle 8, 19 \rangle) = \langle 0.296, 0.704 \rangle$



13.4 贝叶斯网络近似推理-直接采样

■ 拒绝采样的缺陷

□ 拒绝了太多的样本

- 拒绝采样的复杂性主要取决于被接受的样本的比例，该比例等于证据的先验概率 $P(e)$ 。对于具有许多证据变量的复杂问题，这一比例极小。
- 随着证据变量数量的增加，与证据 e 相一致的样本在所有样本中所占的比例呈指数级下降，对于复杂问题不能使用这种方法。
- 汽车保险问题中的典型证据，接受率在 $1/1000$ 到 $1/10000$ 之间。

□ 解决思路：从一个简单的分布中采样并进行必要的修正

13.4 贝叶斯网络近似推理-直接采样

■ 计算条件概率：重要性采样

- **重要性采样**(importance sampling)使用另一个采样于分布 Q 的样本来模拟从分布 P 中采样的结果，并通过在计数每个样本时使用修正因子 $P(x)/Q(x)$ ，也称作**权重**，来确保答案在极限下是正确的。（ $Q(x)$ 容易采样， $P(x)/Q(x)$ 容易计算）

$$\hat{P}(z|e) = \frac{N_Q(z)}{N} \frac{P(z|e)}{Q(z)} \approx Q(z) \frac{P(z|e)}{Q(z)} = P(z|e)$$

权重补偿了由于 $Q(x)$ 和 $P(x)$ 不同导致的过采样或欠采样

例如：如果对于一些 x ， $Q(x)$ 远大于 $P(x|e)$ ，那么这些 x 的样本数量就会比应有数量多得多，但是每个样本的权重很小，所以结果和正确的样本数量情况一样

13.4 贝叶斯网络近似推理-直接采样

■ 基于似然加权的重要性采样

function LIKELIHOOD-WEIGHTING(X, e, bn, N) **returns** 一个 $P(X | e)$ 的估计

inputs: X , 查询变量

e , 变量 E 的观测值

bn , 一个指定联合分布 $P(X_1, \dots, X_n)$ 的贝叶斯网络

N , 生成的样本总数

local variables: W , 一个 X 每个值的加权计数向量, 初始为0

for $j = 1$ **to** N **do**

$x, w \leftarrow \text{WEIGHTED-SAMPLE}(bn, e)$

$W[j] \leftarrow W[j] + w$ 其中 x_j 是 X 在 x 中的值

return $\text{NORMALIZE}(W)$

遍历所有变量, 遇到证据变量计算权重, 遇到非证据变量采样。

拒绝采样

对比

$C[j] \leftarrow C[j] + 1$, 其中 x_j 是 X 在 x 中的值

function WEIGHTED-SAMPLE(bn, e) **returns** 一个事件与一个权重

$w \leftarrow 1$; $x \leftarrow$ 一个具有 n 个元素的事件, 含有来自 e 的固定值

for $i = 1$ **to** n **do**

if X_i 是一个值 x_{ij} 来自 e 的证据变量

then $w \leftarrow w \times P(X_i = x_{ij} | \text{parents}(X_i))$

else $x[i] \leftarrow P(X_i | \text{parents}(X_i))$ 中的一个随机样本

return x, w

证据变量值直接给定, 其他变量待定

遇到证据变量计算权重

遇到非证据变量正常采样

图 13-18 贝叶斯网络推断中的似然加权算法。在 WEIGHTED-SAMPLE 中, 每个非证据变量根据给定的已采样父变量值的条件分布进行采样, 权重根据每个证据变量的似然进行累积

13.4 贝叶斯网络近似推理-直接采样

■ 基于似然加权的重要性采样

function LIKELIHOOD-WEIGHTING(X, e, bn, N) **returns** 一个 $P(X | e)$ 的估计

inputs: X , 查询变量

e , 变量 E 的观测值

bn , 一个指定联合分布 $P(X_1, \dots, X_n)$ 的贝叶斯网络

N , 生成的样本总数

local variables: W , 一个 X 每个值的加权计数向量, 初始为 0

for $j = 1$ **to** N **do**

$x, w \leftarrow \text{WEIGHTED-SAMPLE}(bn, e)$

$W[j] \leftarrow W[j] + w$ 其中 x_j 是 X 在 x 中的值

return $\text{NORMALIZE}(W)$

function WEIGHTED-SAMPLE(bn, e) **returns** 一个事件与一个权重

$w \leftarrow 1; x \leftarrow$ 一个具有 n 个元素的事件, 含有来自 e 的固定值

for $i = 1$ **to** n **do**

if X_i 是一个值 x_{ij} 来自 e 的证据变量

then $w \leftarrow w \times P(X_i = x_{ij} | \text{parents}(X_i))$

else $x[i] \leftarrow P(X_i | \text{parents}(X_i))$ 中的一个随机样本

return x, w

两个行为:

- 每个非证据变量: 根据已采样的父变量的值的条件分布进行采样
- 每个证据变量: 根据每个证据变量的发生的概率计算权重并累计

权重定义: 该证据变量的值发生的概率 (似然)

似然: 证据发生的概率

图 13-18 贝叶斯网络推断中的似然加权算法。在 WEIGHTED-SAMPLE 中, 每个非证据变量根据给定的已采样父变量值的条件分布进行采样, 权重根据每个证据变量的似然进行累积

13.4 贝叶斯网络近似推理-直接采样

■ 似然权重的原理

- 记上述算法产生的采样分布为 Q_{ws} 。如果非证据变量是 $Z = \{Z_1, \dots, Z_l\}$ ，则有

$$Q_{ws}(z) = \prod_{i=1}^l P(z_i | \text{parents}(Z_i))$$

只对非证据变量 z 进行采样，对应 z 的条件概率的累计


- 根据重要性采样思想，其权重应为

$$\begin{aligned} w(z) &= \frac{P(z|e)}{Q_{ws}(z)} = \frac{\alpha P(z, e)}{Q_{ws}(z)} = \alpha \frac{\prod_{i=1}^l P(z_i | \text{parents}(Z_i)) \prod_{i=1}^m P(e_i | \text{parents}(E_i))}{\prod_{i=1}^l P(z_i | \text{parents}(Z_i))} \\ &= \alpha \prod_{i=1}^m P(e_i | \text{parents}(E_i)) \end{aligned}$$

权重是证据变量在给定其父变量之后的条件概率的乘积（证据的概率通常被称为**似然**，故称为**似然加权**）

13.4 贝叶斯网络近似推理-直接采样


■ 例子



13.4 贝叶斯网络近似推理-直接采样

■ 例子

- 查询 $P(Rain|Cloudy = true, WetGrass = true)$
- 拓扑次序是Cloudy, Sprinkler, Rain, WetGrass
- 算法过程如下：生成一个事件并计算权重，w初始化为1：
 1. Cloudy是值为true的证据变量。因此，我们设置 $w \leftarrow w \times P(Cloudy = true) = 0.5$ 。
 2. Sprinkler不是证据变量，所以从 $P(Sprinkler|Cloudy = true) = \langle 0.1, 0.9 \rangle$ 中采样，假设返回了false。
 3. Rain不是证据变量，所以从 $P(Rain|Cloudy = true) = \langle 0.8, 0.2 \rangle$ 中采样，假设返回了true。
 4. WetGrass 是 值 为 true 的 证 据 变 量 。 因 此 ， 我 们 设 置 $w \leftarrow w \times P(WetGrass = true|Sprinkler = false, Rain = true) = 0.5 \times 0.9 = 0.45$ 。
- 由此，算法返回了权重为0.45的事件[true, false, true, true]，被计入Rain=true下



13.4 贝叶斯网络近似推理-直接采样

■ 直接采样vs.似然加权




图 13-19 保险网络中拒绝采样与似然加权的表现。 x 轴表示生成的样本数量， y 轴表示对 *PropertyCost* 查询的任一概率值的最大绝对误差

13.4 贝叶斯网络近似推理-直接采样

■ 似然加权算法

□ 优点：

- 似然加权使用了所有的生成样本，比拒绝采样更高效。

□ 缺点：

- 随着证据变量数量的增加，它的性能会下降。大多数样本的权重都很低。
- 加权估计将由赋予证据大于无穷小的可能性的极小部分样本所主导。


13.4 贝叶斯网络近似推理

■ 蒙特卡洛算法

- 按抽样调查法（采样）求取统计值（计数）来推定未知特性量（随机变量）的计算方法。
- 特别适用于一些解析法难以求解甚至不可能求解的问题

■ 两个算法家族

- 直接采样
- **马尔科夫链采样**



13.4 贝叶斯网络近似推理-MCMC


■ 通过马尔可夫链模拟进行推理

- **马尔可夫链蒙特卡洛**(Markov chain Monte Carlo, MCMC)算法：
不再从头生成每个样本，**而是通过对前一个样本进行随机改变而生成新样本。**
- 可以将MCMC算法想象成：样本处于特定的当前状态，该状态为每个变量指定一个值，并通过对当前状态进行随机修改来生成下一状态。
- **吉布斯采样**（Gibbs Sampling）：一种特殊形式的MCMC算法，称为Gibbs采样，特别适合贝叶斯网络。

13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

- 从任意的一个状态（将证据变量固定为它的观察值）出发，通过对一个非证据变量 x_i 随机采样一个值来生成下一个状态。对 x_i 的采样条件依赖于 x_i 的马尔科夫毯中的变量的当前值。
- 该算法在状态空间（可能的完整赋值的空间）中游走，每次调整一个变量，并保持证据变量不变。




马尔可夫毯：变量的父结点、子结点和子结点的父结点

给定它的马尔可夫毯（浅紫色区域），节点X 条件独立于网络中的所有其他节点

13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

□ $P(\text{Rain}|\text{Sprinkler}=\text{true}, \text{WetGrass}=\text{true})$



1. 非证据变量 Cloudy 和 Rain 分别随机初始化为 true 和 false, 初始状态为 $[C=\text{true}, S=\text{true}, R=\text{false}, W=\text{true}]$ (样本1)
2. 给定马尔可夫毯当前的值, 对Cloudy采样
 - 从 $P(\text{Cloudy}|\text{Sprinkler}=\text{true}, \text{Rain}=\text{false})$ 采样。假设采样结果为 $\text{Cloudy}=\text{false}$, 则新的状态是 $[C=\text{false}, S=\text{true}, R=\text{false}, W=\text{true}]$ (样本2)
3. 给定马尔可夫毯当前的值, 对Rain采样
 - 从 $P(\text{Rain}|\text{Cloudy}=\text{false}, \text{Sprinkler}=\text{true}, \text{WetGrass}=\text{true})$ 中采样。假设采样结果为 $\text{Rain}=\text{true}$, 则新状态是 $[C=\text{false}, S=\text{true}, R=\text{true}, W=\text{true}]$ (样本3)

13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

- 计算马尔可夫毯分布 $P(X_i | mb(X_i))$, 其中表示 X_i 的马尔可夫毯变量 $mb(X_i)$ 的值。

$$P(x_i | mb(X_i)) = \alpha P(x_i | parents(X_i)) \prod_{Y_j \in Children(X_i)} P(y_j | parents(Y_j))$$

证明:
$$\begin{aligned} P(x_i | mb(X_i)) &= P(x_i | parents(X_i), Y, Z) = \alpha(x_i, parents(X_i), Y, Z) \\ &= \alpha P(Y | x_i, parents(X_i), Z) P(x_i | parents(X_i), Z) \\ &= \alpha P(Y | x_i, Z) P(x_i | parents(X_i)) \end{aligned}$$

Y : X_i 的子节点 Z : Y 的父节点

13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

- 计算马尔可夫毯分布 $P(X_i | mb(X_i))$, 其中表示 X_i 的马尔可夫毯变量 $mb(X_i)$ 的值。


$$P(x_i | mb(X_i)) = \alpha P(x_i | parents(X_i)) \prod_{Y_j \in Children(X_i)} P(y_j | parents(Y_j))$$

- 从 $P(\text{Cloudy} | \text{Sprinkler} = \text{true}, \text{Rain} = \text{false})$ 中采样:

$$P(c | s, \neg r) = \alpha P(c)P(s | c)P(\neg r | c) = \alpha \times 0.5 \times 0.1 \times 0.2$$

$$P(\neg c | s, \neg r) = \alpha P(\neg c)P(s | \neg c)P(\neg r | \neg c) = \alpha \times 0.5 \times 0.5 \times 0.8$$

- 采样分布为: $\alpha \langle 0.001, 0.020 \rangle \approx \langle 0.048, 0.952 \rangle$



13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

- 这个过程中所访问的每一个状态都是一个样本，能对查询变量 Rain 的估计做贡献。如果该过程访问了 20 个 Rain 为真的状态和 60 个 Rain 为假的状态，则所求查询的解为：

$$NORMALIZE(< 20, 60 >) = < 0.25, 0.75 >$$

13.4 贝叶斯网络近似推理-MCMC

■ 贝叶斯网络中的吉布斯采样

function GIBBS-ASK(X, e, bn, N) **returns** 一个 $P(X|e)$ 的估计
local variables: C , 一个 X 的每个值的计数向量, 初始为0
 Z , bn 中的非证据变量
 x , 网络的当前状态, 从 e 中初始

使用 Z 中变量的随机值初始 x

for $k = 1$ **to** N **do**

 根据任意分布 $\rho(i)$ 从 Z 中选择变量 Z_i

 通过从 $P(Z_i | mb(Z_i))$ 中采样, 设置 x 中 Z_i 的值

$C[j] \leftarrow C[j] + 1$ 其中 x_j 是 X 在 x 中的值

return NORMALIZE(C)

图 13-20 贝叶斯网络近似推断的吉布斯采样算法。这个版本采用了随机选择变量, 此外循环遍历变量也可行

13.4 贝叶斯网络近似推理-MCMC

■ 吉布斯采样 vs. 似然加权




图 13-22 吉布斯采样与似然加权在汽车保险网络上表现的比较。(a) 对 *PropertyCost* 上的标准查询。(b) 输出变量是被观测的并且 *Age* 是查询变量的情况

- 采样更快，采样时仅算一个马可夫毯的条件概率即可
- 证据变量在下游时，优于似然加权
- 证据变量在上游时，有争议

本章小结

- 贝叶斯网络是一个有向无环图，其结点对应于随机变量；每个结点都有一个给定其父结点下的条件概率分布。
- 贝叶斯网络提供了一种表示问题域中的条件独立性关系的简洁方式。
- 贝叶斯网络指定了完全联合概率分布；完全联合概率分布中每个概率为局部条件分布的乘积。
- 构造贝叶斯网络时，网络的紧致性与节点排序非常相关。
- 条件分布使用概率表表达，但满足条件时也存在更高效的表达形式，例如确定性关系，逻辑或关系。
- 涉及连续变量的条件概率分布可以使用离散化、线性高斯分布、软阈值表达。

本章小结

- 贝叶斯网络中的推理意味着给定一个证据变量集合后，计算一个查询变量集合的概率分布。贝叶斯网络的精确推理包含枚举推理和变量消元法。
- 如果概率的解析解非常难以计算，通常会使用马尔科夫采样方法。
- 像似然加权、马尔科夫链蒙特卡洛方法这样的随机近似技术能够提供对网络的真实后验概率的合理估计，并能够比精确算法处理规模大得多的网络。

课程作业

- 袋子里面有3个有偏差的硬币a、b和c，抛掷硬币正面朝上的概率分别是20%、60%和80%。从袋子里随机取出一个硬币（3个硬币被取出的概率是相等的），并把取出的硬币抛掷3次，得到抛掷结果依次是 X_1 ， X_2 和 X_3 。
- a. 画出对应的贝叶斯网络并定义必要的CPT表。
- b. 如果抛掷结果是2次正面朝上，1次反面朝上，计算取出的硬币最可能是哪一个。

THANKS

Q & A