



—— 人工智能原理与算法 ——

第14章- 时间上的概率推理

中科院自动化研究所 朱翔昱

14 时间上的概率推理-概述

- 目标：解读现在，理解过去，预测未来
- 处理时序不确定性：
 - 智能体维护一个**信念状态**，它表示目前哪些世界状态是可能的。
 - 根据信念状态和**转移模型**，智能体可以预测世界在下一个时间步将如何发展。
 - 基于观测感知和**传感器模型**，智能体可以更新信念状态。
- 回顾过往章节的不确定性：
 - 复杂环境的搜索（第4章）：显式枚举信念状态
 - 逻辑智能体（第7章）：逻辑公式

- **时间与不确定性**
- **时序模型中的推理**
- **隐马尔可夫模型**
- **卡尔曼滤波器**
- **动态贝叶斯网络**

14.1 时间与不确定性-问题概述

- **静态世界**下进行概率推理时，每个随机变量都有一个唯一的固定取值
 - 示例1：在修理汽车时，我们总是假设发生故障的部分在整个诊断过程中一直都是故障的
 - 任务：根据已经观察到的证据推断汽车的状态，这个状态也是保持不变的



14.1 时间与不确定性-问题概述


■ 动态情景：

- 治疗一个糖尿病人。有诸如病人**近期**的胰岛素服用剂量、食物摄入量、血糖水平，以及其他一些身体上的征兆等证据。
- 任务：评价病人的当前状态，包括**真实**的血糖水平和胰岛素水平；给定了这些信息，能够对病人的食物摄入量或者胰岛素服用剂量进行决策。
- **不同于**汽车修理问题：这个问题本质是**动态的**，血糖水平及其测量值会随着时间发生迅速的变化，取决于近期的食物摄入量、胰岛素剂量、新陈代谢活动。**需要对这些变化进行建模。**
- 用一个值来衡量这些变量（比如平均值），会损失大量信息。有时候，值本身的大小都不重要的，变化模式才更重要。

14.1 时间与不确定性-状态与观测

■ 本章讨论离散时间模型：

- 将世界看作是一系列快照或**时间片**(time slice)，每个快照或时间片都包含了一组随机变量，其中一部分是可观察的，而另一部分则是不可观察的。
- **状态变量**：符号 X_t 来表示在时刻 t 的不可观察的变量集
- **证据变量**：符号 E_t 表示可观察的证据变量集。时刻 t 的观察结果为 $E_t = e_t$



14.1 时间与不确定性-状态与观测

■ 时序问题的建模：随机变量

- 你是一名地下设施的保安，想知道今天是否下雨，但接触外面世界的唯一途径是每天早上看到主管进来时带不带雨伞。这个问题是动态的，因为前一天下雨（带伞）很可能使得第二天也下雨（带伞），所以建模随机变量随时间变化的趋势很重要。
- 对于每一天 t ，集合 E_t 包含单个证据变量 $Umbrella_t$ 或简称 U_t （雨伞是否出现），集合 X_t 包含单个状态变量 $Rain_t$ 或简称 R_t （是否下雨）
- 状态序列从 $t = 0$ 开始，证据从 $t = 1$ 开始到达
- 状态变量： $R_0, R_1, R_2, \dots$
- 证据变量： $U_1, U_2, \dots$
- $X_{a:b}$: X_a 到 X_b 的变量集合



14.1 时间与不确定性-转移模型与传感器模型


■ 转移模型

- 确定了给定问题的状态变量集合和证据变量集合之后，下一步需要指定世界如何演变 (**转移模型**) 以及证据变量如何获得它们的值 (**传感器模型**)。
- **转移模型**：在给定过去的状态变量的值之后，确定最新状态变量的概率分布 $P(X_t|X_{0:t-1})$
 - 该转移模型会随着时间的推进，导致条件变量 $X_{0:t-1}$ 无限扩张，直到变得无法计算。

14.1 时间与不确定性-转移模型与传感器模型

■ 转移模型

- 马尔可夫假设(Markov assumption): 当前状态只依赖于有限的固定数量的过去状态。比如一阶马尔可夫过程假设其中当前状态只依赖于前一个状态, 而与更早的状态无关:



(a) 一阶马尔可夫过程对应的贝叶斯网络结构 $P(X_t|X_{t-1})$

(b) 一个二阶马尔可夫过程 $P(X_t|X_{t-1}, X_{t-2})$

14.1 时间与不确定性-转移模型与传感器模型

■ 转移模型

- 仍然存在一个问题: t 的可能的值有无穷多个。我们需要为每个时间步 $P(X_t|X_{t-1})$ 指定不同的分布吗?
- 进一步假设世界状态的变化是一个**时间齐次(time-homogeneous)**的过程: 转移模型是一个不随时间变化的过程。
- 例如雨伞世界中, 条件概率 $P(R_t|R_{t-1})$ 对所有 t 都是一样的, 只需要指定一个条件概率表即可。

14.1 时间与不确定性-转移模型与传感器模型

■ 传感器模型:

- 传感器马尔科夫假设：称职的状态 x 应该能生成当前传感器值


$$P(E_t|X_{0:t}, E_{1:t-1}) = P(E_t|X_t)$$

- 证据变量仅依赖于当前时刻的状态变量。
- $P(E_t|X_t)$ 是传感器模型，也称为观测模型

14.1 时间与不确定性-转移模型与传感器模型

■ 传感器模型与观测模型：

- 回到雨伞世界：状态变量 $Rain_t$ 或简称 R_t （是否下雨），证据变量 $Umbrella_t$ 或简称 U_t （雨伞是否出现）



14.1 时间与不确定性-转移模型与传感器模型

■ 时序模型的完全联合概率分布：

- 初始状态：时刻0时的先验概率分布 $P(X_0)$
- 所有变量的**完全联合分布**为：


$$P(X_{0:t}, E_{1:t}) = P(X_0) \prod_{i=1}^t P(X_i | X_{i-1}) P(E_i | X_i)$$



先验



转移模型



传感器模型

14.1 时间与不确定性-转移模型与传感器模型

■ 提高近似的精确程度：

- **提高马尔可夫过程模型的阶数。**例如，我们可以通过为结点 $Rain_t$ ，增加父结点 $Rain_{t-2}$ 构造一个二阶马尔可夫过程，这或许能够提供稍微精确些的预测。例如，某些干旱地方很少连续下两天以上的雨。
- **扩大状态变量集合。**例如，我们可以增加变量 $Season_t$ 以允许我们结合考虑雨季的历史记录，或者我们可以增加时刻 t 的温度、时刻 t 的湿度、时刻 t 的气压以允许我们使用降雨条件的物理模型。

14.1 时间与不确定性-转移模型与传感器模型

■ 提高近似的精确程度：

- 增加阶数总可以被重新表述为保持阶数固定，扩大状态变量集合。
- 扩大状态变量的集合，总是意味着问题难度的上升。
 - ▶ 新的状态变量也需要预测，导致概率模型变得复杂，计算复杂度变高
- 选择合适的变量集依赖于正确地理解问题的“物理”过程。
- **使用更多的传感器是提升精确度的直接有力方法**
 - ▶ 自动驾驶车辆，添加新的雷达可以有效降低难度（但会增加成本）

14.1 时间与不确定性

■ 总结：动态世界下的概率建模

□ 随机变量：

- ▶ 随机变量加上角标 t ，表示随机变量随时间变化
- ▶ 随机变量包括状态变量 X_t 和证据变量 E_t

□ 概率模型：

- ▶ 转移模型： $P(X_t|X_{t-1})$
- ▶ 传感器模型： $P(E_t|X_t)$

□ 完全联合概率分布：

$$P(X_{0:t}, E_{1:t}) = P(X_0) \prod_{i=1}^t P(X_i|X_{i-1})P(E_i|X_i)$$

- 时间与不确定性
- 时序模型中的推理
- 隐马尔可夫模型
- 卡尔曼滤波器
- 动态贝叶斯网络

14.2 时序模型中的推理-基本任务概述

■ 时序模型中的五大推理任务：

滤波

预测

平滑

最可能解释

学习

14.2 时序模型中的推理-基本任务概述

■ 五大基本任务：滤波，预测，平滑，最可能解释，学习

□ **滤波**（状态估计）：给定目前为止的所有证据，计算**当前状态**的后验概率分布 $P(X_t|e_{1:t})$

- ▶ 举例：给定目前为止所有对雨伞的观测值，计算今天下雨的概率
- ▶ 名称源于信号处理中噪声过滤， X_t 是真实信号， $e_{1:t}$ 为噪声信号。
滤波操作基于信号的连续性进行去噪。

14.2 时序模型中的推理-基本任务概述

■ 五大基本任务：滤波，预测，平滑，最可能解释，学习

- 预测：给定目前为止的所有证据，计算**未来状态**的后验分布

$$P(X_{t+k}|e_{1:t}).$$

- ▶ 举例：给定到目前为止对雨伞携带者的所有观测值，计算从现在起 3 天后下雨的概率。

14.2 时序模型中的推理-基本任务概述

■ 五大基本任务：滤波，预测，平滑，最可能解释，学习

- 平滑：给定目前为止的所有证据，计算过去某一个状态的后验概率，

$$P(X_k | e_{1:t}), 0 \leq k < t。$$

- ▶ 举例：给定到目前为止对携带雨伞的所有观测值，计算上周三下雨的概率。
- ▶ 平滑vs.滤波 ($P(X_k | e_{1:t})$ vs. $P(X_k | e_{1:k})$)：对时刻 k 的状态，平滑它包含了更多的证据 ($k+1$ 到 t 时刻的证据)，提供了比当时能得到的估计 (滤波) 更好的估计，(输出比滤波更平滑)

14.2 时序模型中的推理-基本任务概述

■ 五大基本任务：滤波，预测，平滑，最可能解释，学习

- **最可能解释**：给定观察序列，可能希望找到**最可能生成**这些观察结果的状态序列， $\operatorname{argmax}_{X_{1:t}} P(X_{1:t} | e_{1:t})$ 。

- ▶ 举例：如果前三天都出现了雨伞，而在第四天没有出现雨伞，那么最可能的解释就是前三天下雨了，而第四天没有下雨。
- ▶ 应用：在语音识别中，给定一个声音序列找到最有可能的单词序列

14.2 时序模型中的推理-基本任务概述

■ 五大基本任务：滤波，预测，平滑，最可能解释，学习

□ **学习**：如果我们不知道转移模型与传感器模型，那么可以从观测中学习。推断对实际发生的转移以及产生传感器读数的状态进行估计，这些估计可用于**学习模型**。学习过程可以通过**期望最大化**迭代更新算法来实现，也可以由来自给定证据时模型参数的**贝叶斯更新**实现。

- ▶ 极大似然参数学习方法
- ▶ 期望最大化(EM算法)
- ▶ 在贝叶斯网络学习中介绍

14.2 时序模型中的推理-滤波

■ 滤波：

- 定义：给定目前为止的所有证据，计算**当前状态**后验概率分布。
- 基本形式为 $P(X_t|e_{1:t})$ ，每次计算都需要回顾整个证据历史（效率低）。一个有用的滤波算法需要维持一个当前状态估计并进行更新，而不是每次更新时回顾整个感知历史。
- 给定直到时刻 t 的滤波结果，需要根据新的证据 e_{t+1} 来计算时刻 $t + 1$ 的滤波结果。即存在某个函数 f 满足

$$P(X_{t+1}|e_{1:t+1}) = f(e_{t+1}, P(X_t|e_{1:t}))$$

- 这个过程称为递归估计。

14.2 时序模型中的推理-滤波

■ 递归估计

- **第一部分（预测）**：使用到t为止的证据，预测t+1的状态变量
- **第二部分（更新）**：t+1的证据多大程度上支持预测的状态变量

$$\begin{aligned}
 P(X_{t+1} | e_{1:t+1}) &= P(X_{t+1} | e_{1:t}, e_{t+1}) \quad (\text{证据分解}) \\
 &= \alpha P(e_{t+1} | X_{t+1}, e_{1:t}) P(X_{t+1} | e_{1:t}) \quad (\text{给定 } e_{1:t}, \text{使用贝叶斯法则}) \\
 &= \alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{更新}} \underbrace{P(X_{t+1} | e_{1:t})}_{\text{预测}} \quad (\text{根据传感器马尔可夫假设})
 \end{aligned}$$

$$\begin{aligned}
 P(X_{t+1} | e_{1:t+1}) &= \alpha P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t, e_{1:t}) P(x_t | e_{1:t}) \quad (\text{引入 } x_t) \\
 &= \alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{传感器模型}} \sum_{x_t} \underbrace{P(X_{t+1} | x_t)}_{\text{转移模型}} \underbrace{P(x_t | e_{1:t})}_{\text{递归}} \quad (\text{马尔可夫假设})
 \end{aligned}$$

14.2 时序模型中的推理-滤波

■ 递归估计

- **核心滤波公式：**滤波估计是沿着逆时间流传播的“消息”。

$$\begin{aligned}
 \boxed{P(X_{t+1} | e_{1:t+1})} &= \alpha P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t, e_{1:t}) P(x_t | e_{1:t}) \\
 &= \alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{传感器模型}} \sum_{x_t} \underbrace{P(X_{t+1} | x_t)}_{\text{转移模型}} \underbrace{P(x_t | e_{1:t})}_{\text{递归}} \quad (\text{马尔可夫假设})
 \end{aligned}$$

- **从t=0时刻开始，f在每一时刻都计算，沿着序列前向（顺时间流）传播，直到时刻t。**消息在每次转移时进行修正并根据每次新的观测进行更新：


$$f_{1:t+1} = \text{FORWARD}(f_{1:t}, e_{t+1})$$

- 即使无限期地追踪当前状态分布，更新的时间与空间要求也是常数量级。

14.2 时序模型中的推理-滤波

■ 雨伞世界的滤波:

- $P(R_t|u_{1:t})$ when $t=2$, 即计算 $P(R_2|u_{1:2})$
- 第0天, 没有观测, 只能依靠先验信念; 假设由 $P(R_0) = \langle 0.5 \ 0.5 \rangle$ 组成。



14.2 时序模型中的推理-滤波

■ 示例3 雨伞世界

□ **递归公式:**

$$\alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{传感器模型}} \sum_{x_t} \underbrace{P(X_{t+1} | x_t)}_{\text{转移模型}} \underbrace{P(x_t | e_{1:t})}_{\text{递归}}$$

□ 第0天, 没有观测; 假设由 $P(R_0) = \langle 0.5, 0.5 \rangle$ 组成。

□ 第1天, 雨伞出现, 所以 $U_1 = \text{true}$ 。从 $t=0$ 到 $t=1$ 的**预测步骤**:

$$P(R_1) = \sum_{r_0} P(R_1 | r_0) P(r_0) = \langle 0.7, 0.3 \rangle \times 0.5 + \langle 0.3, 0.7 \rangle \times 0.5 = \langle 0.5, 0.5 \rangle$$

□ **更新步骤:** 乘以 $t=1$ 时的证据概率并归一化 ,

$$P(R_1 | u_1) = \alpha P(u_1 | R_1) P(R_1) = \alpha \langle 0.9, 0.2 \rangle \langle 0.5, 0.5 \rangle = \alpha \langle 0.45, 0.1 \rangle \approx \langle 0.818, 0.182 \rangle$$

14.2 时序模型中的推理-滤波

■ 示例3 雨伞世界

□ **递归公式:**
$$\alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{传感器模型}} \sum_{x_t} \underbrace{P(X_{t+1} | x_t)}_{\text{转移模型}} \underbrace{P(x_t | e_{1:t})}_{\text{递归}}$$

□ **第2天:** 雨伞出现, 所以 $U_2 = \text{true}$ 。从 $t = 1$ 到 $t = 2$ 的**预测步骤**:

$$P(R_2 | u_1) = \sum_{r_1} P(R_2 | r_1) P(r_1 | u_1) = \langle 0.7, 0.3 \rangle \times 0.818 +$$

$$\langle 0.3, 0.7 \rangle \times 0.182 \approx \langle 0.627, 0.373 \rangle$$

□ **更新步骤:** 使用 $t = 2$ 时的证据更新它, 得到

$$\begin{aligned} P(R_2 | u_1, u_2) &= \alpha P(u_2 | R_2) P(R_2 | u_1) = \alpha \langle 0.9, 0.2 \rangle \langle 0.627, 0.373 \rangle \\ &= \alpha \langle 0.565, 0.075 \rangle \approx \langle 0.883, 0.117 \rangle \end{aligned}$$

□ 由于下雨的持续性, 即使证据变量是相同的, 下雨的概率也变高了。

$$\langle 0.818, 0.182 \rangle \text{ vs. } \langle 0.883, 0.117 \rangle$$

14.2 时序模型中的推理-预测

■ 预测

- 定义：给定目前为止的所有证据，计算**未来状态**的后验分布

$$P(X_{t+k}|e_{1:t}).$$

- **预测** $P(X_{t+k}|e_{1:t})$ **vs. 滤波** $P(X_t|e_{1:t})$ ：预测的任务可以被简单地认为是没有增加新证据条件下的滤波，滤波过程已经包含了一个单步预测。

滤波公式

$$\begin{aligned}
 P(X_{t+1} | e_{1:t+1}) &= P(X_{t+1} | e_{1:t}, e_{t+1}) \quad (\text{证据分解}) \\
 &= \alpha P(e_{t+1} | X_{t+1}, e_{1:t}) P(X_{t+1} | e_{1:t}) \quad (\text{给定 } e_{1:t}, \text{使用贝叶斯法则}) \\
 &= \alpha \underbrace{P(e_{t+1} | X_{t+1})}_{\text{更新}} \underbrace{P(X_{t+1} | e_{1:t})}_{\text{预测}} \quad (\text{根据传感器马尔可夫假设})
 \end{aligned}$$

滤波过程已经包含了一个单步预测

14.2 时序模型中的推理-预测

■ 预测

- 预测公式：希望 $t+k+1$ 时刻的预测是基于 $t+k$ 时刻的预测

$$\begin{aligned}
 \boxed{P(X_{t+k+1}|e_{1:t})} &= \sum_{x_{t+k}} P(X_{t+k+1}, x_{t+k}|e_{1:t}) \\
 &= \sum_{x_{t+k}} P(X_{t+k+1}|x_{t+k}, e_{1:t})P(x_{t+k}|e_{1:t}) \quad (\text{乘积法则}) \\
 &= \sum_{x_{t+k}} \underbrace{P(X_{t+k+1}|x_{t+k})}_{\text{转移模型}} \underbrace{\boxed{P(x_{t+k}|e_{1:t})}}_{\text{递归}}
 \end{aligned}$$

- 在计算时，不断递归，直到 $k=0$ 时，递归部分变为： $P(x_t|e_{1:t})$
- 此时变成了滤波公式，使用滤波公式计算即可

14.2 时序模型中的推理-预测

■ 预测

□ 预测公式：

$$P(X_{t+k+1}|e_{1:t}) = \sum_{x_{t+k}} \underbrace{P(X_{t+k+1}|x_{t+k})}_{\text{转移模型}} \underbrace{P(x_{t+k}|e_{1:t})}_{\text{递归}}$$

- 这个公式只涉及转移模型，而不涉及传感器模型。**因此不需要新的证据，可以无限向未来推导。**
- 当预测无限遥远的未来时，下雨的预测分布将收敛到不动点 $\langle 0.5, 0.5 \rangle$ ，这就是马尔科夫过程的平稳分布。
- 转移模型不确定性越大，对未来的了解就越模糊。

14.2 时序模型中的推理-预测

■ 前向递归的其他应用：证据的似然

- 可以使用前向递归来计算证据序列的似然 $P(e_{1:t})$
- 在选择模型时有用，如果有多个可能的模型（转移模型和传感器模型），选择似然最高的模型。
- 定义似然消息 $l_{1:t}(X_t) = P(X_t, e_{1:t})$ ，这个计算**与滤波运算相同**

$$l_{1:t+1} = FORWARD(l_{1:t}, e_{t+1})$$

- 计算得到 $l_{1:t}$ 后，可以通过求和消元消去 X_t 得到实际的似然

$$L_{1:t} = P(e_{1:t}) = \sum_{x_i} l_{1:t}(x_i)$$

14.2 时序模型中的推理-预测

■ 采用似然消息 $l_{1:t}(X_t) = P(X_t, e_{1:t})$

$$l_{1:t+1}(X_{t+1}) = \boxed{P(X_{t+1}, e_{1:t+1})} = P(X_{t+1}, e_{1:t}, e_{t+1})$$

$$= P(e_{t+1} | X_{t+1}, e_{1:t}) P(X_{t+1}, e_{1:t}) \quad (\text{乘积法则})$$

$$= P(e_{t+1} | X_{t+1}) P(X_{t+1}, e_{1:t}) \quad (\text{传感器模型})$$

$$= P(e_{t+1} | X_{t+1}) P(X_{t+1} | e_{1:t}) P(e_{1:t}) \quad (\text{乘积法则})$$

$$= P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | e_{1:t}, x_t) P(x_t | e_{1:t}) P(e_{1:t}) \quad (\text{引入 } x_t)$$

$$= P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t) \boxed{P(X_t, e_{1:t})} \quad (\text{转移模型})$$


$$= P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t) l_{1:t}$$

传感器模型
转移模型
递归

14.2 时序模型中的推理-平滑

■ 平滑

- 定义：平滑是给定直到现在的已知证据，来计算过去的状态分布的过程；也就是，对于 $0 \leq k < t$ 计算 $P(X_k|e_{1:t})$




平滑计算 $P(X_k|e_{1:t})$ ，给定从时刻 1 到时刻 t 的完整观测序列，计算过去某时刻 k 的状态的后验分布

14.2 时序模型中的推理-平滑

■ 平滑

□ 平滑公式的推导:

$$\begin{aligned}
 P(X_k | e_{1:t}) &= P(X_k | e_{1:k}, e_{k+1:t}) \quad (\text{到}k\text{为止的证据, } k+1\text{到}t\text{的证据}) \\
 &= \alpha P(X_k | e_{1:k}) P(e_{k+1:t} | X_k, e_{1:k}) \quad (\text{给定}e_{1:k}, \text{使用贝叶斯法则}) \\
 &= \alpha P(X_k | e_{1:k}) P(e_{k+1:t} | X_k) \quad (\text{使用条件独立性})
 \end{aligned}$$



$k+1$ 之后的证据只依赖于 $k+1$ 之后的状态变量，而 $k+1$ 之后的状态变量只依赖于 X_k ，因此在给定 X_k 的条件下， $k+1$ 之后的证据与之前的证据条件独立。

14.2 时序模型中的推理-平滑

■ 平滑

□ 平滑公式的推导:

$$P(X_k | e_{1:t}) = P(X_k | e_{1:k}, e_{k+1:t}) \quad (\text{到}k\text{为止的证据, } k+1\text{到}t\text{的证据})$$

$$= \alpha P(X_k | e_{1:k}) P(e_{k+1:t} | X_k, e_{1:k}) \quad (\text{给定}e_{1:k}, \text{使用贝叶斯法则})$$

$$\stackrel{\text{滤波}}{=} \alpha \boxed{P(X_k | e_{1:k})} \boxed{P(e_{k+1:t} | X_k)} \quad (\text{使用条件独立性})$$

$$= \alpha f_{1:k} \times b_{k+1:t} \quad \text{后向消息}$$

- 前向消息 $f_{1:k}$ 可以通过从时刻1到时刻k的后向递归来计算
- 后向消息 $b_{k+1:t}$ 可以通过从时刻t到时刻k的前向递归过程来计算。
- “ $\times$ ”是逐点乘积, 代表条件概率表格的逐点乘积

14.2 时序模型中的推理-平滑

■ 平滑：后向消息 $b_{k+1:t}$ 的计算


$$\begin{aligned}
 \boxed{P(e_{k+1:t}|X_k)} &= \sum_{x_{k+1}} P(e_{k+1:t}|X_k, x_{k+1})P(x_{k+1}|X_k) && \text{(引入 } x_{k+1} \text{ 并条件化)} \\
 &= \sum_{x_{k+1}} P(e_{k+1:t}|x_{k+1})P(x_{k+1}|X_k) && \text{(根据条件独立性)} \\
 &= \sum_{x_{k+1}} P(e_{k+1}, e_{k+2:t}|x_{k+1})P(x_{k+1}|X_k) \\
 &= \sum_{x_{k+1}} \underbrace{P(e_{k+1}|x_{k+1})}_{\text{传感器模型}} \underbrace{\boxed{P(e_{k+2:t}|x_{k+1})}}_{\text{递归}} \underbrace{P(x_{k+1}|X_k)}_{\text{转移模型}}
 \end{aligned}$$

$$b_{k+1:t} = \text{BACKWARD}(b_{k+2:t}, e_{k+1}) \quad f_{1:t+1} = \text{FORWARD}(f_{1:t}, e_{t+1})$$

14.2 时序模型中的推理-平滑

■ 平滑:

- $P(X_k|e_{1:t}) = P(X_k|e_{1:k}, e_{k+1:t}) = \alpha P(X_k|e_{1:k})P(e_{k+1:t}|X_k, e_{1:k}) = \alpha P(X_k|e_{1:k})P(e_{k+1:t}|X_k) = \alpha f_{1:k} \times b_{k+1:t}$
- $f_{1:k}$ 使用滤波前向传播, 从时刻0向前运行到 k
- $b_{k+1:t}$ 使用后向传播, 从时刻 t 向后运行到 $k + 1$
- 后向阶段的初始化($k=t$), 采用 $b_{t+1:t} = P(e_{t+1:t}|X_t) = P(\cdot|X_t) = 1$, 1 是由1组成的向量。空序列观测到的概率为1



14.2 时序模型中的推理-平滑

■ 示例：雨伞世界

- 给定第一天和第二天的雨伞观测，计算 $k = 1$ 时下雨概率的平滑估计

$$P(R_1|u_1, u_2) = \alpha P(R_1|u_1)P(u_2|R_1)$$

- 第一项前向滤波，已经得到 $\langle 0.818, 0.182 \rangle$

- 第二项应用后向消息： $\sum_{x_{k+1}} P(e_{k+1}|x_{k+1})P(e_{k+2:t}|x_{k+1})P(x_{k+1}|X_k)$

$$P(u_2|R_1) = \sum_{r_2} P(u_2|r_2)P(\quad|r_2)P(r_2|R_1) = \langle 0.69, 0.117 \rangle$$

- 第一天下雨概率的平滑估计是

$$P(R_1|u_1, u_2) = \alpha \langle 0.818, 0.182 \rangle \times \langle 0.69, 0.41 \rangle \approx \langle 0.883, 0.117 \rangle$$

- 下雨的平滑估计(0.883)要高于滤波估计(0.818)，因为第二天带伞使得第二天大概率下雨，从而第一天下雨概率更大

14.2 时序模型中的推理-平滑

■ 平滑的计算复杂度

□ 前向递归和后向递归方法

- 对一个特定时间步 k 进行平滑: $O(t)$
- 对每个要平滑的时间步运行一次完整的平滑过程: $O(t^2)$

□ 动态规划方法

- 将前向递归和后向递归在每个时间点的结果存储复用
- 前向-后向算法: $O(t)$

14.2 时序模型中的推理-平滑

■ 前向-后向算法

function FORWARD-BACKWARD(*ev*, *prior*) **returns** 一个概率分布的向量

inputs: *ev*, 时间步1, ..., *t*的证据值的向量

prior, 初始状态的先验分布 $P(X_0)$

local variables: *fv*, 时间步0, ..., *t*的前向消息的向量

b, 后向消息的表示, 初始化全为1

sv, 时间步0, ..., *t*的平滑估计的向量

fv[0] $\leftarrow$ *prior*

for *i* = 1 **to** *t* **do**

fv[*i*] $\leftarrow$ FORWARD(*fv*[*i* - 1], *ev*[*i*])

for *i* = *t* **down to** 1 **do**

sv[*i*] $\leftarrow$ NORMALIZE(*fv*[*i*] $\times$ *b*)

b $\leftarrow$ BACKWARD(*b*, *ev*[*i*])

return *sv*

从前到后, 依次计算前向消息

从后到前, 依次计算后向消息,
并输出平滑结果

□ 缺点:

- 当状态空间规模庞大而序列很长时, 算法的空间复杂度可能会过高
- 不适合在线平滑: 算法必须在新证据不断地追加到序列末尾的同时, 为以前的时间片计算平滑估计

14.2 时序模型中的推理-寻找最可能序列

- **寻找最可能序列：** 给定观察序列，可能希望找到**最可能生成**这些

观察结果的状态序列， $\operatorname{argmax}_{X_{1:t}} P(X_{1:t} | e_{1:t})$ 。

- **示例：雨伞世界**

- 假设 $[true, true, false, true, true]$ 是警卫观察到的前5天的雨伞序列。解释这个序列的最可能的天气序列是什么？
- 第3天没有出现雨伞是否意味着这天没有下雨还是主管忘记了带伞？
- 如果第3天没有下雨，也许第4天也没有下雨，而主管第4天带了雨伞只是为了以防万一。
- 可选择的天气序列总共有 2^5 个。是否有方法能找到最可能的序列而不用把所有序列枚举出来呢？

14.2 时序模型中的推理-寻找最可能序列

■ 示例3 雨伞世界


- 一个直观方法：使用平滑 $P(X_k|e_{1:t})$ 找到天气在每个时间步上的后验分布。然后构造序列，在每一步中根据后验分布找出最可能的天气。



- **不可行。**通过平滑得到的是单个时间步上的后验分布，我们需要的是所有时间步上的联合概率分布。与单个时间步的结果可能完全不同。

$$\operatorname{argmax}_{X_{1:t}} \prod_{k=1}^t P(X_k|e_{1:t}) \quad \text{vs.} \quad \operatorname{argmax}_{X_{1:t}} P(X_{1:t}|e_{1:t})$$


14.2 时序模型中的推理-寻找最可能序列



■ 问题建模

- **路径表示状态**：构建一个图（graph），其结点是每个时间步可能的状态。把下雨的序列看作图中的一条路径。
- 任一路径的可能性是**沿着路径的转移概率**和每个状态下**观察到给定观测值的概率**的乘积：
 - 一条路径本身发生的概率，其状态转移要符合状态转移模型。
 - 一条路径与证据的契合度。

14.2 时序模型中的推理-寻找最可能序列




例1：雨伞世界鼓励天气维持，转移1次，概率较高

■ 问题建模

- **路径表示状态**：构建一个图（graph），其结点是每个时间步可能的状态。把下雨的序列看作图中的一条路径。
- 任一路径的可能性是**沿着路径的转移概率**和每个状态下**观察到给定观测值的概率**的乘积：
 - 一条路径本身发生的概率，其状态转移要符合状态转移模型。
 - 一条路径与证据的契合度。

14.2 时序模型中的推理-寻找最可能序列




例2：雨伞世界鼓励天气维持，每次都转移，概率较低

■ 问题建模

- **路径表示状态**：构建一个图（graph），其结点是每个时间步可能的状态。把下雨的序列看作图中的一条路径。
- 任一路径的可能性是**沿着路径的转移概率**和每个状态下**观察到给定观测值的概率**的乘积：
 - 一条路径本身发生的概率，其状态转移要符合状态转移模型。
 - 一条路径与证据的契合度。

14.2 时序模型中的推理-寻找最可能序列



■ 问题建模

- 马尔科夫性：到达 $t+1$ 时刻每个状态的最优路径与到达 t 时刻每个状态的最优路径之间存在递归关系。
- 例如在时刻5，结束于 $Rain_5 = \text{true}$ 的最优路径，只有两种情况：
 - 到达时刻4且 $Rain_4 = \text{True}$ 的最优路径，加上下一时刻保持下雨的路径
 - 到达时刻4且 $Rain_4 = \text{False}$ 的最优路径，加上下一时刻转换为 $Rain_5 = \text{True}$ 的路径。

应该是一个前向递归！

14.2 时序模型中的推理-寻找最可能序列

■ 计算最可能路径

□ 定义消息 $m_{1:t+1} = \max_{x_{1:t}} P(x_{1:t}, X_{t+1}, e_{1:t+1})$ 等价于 $\max_{x_{1:t}} P(x_{1:t}, X_{t+1} | e_{1:t+1})$

$$\begin{aligned}
 m_{1:t+1} &= \max_{x_{1:t}} P(x_{1:t}, X_{t+1}, e_{1:t+1}) \\
 &= \max_{x_{1:t}} P(x_{1:t}, X_{t+1}, e_{1:t}, e_{t+1}) \\
 &= \max_{x_{1:t}} P(e_{t+1} | x_{1:t}, X_{t+1}, e_{1:t}) P(x_{1:t}, X_{t+1}, e_{1:t}) \\
 &= P(e_{t+1} | X_{t+1}) \max_{x_{1:t}} P(X_{t+1} | x_t) P(x_{1:t}, e_{1:t}) \text{ (乘积法则和独立性)} \\
 &= P(e_{t+1} | X_{t+1}) \max_{x_{1:t}} P(X_{t+1} | x_t) P(x_{1:t-1}, x_t, e_{1:t}) \\
 &= P(e_{t+1} | X_{t+1}) \max_{x_t} \max_{x_{1:t-1}} P(X_{t+1} | x_t) P(x_{1:t-1}, x_t, e_{1:t}) \\
 &= P(e_{t+1} | X_{t+1}) \max_{x_t} P(X_{t+1} | x_t) \max_{x_{1:t-1}} P(x_{1:t-1}, x_t, e_{1:t})
 \end{aligned}$$

14.2 时序模型中的推理-寻找最可能序列

■ 计算最可能路径

□ 定义消息 $m_{1:t+1} = \max_{x_{1:t}} P(x_{1:t}, X_{t+1}, e_{1:t+1})$

$$m_{1:t+1} = \max_{x_{1:t}} P(x_{1:t}, X_{t+1}, e_{1:t+1}) =$$

$$= P(e_{t+1} | X_{t+1}) \max_{x_t} P(X_{t+1} | x_t) \max_{x_{1:t-1}} P(x_{1:t-1}, x_t, e_{1:t})$$

符合证据的程度

最可能的转移形式

上一时刻的最优路径

14.2 时序模型中的推理-寻找最可能序列

■ 计算最可能路径

□ 对比滤波公式（前向消息）：


$$\text{滤波: } f_{1:t+1} = \alpha P(e_{t+1}|X_{t+1}) \sum_{x_t} P(X_{t+1}|X_t) f_{1:t}$$

$$\text{最大: } m_{1:t+1} = P(e_{t+1}|X_{t+1}) \max_{x_t} P(X_{t+1}|x_t) m_{1:t}$$

- 求和变成求最大值
- 没有归一化常数 α
- 计算最可能序列的算法类似于滤波：它从时刻0以先验 $m_{1:0} = P(X_0)$ 开始，沿着序列前向运行，在每个时间步计算消息 m

14.2 时序模型中的推理-寻找最可能序列

- 计算最可能路径 $m_{1:t+1} = P(e_{t+1}|X_{t+1}) \max_{x_t} P(X_{t+1}|x_t)m_{1:t}$




- 雨伞观测序列 $[true, true, false, true, true]$ 的操作，其中证据从时刻1开始。每个 t 展示了消息 $m_{1:t}$ 的值，给出在时刻 t 到达每个状态的最佳序列的概率。
- 同时，对于每个状态，指向它的粗箭头**记录**它的最佳的前驱状态，其中“最佳”由前一个序列概率和转移概率的乘积来度量。沿着粗箭头从 $m_{1:5}$ 中最可能状态向后回溯，给出了最可能序列，如粗外框和较深阴影所示。

- 时间与不确定性
- 时序模型中的推理
- 隐马尔可夫模型（离散变量）
- 卡尔曼滤波器（连续变量）
- 动态贝叶斯网络

14.3 隐马尔可夫模型-概述

■ 隐马尔可夫模型 (Hidden Markov Model, HMM)

- 隐马尔可夫模型：用单个离散随机变量描述状态的时序概率模型，其过程状态由**单个离散**随机变量描述。
- 雨伞预测模型，只有一个状态变量： $Rain_t$



- 如果模型有两个或多个状态变量
 - ▶ 多个变量组合为单个“大变量”，他的值是每个状态变量的值组成的元组。(两个布尔变量，等于一个4个值的大变量)

14.3 隐马尔可夫模型-简化矩阵算法

■ 简化矩阵算法

- 隐马尔科夫的简单形式允许所有基础算法通过简单的矩阵实现，包括转移模型、传感器模型，前向消息和后向消息。
- 用整数 $1, \dots, S$ 表示状态变量的可能值，其中 S 是可能状态的数量。
- 转移模型: $P(X_t|X_{t-1})$ 变成了一个 $S \times S$ 的转移矩阵 T ，其中：

$$T_{ij} = P(X_t = j | X_{t-1} = i)$$

- ▶ 例：如果为状态 $Rain = true$ 和 $Rain = false$ 分别编号1和2，则雨伞世界的转移矩阵是

$$T = P(X_t|X_{t-1}) = \begin{pmatrix} 0.7 & 0.3 \\ 0.3 & 0.7 \end{pmatrix}$$

$$T = \begin{pmatrix} \text{下雨} \rightarrow \text{下雨}, & \text{下雨} \rightarrow \text{不下雨} \\ \text{不下雨} \rightarrow \text{下雨}, & \text{不下雨} \rightarrow \text{不下雨} \end{pmatrix}$$

14.3 隐马尔可夫模型-简化矩阵算法

■ 简化矩阵算法

- **传感器模型**：证据变量 E_t 的值在时刻 t 已经得知(e_t)，只需要指定每个状态导致 e_t 出现的概率 $P(e_t|X_t = i)$
- **对角观测矩阵 O_t** ： O_t 的第 i 个对角元素是 $P(e_t|X_t = i)$
- 雨伞世界，第一天 $U_1 = true$ ，第三天 $U_3 = false$

$$O_1 = \begin{pmatrix} 0.9 & 0 \\ 0 & 0.2 \end{pmatrix}, \quad O_3 = \begin{pmatrix} 0.1 & 0 \\ 0 & 0.8 \end{pmatrix}$$

□ 前向消息：

$$f_{1:t+1} = \alpha O_{t+1} T^T f_{1:t}$$

□ 后向消息：

$$b_{k+1:t} = T O_{k+1} b_{k+2:t}$$

矩阵论是一门成熟的学科，
矩阵运算在硬件和软件层面充分优化，写成矩阵有助于推导和计算机实现。

14.3 隐马尔可夫模型-简化矩阵算法


■ 前向-后向算法的另一种实现

- **传统方案：**对所有时间片的平滑需要计算所有时间片的前向消息 $f_{1:k}$ 和后向消息 $b_{k+1:t}$ 。前向-后向算法通过存储前向信息 $f_{1:k}$ ，并在后向传播的时候直接使用来避免冗余计算。
- **另一种方案：**在后向传播的过程中同时计算 f 和 b ：
 - ▶ 原始计算公式： $f_{1:t+1} = \alpha O_{t+1} T^T f_{1:t}$
 - ▶ 逆向计算公式： $f_{1:t} = \alpha' (T^T)^{-1} (O_{t+1})^{-1} f_{1:t+1}$
 - ▶ 首先运行标准前向传播方法得到最终时刻的前向消息 $f_{t:t}$ ，然后使用逆向公式同时对 f 和 b 后向传播。
 - ▶ 优点：存储要求低。 缺点：逆矩阵必须存在。


14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题

- ▣ 原始版本（第4章 复杂环境中的搜索）：机器人有单个非确定性的动作Move，它的传感器可以完美地报告在紧邻的北、东、南、西（NESW）4个方向是否有障碍物；机器人的信念状态是它可能所处的位置的集合。



$E_0 = (1011)$ 后的信念状态




$E_0 = (1011)$, $E_1 = (1010)$
后的信念状态

14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题

- 现在我们将**传感器中的噪声**考虑在内，并将机器人随机移动的想法形式化。即它移动到任何相邻的空方格的可能性都是相等的。



- **状态变量**: x_t 表示机器人在离散网格上的位置; 用整数 $\{1, \dots, S\}$ 标记, 空方格数量 $S = 42$ 。状态变量只有一个且离散, 符合隐马尔可夫模型。

14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题

- **转移模型**：Move 动作使得机器人等可能地到达任何邻近的方格，令 $Neighbors(i)$ 表示与 i 相邻的空方格集合， $N(i)$ 是该集合大小：

$$P(X_{t+1} = j | X_t = i) = T_{ij} = \begin{cases} \frac{1}{N(i)}, & \text{如果 } j \in Neighbors(i) \\ 0, & \text{其他} \end{cases}$$

在我们考虑的特定环境中， $S = 42$ ，转移矩阵 T 有 $42 \times 42 = 1764$ 个元素：

- **先验**：我们不知道机器人从哪个位置出发，所以我们假设它服从一个所有方格上的均匀分布，也就是说， $P(X_0 = i) = 1/S$ 。

14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题

- **证据变量：**传感器变量 E_t 给出每个罗盘方北东南西向（NESW）是否存在障碍，1010就是南北障碍，一共有 16 个可能的值。
- **传感器模型：**假设每个传感器的错误率是 ε ，4 个方向出现错误是相互独立的。在这种情况下，所有4位都正确的概率是 $(1 - \varepsilon)^4$ ，都错误的概率是 ε^4 。此外，如果 d 是方格 i 的真实传感值与实际读数 e_t 之间的差异——错误的个数，那么方格 i 中的机器人接收到传感器读数 e_t 概率为：

$$P(E_t = e_t | X_t = i) = (O_t)_{ii} = (1 - \varepsilon)^{4-d} \varepsilon^d$$


- ▶ 例如，一个所有位置都没有障碍物的方格产生出传感器读数1000（错对对对）的概率 $(1 - \varepsilon)^3 \varepsilon^1$

14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题


- 给定矩阵 T (转移模型) 和 O (传感器模型) 我们可以弄清机器人在某个时刻在哪里。
- 用法1：使用**滤波**找到机器人当前位置的概率。假设时刻1南北西有障碍物，时刻2南北有障碍物，传感器故障率0.2。

$$P(X_2 | E_1 = 1011, E_2 = 1010)$$




14.3 隐马尔可夫模型-示例：定位

■ 示例：真空吸尘器世界的定位问题



传感器
有故障





传感器
无故障

14.3 隐马尔可夫模型-示例：定位


■ 示例：真空吸尘器世界的定位问题

- 用法2：使用平滑找到任何过去时间它所处的位置。使用前向-后向算法找到所处位置最可能得路径
- 传感器错误率与定位及路径误差。即使错误率=0.2（59%的情况下有错误），20次观测后基本确定自己的位置，误差不超过两个方格。



- 时间与不确定性
- 时序模型中的推理
- 隐马尔可夫模型（离散变量）
- 卡尔曼滤波器（连续变量）
- 动态贝叶斯网络

14.4 卡尔曼滤波器-概述



■ HMM与卡尔曼滤波器的异同点

- HMM处理的是离散状态，卡尔曼处理的是连续状态
- HMM观测没有噪声，卡尔曼假设有高斯白噪声
- HMM只有状态转移矩阵，卡尔曼是状态转移矩阵+高斯噪声过程

14.4 卡尔曼滤波器-概述

■ 典型应用-轨迹预测

- 想象你是一名第二次世界大战时期的雷达操作员，你正盯着屏幕上每10 秒出现一次的微弱的、徘徊的光点。
- 想象你是开普勒，你试图从一系列非常不准确的角度观测数据中重建行星的运动，这些观测数据是在不规则且不精确的间隔得到的。
- 这些任务都是滤波：根据一段时间内带有噪声的观测来估计状态变量，该变量是运动对象的位置和速度，因此是连续的，不能够使用HMM来表示。
- **处理连续随机变量的方法，称为用卡尔曼滤波（Kalman filtering）。连续变量下的时间模型可以使用线性高斯模型**

14.4 卡尔曼滤波器-概述

■ 高斯分布的良好性质：封闭性

- 滤波计算之**预测部分**：如果当前滤波分布 $P(X_t|e_{1:t})$ 是高斯分布，转移模型 $P(X_{t+1}|X_t)$ 是线性高斯分布，则预测部分也是高斯分布：

因此，如果 $t=0$ 时的先验是高斯的，
传感器模型和转移模型是线性高斯的，
那么前向传播所计算的滤波在任何时刻都是高斯的。

预测：

- 滤波计算之**更新部分**：如果观测 $P(e_{t+1}|X_{t+1})$ 是高斯，传感器模型 $P(e_{t+1}|X_{t+1})$ 是线性高斯，则新证据更新后滤波结果仍然为高斯：

$$P(X_{t+1}|e_{1:t+1}) = \alpha P(e_{t+1}|X_{t+1})P(X_{t+1}|e_{1:t})$$

更新步骤

传感器模型

预测

14.4 卡尔曼滤波器-一维示例

■ 示例：随机游走 —— 一维卡尔曼滤波

- 单个连续状态变量 x_t 的随机游走，在每个时间点进行一次随机移动，其观测位置 z_t 含有噪声

先验

以 μ_0 为中心，方差为 σ_0^2 的高斯分布

$$P(x_0) = ae^{-\frac{1}{2}\left(\frac{(x_0-\mu_0)^2}{\sigma_0^2}\right)}$$

转移模型

当前位置增加一个方差为常数 σ_x^2 的高斯扰动

$$P(x_{t+1}|x_t) = ae^{-\frac{1}{2}\left(\frac{(x_{t+1}-x_t)^2}{\sigma_x^2}\right)}$$

传感器模型

观察位置为真实位置添加一个方差为 σ_z^2 的高斯噪声

$$P(z_t|x_t) = ae^{-\frac{1}{2}\left(\frac{(z_t-x_t)^2}{\sigma_z^2}\right)}$$

14.4 卡尔曼滤波器——维示例

■ 示例：随机游走 —— 一维卡尔曼滤波

□ $t = 1$ 时滤波结果，单步预测步骤：

$$P(x_1) = \int P(x_1|x_0)P(x_0)dx_0 = \alpha \int e^{-\frac{1}{2}\left(\frac{(x_1-x_0)^2}{\sigma_x^2}\right)} e^{-\frac{1}{2}\left(\frac{(x_0-\mu_0)^2}{\sigma_0^2}\right)} dx_0$$

$$= \alpha e^{-\frac{1}{2}\left(\frac{(x_1-\mu_0)^2}{\sigma_0^2+\sigma_x^2}\right)}$$

□ 更新步骤：

$$P(x_1|z_1) = \alpha P(z_1|x_1)P(x_1) = \alpha e^{-\frac{1}{2}\left(\frac{(z_1-x_1)^2}{\sigma_z^2}\right)} e^{-\frac{1}{2}\left(\frac{(x_1-\mu_0)^2}{\sigma_0^2+\sigma_x^2}\right)}$$

$$= \alpha e^{-\frac{1}{2}\left(\frac{\left(x_1 - \frac{(\sigma_0^2+\sigma_x^2)z_1 + \sigma_z^2\mu_0}{\sigma_0^2+\sigma_x^2+\sigma_z^2}\right)^2}{(\sigma_0^2+\sigma_x^2)\sigma_z^2/(\sigma_0^2+\sigma_x^2+\sigma_z^2)}\right)}$$

14.4 卡尔曼滤波器——一维示例

■ 示例：随机游走 —— 一维卡尔曼滤波

□ 卡尔曼滤波在一维情况下的均值和方差更新公式：

$$\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2)z_{t+1} + \sigma_z^2\mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

$$\sigma_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2)\sigma_z^2}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

□ 新均值 μ_{t+1} 的计算可以解释为新观测值 z_{t+1} 和旧均值 μ_t 的加权平均

- 如果观测值不可靠，即 σ_z^2 较大，我们应更加重视旧的均值；
- 如果旧的均值是不可靠的（ σ_t^2 很大）或过程是高度不可预测的（ σ_x^2 很大），那么我们会更加注重观测值。

14.4 卡尔曼滤波器——一维示例

■ 示例：随机游走 —— 一维卡尔曼滤波

□ 卡尔曼滤波在一维情况下的均值和方差更新公式：

$$\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2)z_{t+1} + \sigma_z^2\mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

$$\sigma_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2)\sigma_z^2}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

- 方差的更新是独立于观测的。因此可以提前计算出方差值的序列。
- 方差序列很快收敛到一个只依赖于 σ_x^2 （转移模型方差）与 σ_z^2 （传感器模型方差）的固定值，从而大大简化了后续的计算。

14.4 卡尔曼滤波器-一般形式

■ 高维卡尔曼滤波（一般形式）

□ 多元高斯分布：

$$\mathcal{N}(x; \mu, \Sigma) = a e^{-\frac{1}{2}((x-\mu)^T \Sigma^{-1}(x-\mu))}$$

□ 转移模型：

$$P(x_{t+1}|x_t) = \mathcal{N}(x_{t+1}; Fx_t, \Sigma_x)$$

□ 传感器模型：

$$P(z_t|x_t) = \mathcal{N}(z_t; Hx_t, \Sigma_z)$$

14.4 卡尔曼滤波器-一般形式

■ 高维卡尔曼滤波（一般形式）

□ 滤波计算：

$$\mu_{t+1} = F\mu_t + K_{t+1}(z_{t+1} - HF\mu_t)$$

$$\Sigma_{t+1} = (I - K_{t+1}H)(F\Sigma_tF^T + \Sigma_x)$$

其中： $K_{t+1} = (F\Sigma_tF^T + \Sigma_x)H^T(H(F\Sigma_tF^T + \Sigma_x)H^T + \Sigma_z)^{-1}$
(卡尔曼增益矩阵)

14.4 卡尔曼滤波器-概述

■ 高维卡尔曼滤波




图 14-11 (a) 在 xy 平面上运动物体的卡尔曼滤波结果，显示真实的轨迹（从左到右）、一系列的噪声观测，以及卡尔曼滤波估计的轨迹。位置估计中的方差由椭圆表示。(b) 对相同的观测序列进行卡尔曼平滑的结果

14.4 卡尔曼滤波器-适用范围


■ 卡尔曼滤波器的经典应用

- 对飞行器和导弹的雷达追踪。
- 潜艇和地面车辆的声学追踪
- 车辆和人的视觉追踪。
- 在一些更加深奥的领域，卡尔曼滤波器被用来从气泡室照片**重建粒子轨迹**和从卫星地表**测量重建洋流**。
- 应用范围远不止于运动追踪：它在任何通过**连续状态变量**和**噪声测量刻画**的系统中都可以使用。这些系统包括纸浆厂、化工厂、核反应堆、植物生态系统等。

- 时间与不确定性
- 时序模型中的推理
- 隐马尔可夫模型
- 卡尔曼滤波器
- 动态贝叶斯网络

14.5 动态贝叶斯网络-概述

■ 动态贝叶斯网络(dynamic Bayesian network, DBN)




- 一种表示描述时序概率模型的贝叶斯网络，具有无穷多变量的贝叶斯网络。
- 动态贝叶斯网络中的每个时间片可以具有任意数量的状态变量与证据变量
- 可以对任意分布建模。卡尔曼滤波器和离散马尔科夫模型都可以转化为动态贝叶斯网络。

14.5 动态贝叶斯网络-构建贝叶斯网络

■ 构建贝叶斯网络

- 三元素：状态变量的先验分布 $P(X_0)$ ，转移模型 $P(X_{t+1}|X_t)$ ，传感器模型 $P(E_t|X_t)$
- 还需要描述连续时间片之间以及状态变量和证据变量之间连接的拓扑结构
- 假设转移模型和传感器模型是时间齐次的（对所有 t 都相同），仅在第一个时间片中描述它们



14.5 动态贝叶斯网络-推断

■ 贝叶斯网络的推断

- 动态贝叶斯网络就是贝叶斯网络，因此可以使用所有贝叶斯网络的推断方法。
- 精确推断：枚举、变量消元
 - ▶ 变量消元恰好模仿了滤波中的递归操作：每次消元恰好消去两个时间片之前的变量，使得贝叶斯网络只保留两个时间片。
- 近似推断：似然加权（更适合动态贝叶斯）、马尔科夫蒙特卡洛（MCMC），

14.5 动态贝叶斯网络-推断

■ 粒子滤波

- 思想1：通过动态贝叶斯网络同时运行 N 个样本，每次一个时间片。他以 N 个样本组成的集合作为前向消息，向前传播。
 - ▶ 原始似然加权：展开整个网络，每次采样一个样本。
 - ▶ 序贯重要性采样（SIS）：无须展开动态贝叶斯网络，沿时间同时采样 N 个样本，内存中只存有当前时间片和下一时间片。
- 思想2：聚焦于状态空间的高概率区域上的样本集合。这通过依据观测值丢弃权重很低的样本，并复制权重很高的样本来实现。
 - ▶ 似然加权中，下游证据越多，则样本权重越小，而动态贝叶斯网络中下游证据很多，样本权重随着序列长度 t 指数下降。
 - ▶ 即使有10万样本，20万次更新后也将失效。

14.5 动态贝叶斯网络-推断

■ 粒子滤波流程：

- 首先，从先验分布 $P(X_0)$ 生成N个样本的总体。然后在每个时间步重复更新循环。
 1. 对每个样本，给定当前值 X_t ，根据转移模型 $P(X_{t+1}|X_t)$ 通过采样下一个状态值 X_{t+1} 向前传播。
 2. 每个样本使用它赋予新证据的似然 $P(e_{t+1}|X_{t+1})$ 进行加权。
 3. 重采样以产生一个有 N 个样本的新总体。每个新样本都是从当前总体中选取的；一个特定样本被选中的概率与它的权重成正比。新样本是无权重的。

14.5 动态贝叶斯网络-推断

■ 粒子滤波流程：




图 14-18 $N=10$ 的雨伞动态贝叶斯网络的粒子滤波更新循环，显示每个状态的样本总体。(a) 在时刻 t ，有 8 个样本表示 $rain$ ，有 2 个样本表示 $\neg rain$ 。每个状态通过转移模型采样下一个状态向前传播。在时刻 $t+1$ ，有 6 个样本表示 $rain$ ，有 4 个样本表示 $\neg rain$ 。(b) 在时刻 $t+1$ 观测到 $\neg umbrella$ 。每个样本通过这个观测的似然来进行加权，权重如圆的大小所示。(c) 从当前的集合中通过加权随机选择产生一个新的集合，共有 10 个样本，其中 2 个样本表示 $rain$ ，8 个样本表示 $\neg rain$

□ 数量代替权重：

- 大量小权重样本变为数量较少的样本
- 少量大权重样本变为数量较多的样本

本章小结

- 通过使用一组**随时间片变化的随机变量**来处理世界的变化状态。
- 时序概率模型包含了描述状态演变的**转移模型**和描述观察过程的**传感器模型**。
- 表示可以设计为（大致）满足**马尔可夫特性**，因此给定现在的信息，未来是独立于过去的。再加上过程是时间齐次的假设，表示可以得到巨大的简化。
- 时序模型主要推理任务：**滤波，预测，平滑，最可能解释**。
- 时序模型3个家族：**隐马尔可夫模型，卡尔曼滤波器，动态贝叶斯网络**。
- 在实际应用中，**粒子滤波**算法及其衍生算法是有效的近似算法。

历史与趣闻

- 许多估计动力学系统状态的基本思想来自数学家高斯（Gauss, 1809），他提出了一种确定性最小二乘算法来解决根据天文观测估计轨道的问题。
- 马尔可夫（Markov, 1913）在分析随机过程时提出了后来被称为马尔可夫假设的理论，他对《叶甫盖尼·奥涅金》文本中的字母估算了一阶马尔可夫链。（Levin et al., 2008）中涵盖了关于马尔可夫链及其混合时间的一般理论。
- 在第二次世界大战期间，维纳（Wiener, 1942）和柯尔莫哥洛夫（Kolmogorov, 1941）分别对连续时间过程和离散时间过程进行了重要的滤波分类工作。

历史与趣闻

- 彼得·斯威林 (Swerling, 1959) 与鲁道夫·卡尔曼 (Kalman, 1960) 描述了带高斯噪声的线性系统中的前向推断的卡尔曼滤波器。在 1960 年访问美国国家航空航天局艾姆斯 (NASA Ames) 研究中心之后, 卡尔曼发现了这种方法在跟踪火箭轨迹方面的适用性, 后来这种滤波被用于阿波罗任务。
- 隐马尔可夫模型和相关的推断和学习算法, 包括前向-后向算法, 是由鲍姆和皮特里 (Baum and Petrie, 1966) 开发的。维特比算法最早出现在 (Viterbi, 1967) 中。
- 前向-后向算法是 EM 算法一般公式的主要前驱之一

历史与趣闻

- 隐马尔可夫模型在语言处理 (Charniak, 1993)、语音识别 (Rabiner and Juang, 1993)、机器翻译 (Och and Ney, 2003)、计算生物学 (Krogh et al., 1994; Baldi et al., 1994)、金融经济学 (Bhar and Hamori, 2004) 以及其他领域得到了广泛的应用。
- 动态贝叶斯网络已经成为计算机视觉中建模各种复杂运动过程的流行方法 (Huang et al., 1994;)。和隐马尔可夫模型一样, 它们也应用在语音识别 (Zweig and Russell, 1998)、机器人定位 (Theocharous et al., 2004) 和基因学 (Murphy and Mian, 1999;) 等方面。其他应用领域包括动作分析 (Suk et al., 2010)、驾驶员疲劳检测 (Yang et al., 2010) 和城市交通建模 (Hofleitner et al., 2012)。

课后作业

- 有一位教授想知道学生是否睡眠充足。每天，教授观察学生在课堂上是否睡觉，并观察他们是否有红眼。教授获得如下的领域知识：
 - 没有观察数据时，学生睡眠充足的先验概率为0.7。
 - 给定学生前一天睡眠充足为条件，学生在晚上睡眠充足的概率是0.8；如果前一天睡眠不充足，则是0.3。
 - 如果学生睡眠充足，则红眼的概率是0.2，否则是0.7。
 - 如果学生睡眠充足，则在课堂上睡觉的概率是0.1，否则是0.3。
- 将这些信息形式化为一个动态贝叶斯网络，使教授可以使用这个网络从观察序列中进行滤波和预测。然后再将其形式化为一个只有一个观察变量的隐马尔可夫模型。给出这个模型的完整的概率表。

课后作业

■ 假定

- e_1 = 没有红眼，没有在课堂上睡觉
- e_2 = 有红眼，没有在课堂上睡觉
- e_3 = 有红眼，在课堂上睡觉。

■ 执行下面的计算：

- 状态估计：针对每个 $t = 1, 2, 3$ ，计算 $P(\text{EnoughSleep}_t | e_{1:t})$
- 平滑：针对每个 $t = 1, 2, 3$ ，计算 $P(\text{EnoughSleep}_t | e_{1:3})$
- 针对 $t = 1$ 和 $t = 2$ ，比较滤波概率和平滑概率

THANKS

Q & A

14.3 隐马尔可夫模型-简化矩阵算法

■ 固定滞后的在线平滑

- 假设滞后时间为 d ，即当前时间为 t 时，在时间片 $t - d$ 处进行平滑。需要计算

$$\alpha f_{1:t-d} \times b_{t-d+1:t}$$

- 下一时刻，当新的观测值到达时，需要为时间片 $t - d + 1$ 计算

$$\alpha f_{1:t-d+1} \times b_{t-d+2:t+1}$$

- 以增量的形式计算

▶ 利用标准滤波，可以根据 $f_{1:t-d}$ 计算 $f_{1:t-d+1}$

▶ 对于后向消息，我们令 $B = TO$ 旧的 B 矩阵和新的 B 矩阵关系可以描述为：

$$B_{t-d+2:t+1} = O_{t-d+1}^{-1} T^{-1} B_{t-d+1:t} T O_{t+1}$$

14.3 隐马尔可夫模型-简化矩阵算法

■ 简化矩阵算法

function FIXED-LAG-SMOOTHING(e_t , hmm , d) **returns** 一个 X_{t-d} 上的分布

inputs: e_t , 时间步 t 的当前证据

hmm , 具有 $S \times S$ 转移矩阵 T 的隐马尔可夫模型

d , 平滑的滞后长度

persistent: t , 当前的时间, 初始为 1

f , 前向消息 $P(X_t | e_{1:t})$, 初始为 $hmm.Prior$

B , d 步后向变换矩阵, 初始为单位矩阵

$e_{t-d:t}$, 从 $t-d$ 到 t 的双端证据列表, 初始为空

local variables: O_{t-d} , O_t , 包含传感器模型信息的对角矩阵

在 $e_{t-d:t}$ 的尾端添加 e_t

$O_t \leftarrow$ 包含 $P(e_t | X_t)$ 的对角矩阵

if $t > d$ **then**

$f \leftarrow \text{FORWARD}(f, e_{t-d})$

从 $e_{t-d:t}$ 的首端移除 e_{t-d-1}

$O_{t-d} \leftarrow$ 包含 $P(e_{t-d} | X_{t-d})$ 的对角矩阵

$B \leftarrow O_{t-d}^{-1} T^{-1} B O_t$

else $B \leftarrow B O_t$

$t \leftarrow t + 1$

if $t > d + 1$ **then return** NORMALIZE($f \times B I$) **else return** null

图 14-6 作为一种在线算法实现的具有固定的 d 步时间滞后的平滑算法, 在给定新时间步的观测值时输出新的平滑估计。注意, 根据式 (14-14), 最终的输出 NORMALIZE($f \times B I$) 恰好是 $\alpha f \times b$

- 在有固定延迟的联机平滑中, 存在一种高效的递归算法——即一种时间复杂度与延迟长度无关的算法

14.4 卡尔曼滤波器-适用范围

■ 扩展卡尔曼滤波器 (EKF)

- 线性高斯转移模型和传感器模型假设是非常强的。
- 扩展卡尔曼滤波器——克服模型中的非线性。
- 扩展卡尔曼滤波器将系统建模为 x_t 在 $x_t = \mu_t$ 区域是局部线性的，其中 μ_t 是当前状态分布的均值。这对于光滑的、行为良好的系统表现良好，并允许追踪器去维护和更新高斯状态分布，是真实后验的合理近似。

14.4 卡尔曼滤波器-适用范围




图 14-12 一只飞向树的鸟（俯视）。(a) 一个卡尔曼滤波器将使用以障碍物为中心的单个高斯分布预测鸟的位置。(b) 一个更实际的模型允许鸟的躲避动作，预测它会飞到一边或另一边

■ “不光滑” 或 “行为不良” ？

- 这意味着(根据协方差 Σ_t)在与当前均值 μ_t 相近的区域内，系统响应存在显著的非线性。

14.4 卡尔曼滤波器-适用范围

■ 切换卡尔曼滤波器

- 多个卡尔曼滤波器并行运行，且每个滤波器使用不同的系统模型。
- 例如，一个用于直飞，一个用于左急转，一个用于右急转。使用的是预测的加权和，其中的权重取决于每个滤波与当前数据的匹配程度。
- 这是一般动态贝叶斯网络模型（下一节）的一个特例。