

机器人学

第十四讲 目标分割与识别

中科院自动化所

章节安排

一

检测、识别与测量

二

图像分割与目标分割

三

初探目标识别：模板匹配

四

特征提取与分类器

五

深度学习简介

检测、识别与测量

视觉检测有时称为提取（Detection/Extraction）

- 目标检测、边缘提取、直线提取等。输入是一幅图像，输出是图像块位置的集合。

识别（recognition）与分类（classification）

- 判断类别属性，输入是一个图像块，输出是类别标签，在数学上描述为可列元素的集合。“re”“cognition”暗示了“再认知”

测量（measurement）：机器人视觉的特色内容

- 计算观测对象的物理属性，输入是图像或者图像块，输出是具有量纲的数据。其中在图像层次上具有的中间输出：像素坐标集合

检测、识别与测量




工业现场：高速皮带缺陷检测




核工业：惯性约束微靶检测

检测、识别与测量

电力行业：无人机高压绝缘子检测、识别与缺陷辨识




大连海事大学 Otst /遗传算法/hough



华北电力大学 PCNN /SIFT/矩特征匹配





电子科技大学 Lab 颜色空间/钢化绝缘子



湖南大学 红外图像分割

检测、识别与测量

电力行业：无人机高压绝缘子检测、识别与缺陷辨识



Descriptor	CGL	SIFT [15]	SURF [1]
TPR	92.7%	92.5%	75.8%
TNR	99.7%	92.4%	90.5%
Average runtime	1.4ms	1.9ms	0.25ms

章节安排

一

检测、识别与测量

二

图像分割与目标分割

三

初探目标识别：模板匹配

四

特征提取与分类器

五

深度学习简介

图像分割与目标分割

图像分割

将一幅图像分割成在某种意义上是均匀的、与相邻区域不同的连通区域

图像分割
技术是目标
分割的基础

图像的许多属性，如阴影、色调、纹理或对比度，可以用来定义均匀性的度量

目标分割

一般被定义为将像素标记为目标像素或背景像素的过程

图像分割与目标分割

表示图像区域的数据结构

像素
集合

记录属于一个区域的所有像素
(标记数组/vector)

只记录区域的边缘，如像素、
线段、曲线等(vector/list)

边缘
集合

图像分割与目标分割

阈值法

出现时间最早

发展为自适应阈值法

图论类
方法

全局性强，理论清晰
基于图割或者连通性
理论对图像进行划分

神经网络
类方法

早期优势不明显

近年展现出强大优势

图像分割与目标分割

对于目标分割的研究始于上世纪70年代

1972年 Bacusmber, James W.等提出了一种基于数字图像的白细胞分类方法

通过在载玻片上设置不同颜色的滤镜，他们得到了表征不同颜色的灰度图像


作者在各灰度图像中通过设定阈值的方式对像素进行标注，成功实现了对白细胞区域的筛选

1992年 日本学者Miyajima, K.等提出基于模糊推理的图像区域分割方法

在该方法中作者提出了一种自顶向下的处理流程

- 估计出目标大致的位置与形状
- 默认初始化阈值进行二值化处理
- 自动调整阈值

阈值的自动调整采用了模糊规则，简而言之，如果模板匹配中误匹配点数量大，则某些阈值增加地快，



图像分割与目标分割

1993年加拿大学者Crevier, D.等基于HSV颜色模型提出了一种彩色图像的分割方法

HSV (Hue, Saturation, Value) 是根据颜色的直观特性由A. R. Smith在1978年创建的一种颜色空间, 也称六角锥体模型 (Hexcone Model)

RGB转化到HSV的算法:

$\max = \max(R, G, B);$

$\min = \min(R, G, B);$

$V = \max(R, G, B);$


$S = (\max - \min) / \max;$

if ($R = \max$) $H = (G - B) / (\max - \min) * 60;$

if ($G = \max$) $H = 120 + (B - R) / (\max - \min) * 60;$

if ($B = \max$) $H = 240 + (R - G) / (\max - \min) * 60;$

if ($H < 0$) $H = H + 360;$



图像分割与目标分割

1986年 英国学者Morris O.J.等首次提出了基于图论的图像分割方法

作者将图像映射到一个加权图上，并使用该图的生成树来描述图像中的区域或边缘。由于边缘检测是分割中的一个双重问题。

作者开发了多种边缘检测方法，每种方法都提供了不同的分割或边缘检测技术。其中最简单的方法使用了最短生成树(SST)，这一概念构成了其他改进方法的基础。

与阈值类方法相比，基于图论的方法一个重要特点是区域可以用分层的方式描述。

图像分割与目标分割

赋权图

一条边首尾各连接一个顶点，既可以是两个不同的顶点，也可以是同一个顶点。如果给每条边赋予一个权重，所得到的图称为赋权图

无向图

如果给每条边指定一个方向，所得到的图称为有向图，否则称为无向图

连通图

在无向图中，若任意两个顶点 v_i 与 v_j 都有路径相通，则称该无向图为连通图

图像分割与目标分割

“链”是一系列连续的顶点，其中每个顶点通过图中的一条边连接到下一个顶点

链

一个连通图的生成树是指一个连通子图，它含有图中全部 n 个顶点，但只有足以构成一颗树的 $n-1$ 条边。一棵有 n 个顶点的生成树有且仅有 $n-1$ 条边，如果生成树中再添加一条边，则必定成环

环


树

“树”是一组相互连接且没有“环”的链


一个“环”是一个链，它的末端连接在起始顶点上

图像分割与目标分割

在加权图中，权值和最小的生成树叫做“最小生成树”
一个图的多个生成树构成的集合称为“生成森林”



(a)赋权图




(b)最小生成树

图像分割与目标分割


例如坐标为 (x,y) 的像素值为 $I_{x,y}$ ，则记录第 i 个顶点的权值为 $I_{x,y}$ 记为： $v_i = I_{x,y}$

由于 x 和 y 都是离散量，可以建立 i 与 (x,y) 间的一一映射关系。连接第 i 个顶点和第 j 个顶点的边的权值为 $e_{ij} = |v_i - v_j|$

一个顶点理论上可以与任何其他的顶点相连，但考虑到算法的复杂度和实用性，一般只建立每个像素与邻近像素的连接，例如采用八邻域，即每个像素只与上下左右以及对角的八个像素相连，于是所构建的图中，每个顶点最多只连八条边。



图像分割与目标分割



将生成树切割为由一系列不连通的树构成的森林

- 两个顶点的相似性由连接它们的最小权值边定义
- 需要计算最小生成树
- 最小生成树可以用贪心算法、克鲁斯卡尔算法、普里姆算法等

图像分割与目标分割

定义一种度量像素相似度的函数，并以此为依据将图像描述为一个赋权无向图

一

计算图的最小生成树

二

根据生成树的连接权重不断去掉相应的边使得生成树分割为生成森林

三

找到生成森林中每棵树对应图像区域，完成图像分割

四

最基本的基于最小生成树的图像分割算法

图像分割与目标分割

最小生成树包含了将图像分割为任意数量区域所需的所有信息，这些区域按照像素的相似度形成层次化的结构，添加或删除一个区域是一个简单的操作。其存在的问题在于分割过程缺乏对全局信息的考量，很多孤立的像素会被分割为一个独立的区域，这导致分割过程对噪音和干扰十分敏感

基于最小生成树的图像分割方法的特点


空间连接关系被充分考虑，分割出的每个区域都是连通域，这与阈值类方法是不同的

区域的边界明确且平整，不像阈值类方法那样产生锯齿状的边界，并需要通过模糊逻辑等手段进行处理

由于分割的依据是单条边的权值，如果两个差异很大区域被一系列渐变的像素连接，它们往往不能被有效分割。因为这种情况下，虽然两个区域的差异很大，但这种大差异被分摊为多个难以被检测的小差异。为了克服这些缺陷，需要对原始的最小生成树方法加以改进

图像分割与目标分割

递归最小生成树分割法



每次递归只保留图中权重最大的边

图像分割与目标分割

递归最小生成树分割法

由于每个区域中的所有像素值都相同，因此可以对图进行简化，用一个顶点表示整个区域。当最小生成树被切割成一个森林来描述划分时，每棵树都可以被简化为一个单独的顶点。图到图像的映射变成了一对多映射，由顶点 V_i 描述的区域 $P(i)_{x,y}$ 被重新定义为：

$$P(i)_{x,y} = \begin{cases} 1, & \text{如果像素 } x, y \text{ 属于顶点 } V_i \text{ 定义区域} \\ 0, & \text{其他} \end{cases}$$

$$v_i = \sum_{x,y} P(i)_{x,y} I_{x,y} / \sum_{x,y} P(i)_{x,y}$$

图像分割与目标分割



连接顶点 V_i 和 V_j 的边被从图中删除，并添加顶点 V_k 。从顶点 V_i 和 V_j 连接到其他顶点的边的权值根据新顶点 V_k 的值 v_k 进行更新。顶点合并过程会产生一些首尾顶点相同的冗余边，需要进行冗余去除。

图像分割与目标分割

最小最大生成树分割法

将图分解为一系列子图，为每个子图设计一个合适的目标函数。

图像分割问题于是可以转化为最小化所有目标函数的优化问题。

由于一个图可能拥有的子图数量非常庞大，直接求解该优化问题是非常困难的。最小最大生成树法通过寻找该问题的次优解使得算法复杂度降低到可接受的范围。

如果最小生成树被切割为一个由树的集合 $\{T\}$ 构成的生成森林 F ，将每棵树的评价函数 $c(T)$ 定义为：

$$c(T) = \max[|v_i - v_j|] \quad \forall i, j \in T$$

图像分割与目标分割



a

两颗树 T_i, T_j , 使得这两个树
评价值的最大值最小



b

像分割结果。

最后根
夹得图

$$\min[\max[c(T_i), c(T_j)] \mid E_{i,j} \in T_{\max}]$$

2

找到


找到
最大的

图像分割与目标分割


1988年, Pomerleau

最早利用神经网络对图像区域进行感知的研究源自机器人视觉领域。


1988 Pomerleau 提出的这种网络共三层，为全连接结构。作为输入的原始图像大小为 30×32 像素。每个像素为一个独立的输入，因此网络输入层共 **960** 个单元。每个神经元具有一个偏置输入，整个网络可调节的参数量为 $960 \times 4 + 4 \times 30 + 30 = 3994$ 。输出层每个神经元对应一个方向盘的转角。



图像分割与目标分割




人工合成样本



隐含层权重

图像分割与目标分割

提出的方法是一种隐式的图像区域感知方法，虽然区域感知的结果可以用于无人车的航向控制，但并没有给出明确的区域分割结论用神经网络对像素进行显示标记的尝试始于1989年。**Wright**设计了一个三层感知机**Wright**利用图像区域的相对位置关系和特征统计信息作为网络输入进行训练



章节安排

一

检测、识别与测量

二

图像分割与目标分割

三

初探目标识别：模板匹配

四

特征提取与分类器

五

深度学习简介

初探目标识别：模板匹配

数学层面，识别是一个标量值函数：

用一堆数字描述目标，那么函数形式为： $f(\text{目标}) = \text{标量}$
(严格的说，值域是一个可列集)

已知的身份集合
目标的数字化描述
可计算的映射

目标识别的三要素

初探目标识别：模板匹配

根据应用场合的不同可以分为工业机器人目标识别和服务机器人目标识别两大类。由于性能指标的侧重点不同，这两类目标识别任务采用的传感器以及算法具有很多不同点

工业机器人目标识别

- 强调准确率和稳定性
- 一般识别率都要求在99%以上
- 漏检率的要求十分苛刻，往往不能超过千分之一
- 环境人为可控，具有较高的确定性

两大类应用场合

服务机器人目标识别

- 一般用于场景辨识、目标搜索、地图构建等任务
- 在运动过程中有很多次观测识别目标的机会
- 识别准确率和稳定性要求较工业领域要低得多
- 对目标识别的适应性和智能性要求较高


工业领域的目标识别和服务机器人目标识别都对实时性具有较高的要求。不同的是前者对运算平台尺寸、功耗、散热等的要求显著低于后者。

初探目标识别：模板匹配

模板匹配是一种很基础的目标识别方法，具有设计思路直观，算法开发简单等优点，直到今天在工业视觉领域都有着广泛的应用。最简单的模板是事先存储的目标图像，匹配过程用模板图像和采集到的图像做差分。如果采集到的图像与模板图像对应像素的值越接近，那么差值的绝对值就越小。

将模板 $T(m,n)$ 叠放在 $I(u,v)$ 上平移 I 上中被 T 覆盖的部分表示为 I_{ij} ， (i,j) 表示覆盖部分左上角在 I 中的坐标，可以用下式衡量 T 与 I_{ij} 的相似性：

$$E(i, j) = \sum_{m=1}^M \sum_{n=1}^N |I_{ij}(m, n) - T(m, n)|$$



初探目标识别：模板匹配

改为采用L2范数度量：

$$D(i, j) = \sum_{m=1}^M \sum_{n=1}^N [I_{ij}(m, n) - T(m, n)]^2$$

将其归一化，得到模板匹配的相关系数：

$$R(i, j) = \frac{\sum_{m=1}^M \sum_{n=1}^N I_{ij}(m, n) \times T(m, n)}{\sqrt{\sum_{m=1}^M \sum_{n=1}^N [I_{ij}(m, n)]^2} \sqrt{\sum_{m=1}^M \sum_{n=1}^N [T(m, n)]^2}}$$

实际上就是卷积计算

初探目标识别：模板匹配

目标旋转

➡ 相关系数不再能客观的反应目标与模板的差异

构造旋转目标

➡ 可行，但计算量成指数增加

分层模板匹配


➡ 在不影响效果的前提下大幅减小计算量

初探目标识别：模板匹配

多分辨率模板匹配

基本假设：对于输入图像中正确的目标区域，通过降采样同时减小模板和区域的分辨不会显著减小两者的相关性系数。但反之并不成立

初探目标识别：模板匹配



初探目标识别：模板匹配

Barnea等人于1972年提出的惯序相似性检测法（sequential similarity detection algorithm）是另一种降低模板匹配算法复杂性的方法，算法描述如下：

$$\text{定义绝对误差 } \varepsilon(i, j, m, n) = |I_{ij}(m, n) - \bar{I}_{ij} - T(m, n) + \bar{T}|$$

在板图中不断随机选取不重复的像素点，计算与当前覆盖像素的绝对误差，将误差累加，当误差累加值超过了给定阈值 T_h 时，记下累加次数 H 用每个覆盖区域的累加次数 H 作为相似性的度量，用公式表示为：

$$S(i, j) = \left\{ H \left| \min_{1 \leq H \leq M \times N} \left[\sum_{h=1}^H \varepsilon(i, j, m, n) \geq Th \right] \right. \right\}$$

章节安排

一

检测、识别与测量

二

图像分割与目标分割

三

初探目标识别：模板匹配

四

特征提取与分类器

五

深度学习简介

特征提取与分类器


两种思路

模板匹配法是一种遍历式的度量过程，通过累加对应像素的绝对差度量模板和覆盖区域的差异

另一种目标识别的思路是用判别代替度量，对于输入图像的选定区域，估计它是目标的可能性。

特征提取与分类器


分类器是一个整数值函数，
该函数能够把输入数据映射
到给定类别中的某一个



分类强度

强度是评价一个分类器性能的重要指标，它是指该分类器可以给出正确分类结果的概率，概率越高，我们称其分类能力越强

特征提取与分类器



多个相互独立的弱分类器综合来提升分类准确率。

最早研究该问题的学者是Kearns与Valiant，他们在研究PAC (Probably Approximately Correct) 学习模型的过程中提出了弱分类器与强分类器学习能力等价的猜想，将问题表述为“假设增强问题”(hypothesis boosting problem)所采用的单词“boosting”作为该类算法的称呼一直沿用至今。猜想的核心在于多个弱分类器可以整合在一起成为一个强分类器。

特征提取与分类器

1990年Schapire通过构造多项式的方法证实了这一猜想，这也是最初的Boosting算法，该算法步骤如下：

1

从具有 N 个样本的样本集中抽取 $n_1 < N$ 个样本，构造第一个分类器 f_1

2

从样本集中抽取 $n_2 < N$ 个样本，保证其中有一半的样本是 f_1 误分类的部分，构造第二个分类器 f_2

3

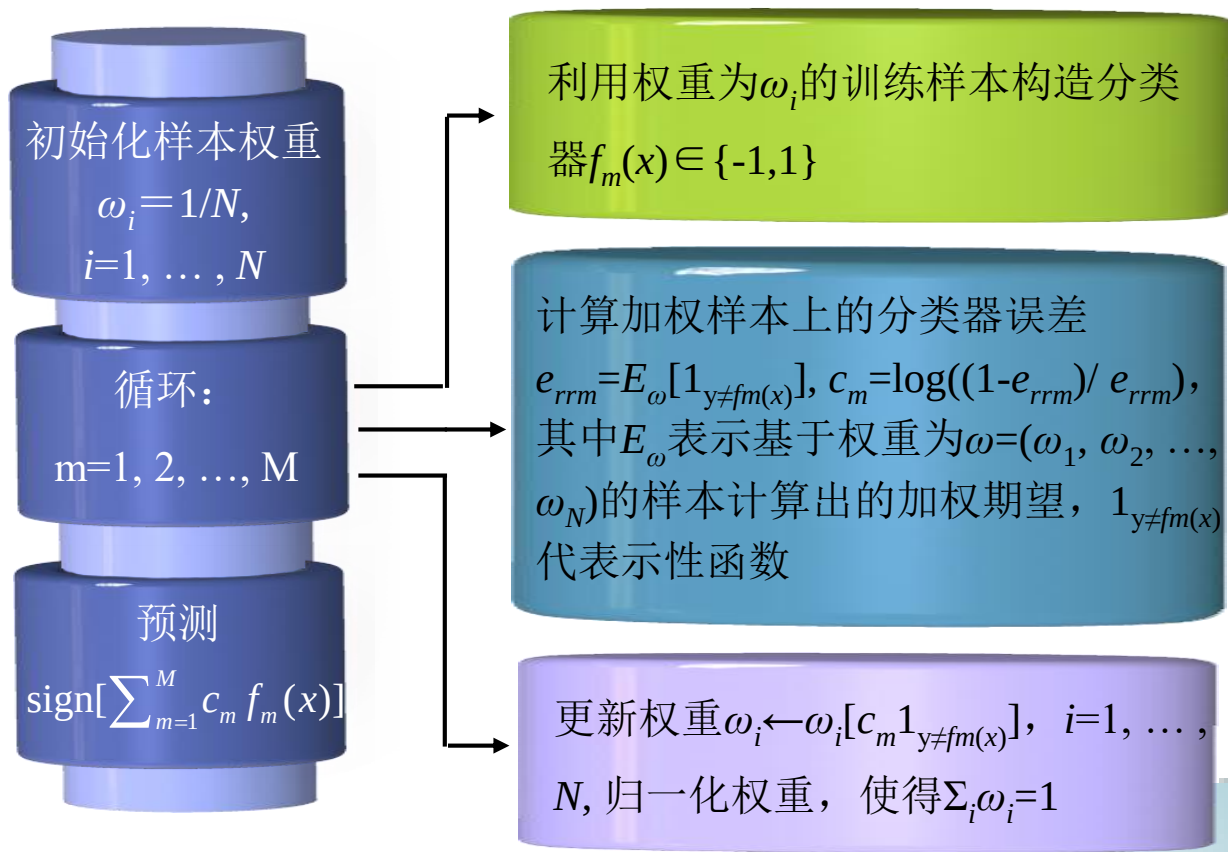
将第一个分类器 f_1 和第二个分类器 f_2 分类结果不一致的样本抽取出来，用于构造第三个分类器 f_3

将分类器 f_1, f_2, f_3 按照投票的方式用于预测


特征提取与分类器

Freund基于加权原理Boost by Majority提出了一种改进的Boosting算法。该算法同时构造多个弱分类器，相较于Schapire提出的原始Boosting算法表现更加出色。


基于该原理，Freund与Schapire在1996年提出了著名的AdaBoost算法，原始版本被称为离散AdaBoost(Discrete AdaBoost)流程如下：



特征提取与分类器



Boost算法用于识别



Boost算法用于目标检测

特征提取与分类器

一个具体的例子

eye-in-hand机器人系统识别流水线上一种特定的工件视觉系统需要判断视野中是否存在该工件，如果有需要给出工件的数量和每个工件的位置

假设我们已经获得了机器人摄像机从各种可能的视角采集到的共 N 个包含目标的图块和 M 个不包含目标的图块。

选定图块中位置为 (i, j) 的像素，由于一共有 $N+M$ 个图块，可以得到 $N+M$ 个像素值，另外每个像素值对应一个标签，如果是目标则标签值等于1，否则等于-1。用这些像素值和相应的标签可以拟合出一个二值函数 $f_1(g) \in \{-1, 1\}$ ，其中 g 为像素值，取值为0到255之间的整数。

特征提取与分类器

得到第一个分类器之后，在样本集中随机选取90%的样本，可以被 $f_1(g)$ 正确分类的样本选中概率比错误分类的低。在选中的样本中，采用类似的方法，取另一个位置的像素值拟合得到第二个分类器 $f_2(g)$ ，假设该分类器的正确率为 E_2 。现在对两个分类器进行联合。假设对于输入样本， $f_1(g)=1$ ， $f_2(g)=-1$ ，那么我们认为样本是目标的可能性大小权值为 $E_1+(1-E_2)=1+E_1f_1(g)+E_2f_2(g)$ ，不是目标的可能性大小为 $(1-E_1)+E_2=1-E_1f_1(g)-E_2f_2(g)$ 。于是得到了一个新的分类器：

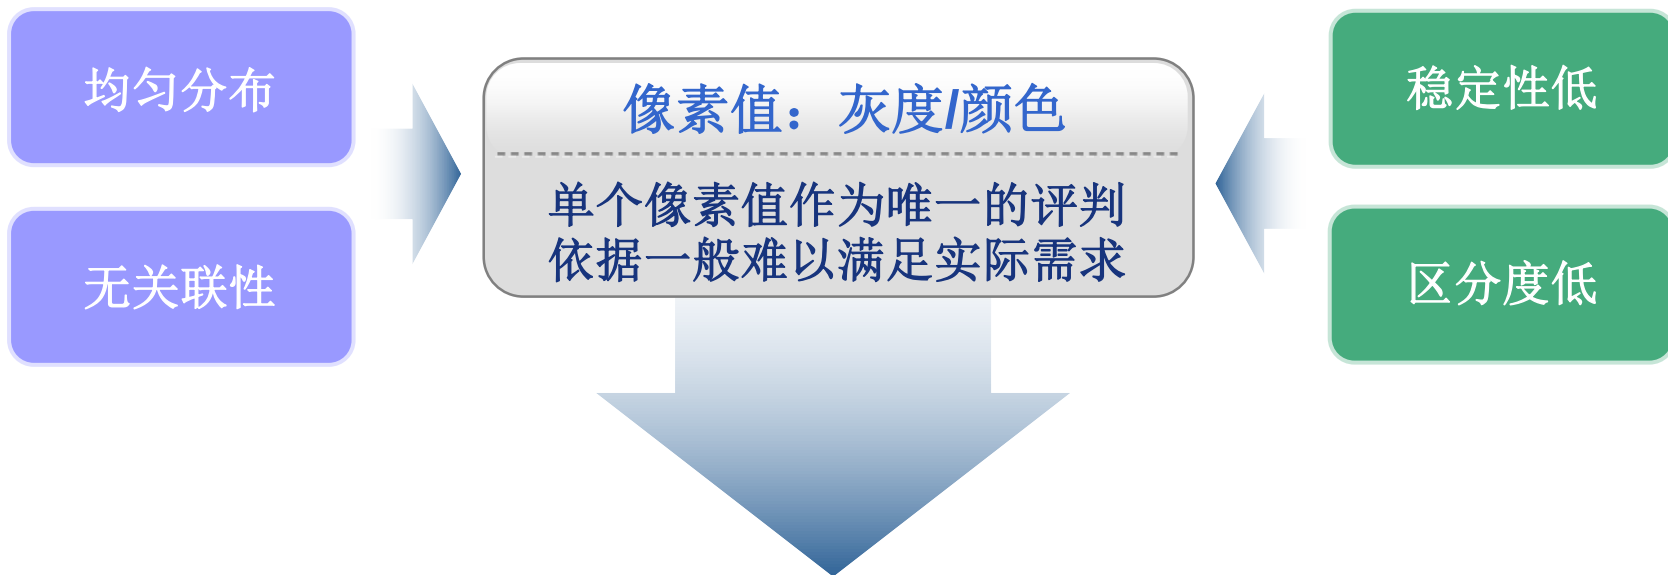
$$f_{12} = \begin{cases} 1 & E_1 f_1(g_1) + E_2 f_2(g_2) \geq -E_1 f_1(g_1) - E_2 f_2(g_2) \\ -1 & E_1 f_1(g_1) + E_2 f_2(g_2) < -E_1 f_1(g_1) - E_2 f_2(g_2) \end{cases}$$

继续上述操作，从样本集中随机选取85%的样本，可以被 f_{12} 正确分类的样本选中概率比错误分类的低。利用这些样本中的某个像素值拟合出第三个分类器。不断重复上述操作，直到得到了 n 个分类器，对它们进行联合，得到强分类器 $f_{1,2,\dots,n}$

$$f_{1,2,\dots,n} = \begin{cases} 1 & \sum_{l=1}^n E_l f_l(g_l) \geq -\sum_{l=1}^n E_l f_l(g_l) \\ -1 & \sum_{l=1}^n E_l f_l(g_l) < -\sum_{l=1}^n E_l f_l(g_l) \end{cases}$$

当机器人在线运行时，对于从采集到的图像中切割出的图块，从指定位置取得像素值，带入到上式就可以得到该区域的目标识别结果。

特征提取与分类器



为了获得更好的分类结果需要进行特征提取，用特征向量代替原始像素值

特征提取与分类器

特征并不是机器视觉领域特有的概念，它是指一个目标不同于其他物体的特性，具有鲜明的统计学意义。用随机变量 T 表示目标是否出现，可以用如下不等式组来表示特征事件

$$P(T=1|F=1) \geq P(F=1|T=0) + D_{thresh}$$

D_{thresh} 区分度

$$P(F=1|T=1) \geq P(T=1|F=0) + S_{thresh}$$

S_{thresh} 稳定性

特征提取与分类器

均值特征质量的计算：用区域的像素均值作为特征。对于非目标区域，我们认为其均值在0到255之间均匀分布。目标平移旋转只会引起均值小幅度波动，不会导致较大变化，例如假设目标区域均值在110到130之间的概率为0.9

$$P(F=1|T=1)=0.9$$

$$P(T=1|F=0)=0.1$$

$$S_{thresh}=0.8$$

$$(130-110)/256=0.078125$$

$$P(F=1|T=0)= 0.078125$$

为了计算 $P(T=1|F=1)$ ，我们需要增加一些变量：

$$P(T=1|F=1)= 0.9M / (0.078125N + 0.821875M)$$

取 $N=100M$ ， $P(T=1|F=1)= 0.104$


$$P(F=1|T=1) \geq P(T=1|F=0) + D_{thresh}$$

$$D_{thresh}=0.004$$

特征提取与分类器

相比于简单的统计指标，对多个像素空间结构进行编码获得的特征具有更好的综合性能指标


LBP（Local Binary Pattern，局部二值模式）是一种用来描述图像局部纹理特征的算子，由T. Ojala, M. Pietikäinen, 和D. Harwood 在1994



所谓算子，是指一种给定的操作步骤。

特征提取与分类器



Ojala等对 LBP 算子进行了改进，将 3×3 邻域扩展到任意邻域，并用圆形邻域代替了正方形邻域




不同半径的圆形LBP算子采样方式示意图

特征提取与分类器

哈尔特征 (Haar)
Papageorgiou等人





图像。由





特征提取与分类器

HOG特征是英文Histogram of Oriented Gradient的缩写，即梯度直方图。其主要思想是目标的表象和形状一般都可以被边缘信息很好的描述，而梯度的统计数据可以较好的反应边缘信息。该特征最早由Navneet Dalal和Bill Triggs于2005年提出





特征提取与分类器




• 分类超平面/超曲面


二值结果




特征提取与分类器



支持向量机 (SVM)



核方法将二维点
投射到三维



核方法

章节安排



检测、识别与测量



图像分割与目标分割



初探目标识别：模板匹配




特征提取与分类器



深度学习简介

深度学习简介

这种称呼源自最优化领域的启发式算法(heuristic algorithm)
启发式算法是相对于最优化算法提出的



深度学习简介

设定优化指标:

D_{thresh} 与 S_{thresh} 只能用作定性的评价，但很难构建出可以解析的目标函数

两个客观且可以定量的指标可以
较为全面地评价编码的质量

一是编码结果
的数据长度

特征，在数据上体现为
具有给定长度的码值，
而特征提取过程可以理解
为对输入图像的编码

二是编码过程中信
息量的丢失程度

100维度降成3维还原为100维

深度学习简介

实际上，研究人员很早就发现自然图像的各像素值间具有高度的相关性，理论上近似无损的降维可以具有很高的压缩比

图像数据虽然具有很高的相关性，但同时也存在各种非线性因素，利用线性优化的方法往往无法得到令人满意的效果

字典学
编码、
机、多



www.sciencemag.org/cgi/content/full/313/5786/504/DC1

Supporting Online Material for



Reducing the Dimensionality of Data with Neural Networks

G. E. Hinton* and R. R. Salakhutdinov


*To whom correspondence should be addressed. E-mail: hinton@cs.toronto.edu

Published 28 July 2006, *Science* **313**, 504 (2006)
DOI: 10.1126/science.1127647

深度学习简介



PCA



栈式自编码器

级联的受限玻尔兹曼机对输入图像进行逐层处理，最后将高维的图像数据近似无损的压缩为很低维度，2000维人脸数据压成30维，724维手写体数字压成6维

深度学习简介



多层神经网络并不是创新的工作，从神经网络被设计出来起就没有人限制其层数关键的创新点在于对这种**多层结构的训练方式**




这种训练方式的成功使得学者们认识到可以用多层结构分层次提取图像特征，随着层级的升高，特征越来越抽象，越来越具有全局性

Hinton提出的分层自编码训练，然后进行输入到输出端微调的方式使得多层神经网络的训练成为可能

深度学习简介


以卷积网络（Convolutional Neural Network, CNN）为代表的深度学习技术于是应运而生了。




卷积层利用卷积核与输入信息进行卷积运算，得到的结果被称为特征图

池化层对特征图进行池化操作，该操作在特征图中的每个通道中独立完成，类似一种降采样操作

深度学习简介



六个单通道的卷积核将3通道输入映射为6通道输出



两个3通道的卷积核将3通道输入映射为2通道输出

深度学习简介

2014年，Girshick等人提出R-CNN法（Region Convolutional Neural Network）算法在CNN网络的基础上增加了选择性搜索操作来确定候选区域

2014年，针对R-CNN中的问题，He等人提出了SPP-Net算法，减少了图片归一化的过程，解决了图片信息丢失以及存储的问题

2015年，Girshick提出了Fast R-CNN算法，该算法引用了感兴趣区域（Region of Interest）以及多任务损失函数方法

2015年，Redmon J 提出了YOLO算法，该算法可以一次性地识别图片内多个物品的类别和位置，实现了端到端的图像识别。

2015年，Liu W 提出了SSD算法，该算法是一种直接预测目标类别的多目标检测算法。


深度学习简介

全卷积网络与卷积网络的卷积层具有相同的结构。对于标准的卷积层，其输入数据一般被描述为一个 $h \times w \times d$ 的数组。在物理意义上，这个数组可以理解为一个 $h \times w$ 的特征图，特征图的每个像素是一个 d 维的特征向量。通过一些特征图边框处理的技术，卷积层输出一个大小与输入相同的特征图。用 $\mathbf{x}_{ij}$ 表示输入特征图上位置 (i, j) 处的向量，输出特征图位置 (i, j) 处的向量 $\mathbf{y}_{ij}$ 的计算公式如下：

$$\mathbf{y}_{ij} = f_{ks} (\{\mathbf{x}_{si+\delta i, sj+\delta j}\}_{0 \leq \delta i, \delta j \leq k})$$


上采样和反卷积：与池化和间隔卷积相反，上采样和反卷积层可以得到比输入特征图尺寸大的输出特征图。所谓上采样层比较简单，实际就是复制或插值操作。例如将输入特征图的每个像素扩大为一个 3×3 的区域，每个像素都是该像素的复制

深度学习简介



卷积网络滑窗过程产生的热力图，温度越高表示目标概率越大


深度学习简介




深度学习简介（移动机器人）



服务机器人避障







视频监控



自动驾驶

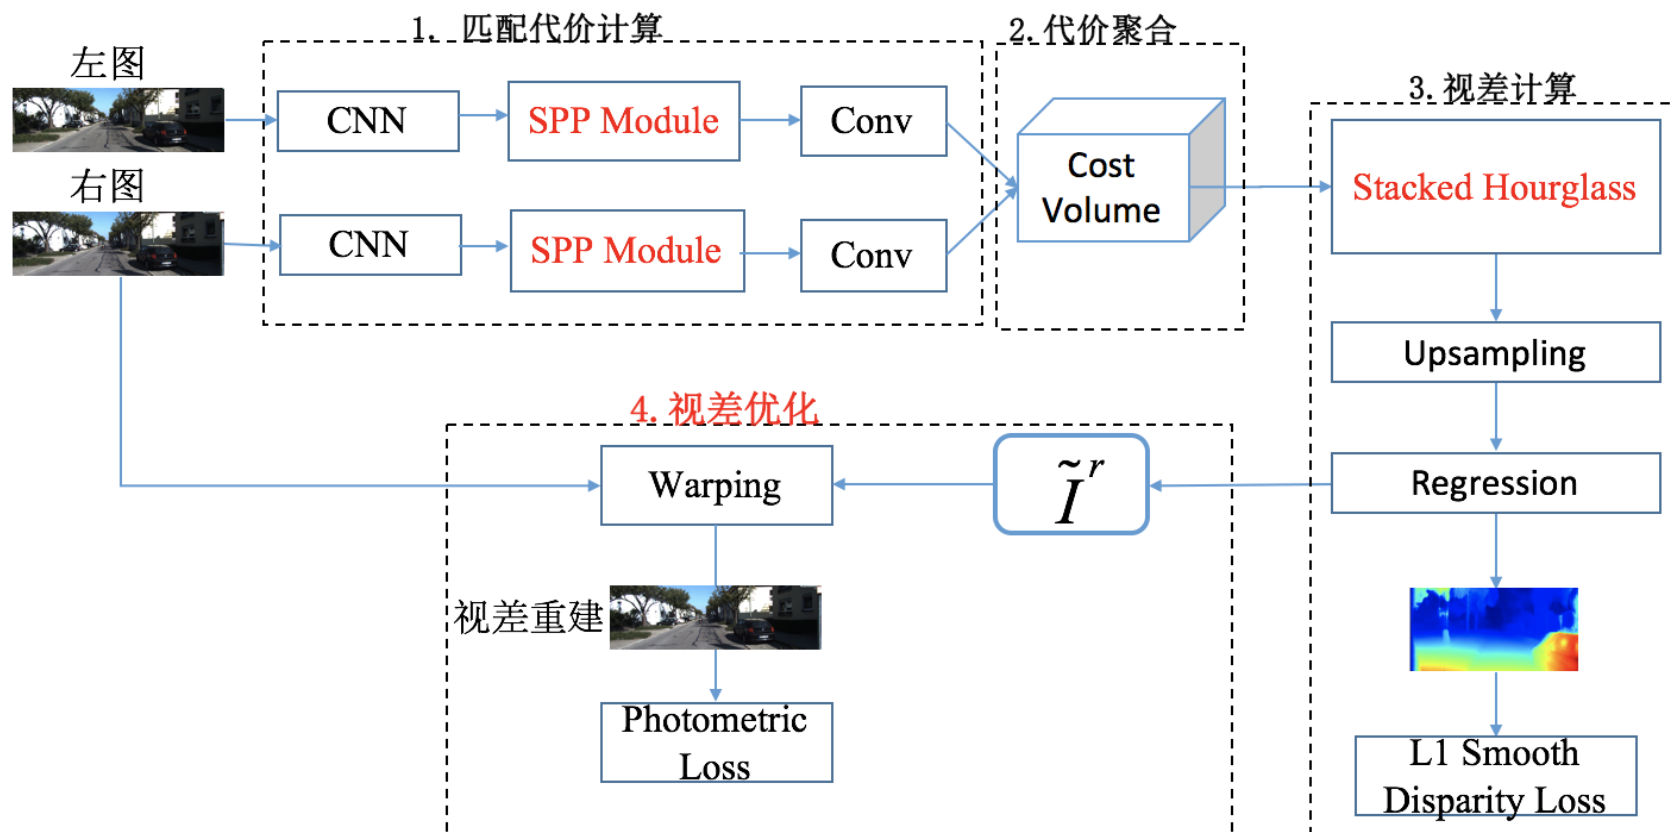


深度学习简介（移动机器人）



三维重建


深度学习简介（移动机器人）



针对多尺度视差的双目立体匹配算法框架


深度学习简介（移动机器人）

1. 匹配代价计算过程中的金字塔池化结构 (SPP-Module)



金字塔池化结构

4. 视差计算过程中的层级卷积网络 (Stacked hourglass CNN)



层级卷积网络

➤ 平滑损失函数:

$$\hat{d} = \sum_{d=0}^{D_{\max}} d \times \sigma(-d_d)$$

$$L_d = \frac{1}{N} \sum_{i=1}^N \text{smooth}_{L_1}(d_i - \hat{d}_i)$$

➤ 视差重建损失函数:

$$L_p = \frac{1}{N} \sum_{i,j} \delta_{i,j}^p \left\| \tilde{I}_{i,j}^r - I_{i,j}^r \right\|_1$$

$$L_s = \frac{1}{N} \sum_{I,j} \rho_s \left\| \partial D_{ij}^x + \partial D_{ij}^y \right\|_1$$

深度学习简介（移动机器人）



左目图像




右目图像



较大误差点(红色点)投影至真值图的局部放大图




预测深度



真值深度



较大误差点(红色点)投影至原图的局部放大图



左目图像



右目图像



预测深度



真值深度

深度学习简介（移动机器人）



RGB图

真值图



预测图

RGB图

真值图

预测图

深度学习简介（移动机器人）



➤ 结构一致性损失:
$$C_{ap}^l = \frac{1}{N} \sum_{i,j} \left(\alpha \frac{1 - \text{SSIM}(I_{ij}^l, \tilde{I}_{ij}^l)}{2} + (1 - \alpha) \|I_{ij}^l - \tilde{I}_{ij}^l\|_2^2 \right)$$

➤ 左右视差一致性损失:
$$C_{lr}^l = \frac{1}{N} \sum_{i,j} \|d_{ij}^l - d_{ij+d_{ij}^l}^r\|_1$$

➤ 视差连续性损失:
$$C_{ds}^l = \frac{1}{N} \sum_{i,j} \left[\|\nabla_x d_{ij}^l\|_1 \exp(-\|\nabla_x I_{ij}^l\|_2^2) + \|\nabla_y d_{ij}^l\|_1 \exp(-\|\nabla_y I_{ij}^l\|_2^2) \right]$$

基于Encoder-Decoder的单目深度估计框架

深度学习简介（移动机器人）


关键帧	像素点	网络输出 深度值(m)	尺度校正参数	优化后 深度值	深度真值(m)	优化后 误差
10.png	(167.12, 788.03)	239.27	(4.76, -0.18)	47.93	48.53	0.012
39.png	(192.01, 938.60)	139.43	(4.74, -0.18)	31.95	30.66	0.042
98.png	(148.97, 498.12)	400.04	(5.18, -0.36)	27.38	26.96	0.016
114.png	(153.32, 401.26)	438.93	(5.52, -0.28)	63.91	64.34	0.0067
145.png	(144.28, 56.24)	364.73	(4.89, -0.25)	20.18	20.57	0.019
172.png	(153.66, 468.45)	445.05	(4.92, -0.24)	63.91	72.36	0.117
207.png	(152.78, 386.42)	437.89	(5.19, -0.32)	54.78	54.99	0.0038
287.png	(284.24, 910.86)	50.96	(5.17, -0.22)	11.98	12.19	0.016

网络的原始深度输出

深度学习简介（移动机器人）



原图



网络输出的深度图



优化后的深度图

深度融合优化前后的细节展示


深度学习简介（移动机器人）



原图

网络输出的深度图

融合优化后的深度图



连续深度图融合成的
三维点云图