

《现代控制理论》课程大作业

——人形机器人运动控制实验报告

李昭阳 202518014628084

声明：

本实验报告所述工作基于本人正在开展的研究成果。鉴于相关研究内容涉及未公开的核心技术与保密事项，完整代码不便公开提交，仅随报告提交部分已开源代码；对核心算法的具体实现细节，报告中进行了必要的抽象与模糊处理。

本人郑重承诺，报告中所呈现的实验过程、实验结果及实验视频均真实可靠，并对其正确性与可复现性承担相应责任。

第 1 章 控制任务场景综述

1.1 控制任务背景和意义

人类的运动能力涵盖了广泛的范围^[1]，拥有适应各种任务所需的不同步态，例如站立、行走、快步走、小跑、奔跑和跳跃^[2]，这种适应性使人类能够在广泛的动作范围中表现出卓越的灵活性和机动性。人类生活中的环境主要为双足行走而设计，其丰富多样性使得人形机器人领域的总体目标是开发能够在这些环境中可靠运行的机器人。基于以上观点，进一步探讨人形机器人及人类步态行为。

1.1.1 人形机器人

人形机器人（Humanoid Robot）通常是指在外形和功能特征上模仿人类的机器人系统，其最显著的结构特征包括一个躯干、两条手臂和两条腿，部分系统还具备头部或拟人化的面部结构^[3]。尽管如此，人形机器人在具体实现上仍存在较大差异，尤其在末端执行器和下肢驱动形式方面。例如，一些人形机器人采用结构简化的手部设计，仅具备有限的抓取与操作能力；另有一些系统在腿部使用轮式驱动以简化运动控制并提高地面适应性^[4]，这类设计在一定程度上牺牲了类人性，但换来了较高的运动稳定性与能效比。



图 1.1 宇树科技 H1（左）、G1（右）型号人形机器人

近年来，随着控制算法、驱动技术、材料科学和人工智能的快速发展，人形机器人研究进入加速阶段，成为机器人学和智能系统领域的研究热点。多个知名科研机构与企业陆续发布了一系列具有代表性的研究成果和产品，推动了该领域

技术的持续演进。波士顿动力公司推出的 Atlas 机器人具备强大的动态运动能力，其完成跳跃、翻滚与复杂跑酷动作的演示，展示了当前人形机器人在运动控制方面的最高水平。Tesla 公司推出的 Optimus 机器人^[5]，以及 Figure 公司的类人机器人^[6]，则尝试通过模仿人类行为数据实现桌面操作、物体搬运等复杂任务的自主执行，在具身智能与任务学习领域提供了新的范式。

同时，研究型双足机器人 Cassie^[6-8]及其人形版本 Digit^[7]，以其模块化设计与高自由度电机驱动系统，在多种复杂地形上实现了稳定行走，为灵巧性与环境适应性提供了兼顾的解决方案。中国机器人企业 Unitree Robotics 也相继推出了 H1 和 G1 两款人形机器人^[8]，其紧凑化设计和良好的性价比受到业界广泛关注（如图1.1所示）。Apptronik 公司推出了 Apollo 机器人，其采用全推杆电机驱动系统^[9]，致力于在动力性能与控制精度之间寻求平衡。同时，人工智能领先企业 OpenAI 在收购 1X 公司^[10]后，进一步推动了具身智能的研究计划，探索如何将通用人工智能模型嵌入人形机器人平台，实现感知—决策—控制的闭环系统^[11]。

综上所述，人形机器人正在成为连接人工智能算法与实际物理系统的重要桥梁。通过在结构设计、传感融合、智能控制以及任务学习等方面的持续探索，该领域有望加速推动智能体从虚拟空间向现实世界迁移，进而为多类应用场景提供更为普适且高效的解决方案。掌握人形机器人核心技术已成为未来人工智能硬件化、实体智能系统落地的突破口。

1.1.2 人类步态行为

人体下肢骨干主要包括髋关节、股骨、膝关节、胫骨与腓骨、踝关节和足，其中以髋、膝、踝三个关节提供主要自由度，骨干之间又由腹肌、椎旁肌、四头肌、腿筋肌、胫骨肌与腓肠肌等肌群相互连接^[12]（如图1.2）。肌肉、骨骼、关节三者相互协调，进而形成了复杂的运动行为。

人体下肢肌肉骨骼结构复杂，将其抽象为简化模型更利于研究。鉴于人体步态变化主要集中在行走方向（矢状面）的偏航角变化，研究者最初将踝关节和膝关节抽象为单轴铰，胫骨和股骨抽象为连杆，构建了经典的二维双摆模型。然而，二维模型无法提供翻滚和俯仰方向的信息，难以满足精确三维研究的需求。因此，在三维情况下，通常将双腿建模为多刚体模型，即将二维单轴铰链替换为多轴铰，二维连杆替换为刚性柱。随着计算机技术的发展以及对肌肉特性研究的不断深入，下肢模型逐渐完善，出现了模拟肌肉、韧带等的多连杆结构，同时也有考虑肌肉疲劳效应的特性模型。




图 1.2 人体下肢主要肌肉、骨骼、关节示意图





图 1.3 人体步行周期示意图



步行关节力矩（左上）、跑步关节力矩（右上）、步行关节角（左下）、跑步关节角（右下）

图 1.4 人类步态参数研究

对人体运动步态的研究可追溯至 1836 年。研究者普遍认为，正常步态具有明显的周期性特征。步行周期是指一侧足跟着地至该侧足跟再次着地的完整过程，其可进一步细分为支撑相和摆动相。如图1.3所示，支撑相是指脚接触地面并承受躯干重力的阶段，通常占步行周期的 60% 左右，又可分为单脚支撑相和双脚支撑相。步行速度与双脚支撑相的时间呈反比关系。摆动相则是指脚离开地面向前迈步直至再次落地的阶段，约占步行周期的 40%。对于单脚而言，在一个完整的步行周期中，会依次经历初接触、足底水平、重心转移、足跟抬起、足尖抬起、摆动至胫骨垂直地面以及再次接触等七个阶段。

在研究人类步态时，通常测量相关运动学和动力学参数。运动学参数包括周期时间、单步时间、占空比、步长、步宽、足夹角等；动力学参数包括关节力矩、下肢重心加速度、肌群活动肌电图等。例如，Winter 等人^[13]运用标准的连杆段动力学程序计算各关节力矩，研究绘制了青年男性行走和奔跑时，髋、膝、踝关节的力矩变化曲线如图1.4。Nilsson 等人^[14]使用 Selspot 光电系统检测记录了青年男性行走和奔跑步态的下肢关节角变化曲线如图1.4，揭示了肌肉活动与关节的运动关系。

人类的步态行为是一种高度优化的生物力学过程，由神经、骨骼、肌肉协调共同完成，在复杂多样的环境中展示出了极高的适应性，例如能在光滑、粗糙平面、斜面或楼梯上稳定行走。通过研究人类的步态行为，特别是总结出共性理论、抽象出简化模型，可以揭示双足生物运动的基本原理。将这些原理应用到人形机器人的设计中，可以开发出更精准有效的运动算法和控制策略。

综上所述，研究人形机器人相关步态规划算法能够提高人形机器人的操作潜力，拓展人形机器人的应用场景，使其能够胜任复杂地形和极端环境下的作业任务，同时在工业生产、农业作业以及室内外服务等多场景中发挥重要作用。

1.2 主要研究内容

本研究围绕人形机器人在复杂环境下的多地形步态规划问题展开。多地形步态规划是双足机器人研究领域中的核心难题之一，其目标在于使人形机器人能够在多种典型地形条件下实现稳定、连续且具有鲁棒性的行走运动。研究所涉及的地形类型包括但不限于平坦地面、起伏不平的崎岖地面、斜坡以及台阶等非结构化或半结构化环境。

针对上述问题，当前人形机器人行走控制方法主要可分为基于模型的优化控

制方法与基于数据驱动的强化学习控制方法两大类。基于模型的优化控制方法通常依赖于精确的动力学建模及约束条件描述，并需要预先规划高质量的参考轨迹，因此在面对复杂地形、不确定扰动或模型参数偏差时，其适应性和鲁棒性往往受到限制。相比之下，强化学习方法通过与环境的交互进行策略学习，能够在一定程度上摆脱对精确模型和人工轨迹设计的依赖，在复杂地形和未知环境中展现出更强的自适应能力与泛化性能。

本研究聚焦于多地形步态生成问题，探索基于强化学习的人形机器人多地形行走策略建模方法。通过构建统一的多地形训练与评估框架，使机器人能够在不同地形条件下学习具备环境适应能力的步态策略，从而实现跨地形的稳定行走。相关研究成果不仅可为多任务强化学习和策略迁移问题提供重要的理论依据和方法参考，也有助于提升人形机器人在真实应用场景中的环境适应性与运动性能。

总体而言，深入开展人形机器人多地形步态规划研究，对于推动机器人在复杂环境中的自主运动能力具有重要意义。该研究有望为人形机器人在救援、巡检、服务及工业等实际应用场景中的部署提供关键技术支撑，并为人形机器人运动控制领域的进一步发展奠定基础。

第 2 章 人形机器人的仿真系统搭建

本章主要探讨人形机器人的仿真系统搭建，旨在为后续的多地形行走策略研究提供可靠的仿真平台。通过复现基于单阶段 PPO 算法的训练环境，并结合 NVIDIA Isaac Gym 平台的高性能特性，构建了包含多样化地形和动态交互特征的仿真系统。本章详细介绍了仿真系统的架构设计、环境构建、仿真对象的建模与控制策略的初步设计，并探讨了域随机化技术在提升策略泛化能力中的应用。通过这些研究内容，本章旨在为后续章节中人形机器人多地形行走策略的优化与验证奠定坚实的基础。

2.1 仿真系统基础架构

在解决人形机器人多地形行走问题之前，本研究基于 RobotEra 开源项目^[15]，复现了使用单阶段 PPO 算法解决人形机器人行走问题的训练环境。其系统流程如图2.1。




图 2.1 单阶段 PPO 强化学习方法训练环境流程图

系统的各组成部分包括如下三个模块：

- **Simulator 1**：用于强化学习训练过程的仿真平台，构建训练环境。
- **Simulator 2**：用于策略验证与性能评估的独立仿真测试平台。

- **Robot:** 目标部署平台，为实际机器人系统，用于检验强化策略的最终效果。

该系统旨在克服仿真-真实差距，实现策略从仿真到真实机器人的迁移部署，其操作流程如下：

1. 为了实现真实-仿真映射，对真实机器人 **Robot** 进行了建模，导入其相关结构描述文件，并在 **Simulator 2** 中构建性能评估的测试环境。
2. 同样基于上述模型信息，在 **Simulator 1** 中构建用于训练的仿真场景。
3. 在完成训练后，将 **Simulator 1** 中获得的策略应用至 **Simulator 2** 中进行验证测试，确认策略在不同仿真环境中的表现一致性。
4. 若策略在测试仿真中表现可靠，则可进一步迁移至真实机器人平台，检验其在现实环境下的实际效果，即实现仿真-真实映射。

该系统的核心优势在于通过分阶段的仿真模拟部署，提高策略从虚拟环境到真实平台的泛化能力，其具体优点包括：

- 借助多样化的仿真环境进行策略验证，可提升模型在复杂或未见环境下的适应能力，降低模型对单一仿真场景的依赖，增强其在现实世界的鲁棒性。
- 通过在不同模拟器中对环境参数（如物理特性微调等）进行系统性测试，可深入分析环境不确定性对策略性能的影响，为实际部署前的策略稳定性提供理论支持。
- 相较于直接在真实机器人上进行试验，仿真平台具备更高的安全性与低成本特征，有助于在风险可控的前提下进行多轮优化与调试。

由于本研究不具备进行真实机器人策略迁移的条件，不涉及 **sim-to-real** 验证，训练和测试集中于机器人在 **simulator 1** 中的表现，但系统架构保留了相关接口以便于后续进一步研究。

2.2 仿真环境构建

本研究中的强化学习训练环境构建依托于 **NVIDIA** 推出的高性能仿真平台 **IsaacGym**^[16]，其具备全流程 **GPU** 加速特性，能够在保持高仿真精度的前提下显著提升训练效率。由于步态规划涉及多种地形适应与稳定控制策略的学习，通常需要海量的交互数据与长时间的训练过程，而 **IsaacGym** 的全 **GPU** 架构使得环境的并行化成为可能，从而允许在单次迭代中并发运行成千上万个环境实例，极大提升了样本生成速率与策略收敛速度。在物理建模方面，该平台集成的物理引擎能够细致还原机器人在多种复杂地形上行走时的动力学响应与接触力变化，确保





图 2.2 宇树 G1 机器人在平坦地形上训练



障碍物地形（上左）、离散崎岖地形（上右）、坡地地形（中）、台阶地形（下）

图 2.3 复杂训练环境地形示意图

了训练过程中所获得策略具备良好的现实可迁移性和鲁棒性，为多地形步态生成提供了可靠的仿真基础。

为了支持控制策略的网络训练，本研究在仿真系统中构建了多样化的行走环境，以充分模拟现实中可能出现的各种地形变化及其对机器人运动控制带来的挑战。本研究将行走环境划分为基础环境与复杂环境两类。其中，基础环境指代无障碍的平坦地形如图2.2所示，该类地形具有结构规则、表面连续的特点，主要用于训练机器人在理想条件下的基本稳定性与共性行走策略。而复杂环境则包括带有障碍物的地形、离散崎岖地形、坡地以及台阶等如图2.3所示，这些环境因地形结构不规则、接触面变化剧烈或存在高度差异，对人形机器人的动态平衡控制与足端落点策略提出了更高要求。

具体而言，障碍物地形通常包含若干固定或随机分布的立体障碍，机器人需具备应对突发地形干扰的躯干姿态调整能力，维持前进稳定性；离散崎岖地形由非连续接触面组成，考验机器人在不确定支撑条件下的动态稳定性与步态调整策略；坡地带来额外的重力分量投影变化，对机器人前向推进力与躯干俯仰控制形成挑战；而台阶地形则具有显著的高度突变，要求机器人能够准确感知落脚点位置，并在执行抬腿与落脚动作时确保重心转移的连贯性与安全性。

为进一步提升环境多样性与任务挑战性，仿真过程中对地形参数、初始状态扰动及外部干扰力进行了随机化设计。例如，在复杂地形中引入随机高度障碍、变化坡度角以及不规则布设的离散支撑面，模拟现实中地形不确定性对步态稳定性的冲击。同时，通过添加随机外力干扰，增强了训练策略对扰动的鲁棒性，有助于获得更具泛化能力的控制策略。这些机制共同构建了一个具备丰富动态交互特征的训练环境，为后续人形机器人多地形自适应行走策略的学习提供了坚实基础。

2.3 仿真对象构建

本研究选用由 Unitree Robotics 公司推出的 G1 人形机器人作为仿真对象，其具备高度集成的结构设计与较强的运动能力，适用于多种人形机器人步态规划与控制算法的验证。G1 机器人采用全身 17 自由度配置，其中双腿各具备 6 自由度，双臂各具备 3 自由度，另包含 1 个腰部自由度，具有人体对称的运动结构。该结构不仅能覆盖大多数人形机器人在行走、起伏和转向中的运动需求，也为本研究中基于本体感觉的步态规划算法提供了充分的动作空间。

G1 的整机高度为 1.27 m，自重约 47 kg，具备较高的动力输出能力：单关节峰值扭矩达到了 360 N·m，关节最大速度可达 40 rad/s，驱动采用高性能无刷电机搭配高精度谐波减速器。为了实现仿真中精确的运动建模与控制策略部署，本研究基于其官方公开的完整的 URDF 模型，搭建了强化学习仿真对象。

在步态规划过程中，足端轨迹的规划通常基于正运动学模型完成。通过正运动学可由关节空间变量映射得到末端在三维空间中的位置，从而实现足端轨迹跟踪，进而分析步态特征。设腿部关节角向量为 $\theta \in \mathbb{R}^6$ ，对应的足端位置可表示为：

$$\mathbf{p}_{\text{foot}} = f(\theta), \quad (2.1)$$

其中 $f(\cdot)$ 为正运动学函数，通常由一系列刚体变换矩阵组成。具体地，对每个关节使用齐次变换矩阵 $\mathbf{T}_i$ 表示，从髋部坐标系出发，足端在世界坐标系中的位置可通过链式乘积获得：

$$\mathbf{T}_{\text{foot}} = \prod_{i=1}^6 \mathbf{T}_i(\theta_i), \quad \mathbf{p}_{\text{foot}} = \mathbf{T}_{\text{foot}}(1 : 3, 4). \quad (2.2)$$

本研究构建了具备地形感知能力的人形机器人运动策略，采用两阶段强化学习方法训练控制器。每一阶段的强化学习问题均可建模为马尔可夫决策过程 (MDP)，形式化表示为 $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, r, \gamma \rangle$ ，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别表示状态空间与动作空间， $T(s' | s, a)$ 为状态转移概率函数， $r(s, a)$ 为奖励函数， $\gamma \in [0, 1]$ 为折扣因子。训练的目标是通过策略 $\pi(a_t | s_t)$ 最大化累积折扣回报，其定义如下：

$$\max_{\pi} J(\mathcal{M}, \pi) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right]. \quad (2.3)$$

考虑到实际机器人在感知层面存在一定的局限性，例如控制噪声、信息延迟以及观测缺失等问题，尽管在仿真环境中可以获取系统的完整状态信息，本研究在策略训练过程中，将每阶段任务进一步建模为部分可观测马尔可夫决策过程 (POMDP)，即训练过程中仿真对象仅基于部分观测量（如关节状态、足端接触信息等）进行决策，以更贴合真实系统的感知特性。这种建模方式不仅提高了策略对复杂地形和干扰的适应能力，也增强了其在现实机器人控制中的稳定性和实用性。

2.3.1 动作空间

为实现对人形机器人仿真对象关节运动的精细控制，本研究将控制策略的输出定义为关节角度相对于一组预设中性姿态的偏置量。中性姿态下各关节角度值

组成的向量称为初始关节配置，用于在动作输入为零时生成目标姿态。该配置涵盖了双腿的 12 个主要关节，具体数值如下：

$$q_{\text{init}} = \begin{bmatrix} 0, & 0, & -0.1, & 0.3, & -0.2, & 0, & 0, & 0, & -0.1, & 0.3, & -0.2, & 0 \end{bmatrix}^T$$

上述角度值依次对应左腿与右腿的：髋关节水平旋转（yaw）、髋关节侧向摆动（roll）、髋关节前后摆动（pitch）、膝关节、踝关节前后俯仰（pitch）以及踝关节侧向翻转（roll）六个自由度。

动作空间中每一个维度表示对对应关节角度的偏移量，其值域被约束在 $[-1, 1]$ rad 范围内，从而构成一个 12 维的动作向量 $a \in \mathbb{R}^{12}$ 。机器人在每个控制周期的期望关节角位置由以下公式计算：

$$\hat{q} = q_{\text{ref}} + \Delta q_{\text{act}}, \quad (2.4)$$

该期望角度被输入至式2.5表示的 PD 控制器，计算产生所需关节力矩并发送至仿真环境电机，实现精确的姿态调整。其中 K_p 和 K_d 是比例-微分控制参数对角矩阵。

$$\tau = K_p(\hat{q} - q) + K_d(\dot{\hat{q}} - \dot{q}) \quad (2.5)$$

值得指出的是，本文选择基于角度偏置进行策略输出而非直接预测绝对角度，其优点主要包括：

- 相较于直接学习绝对角度，学习相对偏移量能够显著降低策略搜索空间，有助于提升训练效率；
- 该表示形式具备更强的通用性与可迁移性，在不同机器人模型或任务环境之间迁移时，能保留原始姿态结构，仅需对偏置部分进行微调；
- 当前初始关节配置已接近静态稳定结构，因此仅需在此基础上施加微小调整以实现多样化动作，从而简化策略的学习目标。

该设计理念在近年来的多个研究工作中得到了验证，并已被广泛应用于人形机器人控制策略的构建中，具有良好的实用性与泛化能力。

2.3.2 状态空间

本研究中，状态空间的设计旨在为策略网络提供充分但不冗余的自身运动状态信息，从而支持其在多样环境中的鲁棒性与泛化能力。整体状态空间由 47 个维度构成，涵盖了机器人底座的角速度、重力方向投影、期望控制指令、关节状态、历史动作以及周期相位信息，具体变量构成详见表2.1。

该状态空间在构建过程中充分权衡了可观测性、系统稳定性与实际部署的可

实现性。通过引入关键变量如底座角速度、关节状态及历史动作输入等，使策略具备应对复杂动态变化的能力；同时，周期相位信息有助于策略在处理周期性任务（如步态控制）时保持时间一致性和结构性表达。

此外，为增强策略在不同仿真环境及未来真实系统中的迁移能力，Actor 状态空间中刻意排除了某些在现实中难以准确获取的观测量（例如高频接触力），仅保留了跨平台均可稳定感知的核心指标。但如表2.1所示，本研究为 Critic 模型引入了额外的特权信息，包括推力扰动、扫描高度图等。这些信息在模拟环境中可轻松获取，因而被用于辅助 Critic 的训练，以提升整体训练效率与策略收敛速度。

表 2.1 状态空间各组成变量

状态组件	维度	Actor 可见	Critic 可见
周期相位	2	✓	✓
控制命令	3	✓	✓
角速度	3	✓	✓
重力方向投影	3	✓	✓
关节角度偏差	12	✓	✓
关节速度	12	✓	✓
历史动作输入	12	✓	✓
摩擦系数	1		✓
即时奖励值	1		✓
足端接触状态	2		✓
底座线速度	3		✓
推力扰动	6		✓
电机输出力矩	12		✓

综上所述，Actor 网络所使用的状态空间在信息量与可实现性之间取得了良好平衡，而 Critic 模型则通过引入特权信息进一步增强了对任务结构的建模能力，从而提升了整体训练过程的效率与策略性能。

2.3.3 域随机化

域随机化技术在解决仿真与现实之间的迁移偏差问题上表现出显著成效，尤其在基于强化学习的人形机器人控制策略中展现了强大的适应能力。该方法通过在仿真环境中引入具有代表性的随机变量，在训练阶段主动模拟现实环境中的各

种不确定性，从而提升策略在复杂、动态且不可预知的真实场景中的泛化能力。借助强化学习无模型的优势以及神经网络的强表达能力，只要仿真中引入的随机扰动在分布上能够覆盖或接近现实环境的变化范围，便可在无需对真实系统精确建模的前提下，获得鲁棒性较强的控制策略。

在人形机器人控制任务中，由于系统结构复杂、控制精度要求高，策略能否成功迁移往往依赖于域随机化设计的合理性与全面性。为此，本研究在训练过程中对一系列关键因素进行了系统性的扰动处理，涵盖了躯干状态观测误差、观测与执行时延、质心偏移、重力加速度、地面摩擦系数和弹性系数等物理环境属性。上述参数均在每轮训练初始化及仿真对象失败重置时重新采样，并在每一轮完整的探索过程中保持不变，以确保策略在多样化训练环境中的一致性与稳定性。表2.2详述了各随机化参数的取值范围及实施方式。

表 2.2 域随机化相关参数设定

参数名称	理论值	施加方式	范围	分布
组件质量	各组件固定质量	比例	$[-5.0, 5.0]$	均匀
摩擦系数	0.8	比例	$[0.1, 2.0]$	均匀
质心偏移	0.0	叠加	$[-0.05, 0.05]$	均匀
控制时延	0.0	叠加	$[5, 40]$	均匀
动作延迟	0.0	叠加	$[0.0, 0.5]$	均匀
动作噪声	0.0	叠加	$[0.00, 0.02]$	均匀
外力干扰	0.0	叠加	$[-15.0, 15.0]$	均匀

2.3.4 其他设置

初始状态：理想的初始状态为机器人关节处于如节2.3.1中所述基准姿态，然而，考虑到实际应用中初始条件通常具有不可预知性与高度变异性，为提升仿真对象在复杂现实环境中的泛化能力，本研究在初始状态生成过程中引入了随机扰动机制。具体而言，在初始关节角位置上施加服从均匀分布 $U(-1, 1)$ 的扰动，同时在初始关节角速度上引入服从 $U(-0.5, 0.5)$ 的随机扰动。此种初始状态的随机化处理有助于增强仿真对象对状态空间多样性的探索能力，避免其训练过程局限于固定或有限的状态区域。例如，仿真对象可能从部分与地面接触或完全悬空的状态启动，从而促进其学习如何在复杂初始条件下实现稳定着地与动态平衡的能力。

第 3 章 基于强化学习的人形机器人控制方法

3.1 强化学习算法简述

强化学习是一种通过智能体与环境交互来学习最优行为策略的机器学习方法。智能体通过在环境中采取行动，以最大化累积奖励为目标，根据环境反馈的奖励来调整自己的行为策略，进而收敛到最优控制解。




图 3.1 Actor-Critic 方法结构框架图

如图3.1，Actor-Critic 算法将整个强化学习系统划分为两个核心组件：Actor 和 Critic。其中，Actor 负责根据当前的状态 s_t 和策略 π 来选择行动 a ，其目标是通过不断调整策略参数 θ ，使得智能体在环境中采取的行动能够最大化长期累积奖励 r ；而 Critic 专注于对 Actor 所采取的行动及其产生的结果进行评估，它通过学习一个价值函数 $V(s_t)$ 来估计在当前状态下采取特定行动所能够获得的预期回报，为 Actor 提供关于策略改进方向的指导。

PPO 是在 Actor-Critic 方法基础上的一种改进型强化学习算法，相比于传统的策略梯度方法在更新策略时容易出现步长过大的问题，PPO 通过引入剪切概率比或信赖域惩罚项等机制，有效限制了新旧策略之间的差异，确保策略的更新更加平稳和可靠，在多个实际任务中表现出良好的性能与鲁棒性，成为当前强化学习领域中应用广泛且效果突出的策略优化方法之一。

3.2 人形机器人行走策略训练

本控制任务强化学习网络基于具备循环神经网络记忆机制的 Actor-Critic 结构设计，前馈部分首先通过一个具有 64 维隐藏状态、单层结构的 LSTM，以建模观测输入时间序列中的时序相关性；随后，输出经过包含三层 MLP 的网络进行进一步特征提取，每层隐藏维度设定为 32，激活函数统一采用指数线性单元 (ELU)，以提升非线性表达能力并避免梯度消失问题。初始化时，网络设置了初始噪声标准差为 1.0，以促进策略在训练早期的探索行为。

在训练过程中，智能体所在的仿真环境以 50Hz 的频率接收策略网络输出的动作指令，并同步返回相应的观测信息和奖励信号。与此同时，物理引擎和底层的 PD 控制模块以 200Hz 的速率持续运行，以确保动态响应的高精度和控制的稳定性。训练与测试工作在一台配备 NVIDIA GeForce RTX 4090 (24GB) GPU 和 Intel Xeon Platinum 8352V @ 2.10GHz CPU 的工作站上进行，该硬件配置能够支持多并行仿真环境下的高效训练。

3.2.1 奖励设计

奖励函数 $R(s)$ 定义为多个子奖励因子的加权求和，最后经截断以确保非负，具体形式如式3.1所示：

$$R(s) = \max \left(\sum_j \omega_j r_j(s), 0 \right) \quad (3.1)$$

其中，各项 $r_j(s)$ 分别表示第 j 类子奖励，其在总体奖励中的影响由权重系数 ω_j 决定。

为适应不同地形在结构特征与动态稳定性要求方面的差异性，本研究针对各类地形设置了差异化的奖励因子权重，或设计了专属的奖励函数，以增强策略在特定地形上的适应能力与表现。

台阶地形由于其显著的几何不连续性以及对机器人动态平衡与精确落足的高度要求，成为强化学习奖励机制设计中具有代表性的关键场景，本文以下将以其为例进行阐述。在其对应的奖励函数中，本文通过提高期望的抬腿高度及其相关奖励项的权重，以增强机器人在应对台阶障碍时的抬腿能力。此外，参考 BeamDojo 方法^[17]，引入了落脚点位置检测机制，用以鼓励机器人在落足过程中将更多的脚部接触面积覆盖于台阶表面，从而提高落足稳定性。该项奖励的计算

公式如下所示：

$$r_{\text{ContactPosi}} = - \sum_{i=1}^2 \sum_{j=1}^n \mathbf{1}\{d_{ij} < \epsilon\} \quad (3.2)$$

其中， d_{ij} 表示机器人第 i 条腿第 j 个接触点与其正下方地面之间的垂直距离， ϵ 为设定的离地高度阈值， $\mathbf{1}\cdot$ 为指示函数， n 为接触检测点数量。当机器人足部落点接近台阶边缘时，与地面距离较大的监测点数量相应增加，从而导致惩罚项增大。该设计旨在通过对落足不稳定行为的惩罚，引导策略趋向于选择更加稳定、安全的落足区域，从而提升整体行走的鲁棒性与动态平衡能力。

为满足任务目标，整个奖励系统可划分为三大模块：正则化奖励、姿态调控回报、以及行为执行反馈。

正则化奖励部分旨在削弱策略中可能出现的高频震荡，通过惩罚关节速度、加速度、关节扭矩，以及动作变化速率，有助于促使策略倾向于生成更加平滑且能量效率更高的动作轨迹。其设定参见表3.1。

表 3.1 正则化项奖励

奖励因子	描述说明	数学形式	主要权重	台阶权重
r_{JointVel}	关节速度抑制项	$- \dot{q} ^2$	1×10^{-3}	1×10^{-4}
r_{JointAcc}	关节加速度惩罚	$- \ddot{q} ^2$	2.5×10^{-7}	2.5×10^{-7}
r_{Torque}	扭矩使用惩罚	$- \tau ^2$	1×10^{-7}	1×10^{-7}
$r_{\text{ActionRate}}$	动作变化幅度惩罚	$- a_t - a_{t-1} ^2$	1×10^{-2}	1×10^{-3}

姿态调控回报奖励主要提升机器人在外部扰动或动态环境下的自稳能力。该模块中的各项奖励因子，如水平角速度惩罚、垂直速度惩罚、躯干高度约束、髋部相对位置控制及姿态稳定性等，均针对实际执行中可能出现的姿态偏离问题进行抑制。与此同时，加入关节限位检测作为惩罚项，进一步增强了策略对物理约束的遵守能力，从而提高了策略的可迁移性和可部署性。具体的奖励项如表3.2。

行为执行反馈奖励则聚焦于引导机器人产生具有明确运动意图的行为表现。尤其是在动态地形下，机器人除了需要维持自身稳定外，还需准确实现目标速度的跟踪。故该模块引入了线速度与角速度的轨迹追踪奖励，确保运动方向和速度的准确性。此外，针对步态生成的稳定性，我们引入了抬脚高度奖励以及足部接触匹配项，以鼓励策略生成合理的摆动高度和接触节律，进一步提升步态执行的协调性与可控性。奖励因子构成如表3.3所示。

表 3.2 姿态调控回报奖励

奖励因子	描述说明	数学形式	主要权重	台阶权重
r_{Alive}	存活奖励	$\mathbf{1}_{\text{alive}}$	0.15	0.35
r_{AngVelXY}	水平角速度惩罚	$- \omega_{xy} ^2$	0.05	0.05
r_{LinVelZ}	垂直方向速度惩罚	$- v_z $	2.0	0.0
$r_{\text{BaseHeight}}$	躯干高度偏离惩罚	$- h - h_{\text{ref}} $	10.0	0.0
$r_{\text{JointPosLimits}}$	关节位置限幅惩罚	$\mathbf{1}_{q \notin [q_{\min}, q_{\max}]}$	5.0	2.0
r_{HipPos}	髋部相对位置惩罚	$- p_{\text{hip}} - p_{\text{ref}} $	1.0	1.0
r_{Ori}	姿态稳定性惩罚	$- q_{\text{ori}} - q_{\text{target}} ^2$	1.0	1.0

表 3.3 行为执行反馈奖励

奖励因子	描述说明	数学形式	主要权重	台阶权重
r_{LinVel}	线速度追踪奖励	$- v_{\text{lin}} - v_{\text{lin}}^{\text{ref}} ^2$	1.0	3.0
r_{AngVel}	角速度追踪奖励	$- \omega_z - \omega_z^{\text{ref}} ^2$	0.5	1.5
r_{Contact}	接触相位奖励	$\mathbf{1}_{\text{contact}}$	0.18	0.3
$r_{\text{ContactPosi}}$	落脚点位置奖励	$-\sum \mathbf{1}\{d_{ij} < \epsilon\}$	0.0	0.8
$r_{\text{FeetSwingHeight}}$	抬脚高度追踪奖励	$- h_{\text{swing}} - h_{\text{ref}} $	5.0	30.0

3.2.2 课程学习

在网络的训练过程中，本研究使用了课程学习的训练方法，地形复杂度及机器人的期望行走速度与角速度将随着训练进程逐步提升。具体而言，当机器人在当前地形条件与运动指令（包括线速度与角速度）下，能够完成超过一半的预设行走距离时，即视为该阶段学习任务完成，从而进入更高难度的地形或更高要求的运动指令进行训练；若未达成该标准，则任务将回退至相对低难度的地形或命令设置，以强化其在低级任务中的稳定性与鲁棒性。该机制旨在通过逐级递进的训练策略，提升机器人在多地形环境中的适应性与泛化能力。

第 4 章 控制任务实验

4.1 多地形行走策略评估实验

本实验旨在评估人形机器人在多地形环境中的行走策略执行效果，实验设计了一个包含五种连续地形类型随机组合的综合测试场景，如图4.1所示（分类如节2.2）。

实验结果表明，机器人能够以平均速度 0.6 m/s 稳定地完成整个多地形组合的连续行走任务。在大多数测试周期中，机器人表现出良好的平衡控制和步态连续性，能够顺利通过各类地形段。除极少数特殊情形（如突发干扰或地形突变导致局部失衡）外，机器人的行走轨迹基本沿着场景中心线展开，在未纠正的情况下，步态延中心线略有偏移，但整体表现出较高的路径保持能力与地形适应能力，验证了所提出行走策略在复杂环境下的有效性与通用性。





图 4.1 五种连续地形综合测试场景

为减少冗余陈述，本实验重点分析平面地形与离散崎岖地形两种典型环境下的行走表现，尤其关注行走过程中步态稳定性及控制策略的有效性。同时，为模拟真实环境中可能出现的地形突变，观测了地形切换场景下的步态表现，以进一步验证机器人在复杂地形间的适应能力。通过对比不同地形条件下的步态特征，实验为多地形适应性策略的评估提供了数据支持。

在具体实验设置中，选取了每条腿六自由度结构中的三个关键关节——髋关节 pitch 、膝关节 pitch 与踝关节 pitch ，作为主要观测对象。这三个位于矢状面方向的关节对直线行走中身体的前向推进、抬腿动作以及地面支撑起着决定性作用，能够充分反映步态的周期性结构与受力变化特征。因此，记录并分析这三个关节在不同地形条件下的角度变化与力矩响应，有助于准确揭示机器人对地形扰动的动态反应过程以及控制策略的差异化调节能力。



平坦地形（左），离散崎岖地形（右）；关节角度（上），关节力矩（下）

图 4.2 平坦地形与离散崎岖地形下行走过程中关节角度与关节力矩变化曲线

图4.2展示了机器人在平坦地形与离散崎岖地形下行走过程中关节角度与关节力矩的时间序列变化曲线。结果显示，在平坦地形条件下，三个关节的角度曲线呈现出高度规律的周期波动，力矩变化曲线平滑且对称，表明机器人能够稳定维持均衡的步态控制状态，且未受到外部干扰的明显扰动，说明控制策略在结构对称性与运动节律性方面具备良好的执行效果。而在离散崎岖地形条件下，尽管机器人依然保持了相对稳定的周期性步态模式，但受地面起伏影响，力矩变化曲线相较于平坦地形呈现出一定程度的非线性波动，尤其在单腿支撑相与摆动相交交替过程中，出现了轻微的力矩峰值抖动，反映出机器人在地形变化过程中需要通过调整内部控制策略以应对支撑不稳定所带来的力学扰动。此外，踝关节的角度曲线相较于髋关节与膝关节发生了较大变化，表明机器人在适应崎岖地形时，主要通过足部调节实现对地面不规则性的快速响应与动态稳定性维持。

为进一步验证控制策略在地形突变条件下的适应能力，实验引入了地形切换场景，即机器人从平坦地形过渡至离散崎岖地形的过程中，分析其步态调节与控制稳定性的动态演化过程。图4.3呈现了地形切换过程中三个关键关节的角度与力矩变化情况。可以观察到，尽管地形特性发生了较为剧烈的变化，机器人在关节角度调节过程中仍保持了良好的连续性与平滑性，未出现突兀的姿态跳变或控制紊乱现象，力矩曲线在地形切换点处也未表现出剧烈的噪声或尖峰波动，表明策略具备较强的时序一致性与控制鲁棒性。该过程中的平滑过渡反映了控制系统具备较强的前馈调节能力与对环境变化的快速反馈响应，能够实现从策略层面到力控层面的多层次协调调节，从而保障机器人在非结构化地形中的持续稳定运动。




图 4.3 地形切换过程中关节角度与关节力矩变化曲线

实验结果表明，机器人在平坦地形下能够实现高度稳定的行走，其关节角度变化规律性强，力矩输出平稳；而在崎岖地形中，尽管地形扰动显著增加，机器人依然表现出较强的适应能力，步态结构随地形变化作出明显调整，控制策略展现出一定的鲁棒性。地形切换实验进一步验证了机器人具备动态调整步态以应对地形突变的能力，步态图中显示的姿态变化与力矩响应反映出控制系统的及时性与适应性。整体而言，本实验验证了控制策略在多地形环境下的可行性，为后续多地形适应性行走系统的拓展和增强提供了重要参考与数据支撑。


4.2 台阶地形行走能力评估实验

为了评估所提出的人形机器人行走算法在复杂地形下的极限能力，本文重点研究了台阶地形条件下的行走性能。台阶地形作为本研究划分的五类典型地形中最具挑战性的类型之一，其地形特征显著复杂，机器人在该地形上行走所需的步

态调节幅度最大。因此，台阶地形不仅代表了本算法适应能力的上限边界，也可作为检验整套行走算法鲁棒性与泛化能力的重要测试平台。

4.2.1 台阶攀爬基础能力实验

本实验每级台阶的宽度为 0.4m，高度为 0.11m。为具体分析台阶行走过程中机器人步态的时序特征，本文选取了机器人攀爬一级台阶过程中的 0.7s 时间段，并对关键步态变化进行了快照分析，如图4.5所示。在 0.0s 时，机器人处于攀爬准备阶段，呈现单腿支撑状态；0.1s 时完成双腿支撑，标志着攀爬动作的初始化；0.2s 时，先摆动腿抬升至最高点；0.4s 时，先摆动腿完成落脚并进入支撑期，同时后摆动腿开始抬升；0.6s 时，后摆动腿抬至高点，机器人整体重心提升到位；至 0.7s 时，后摆动腿完成落地进入支撑，标志着换腿完成及该步态周期的结束。整个过程展示了机器人在面对大幅度高度变化地形时的动态步态调整能力。



关节角度（左），关节力矩（右）

图 4.4 平坦与台阶地形切换过程中关节角度与关节力矩变化曲线

为了进一步量化分析机器人从平地过渡至台阶地形过程中动力学状态的变化，本文记录了关键关节的角度与力矩变化情况，如图4.4所示。实验结果表明，在进入台阶地形后，机器人关节角度显著增大，尤其是髋关节与膝关节的摆动幅度增加，反映出为了完成台阶高度的抬腿动作，控制策略主动增强了腿部的抬升轨迹。同时，膝关节的力矩呈明显上升趋势，说明机器人在垂直方向上需要施加更大的力矩以抬升身体重心完成台阶攀爬，该过程体现了算法在大位移工作空间下的控制效能与机体协同能力。

4.2.2 台阶攀爬极限高度实验

在本实验中，以成功连续攀爬三级台阶为标准，分别测试了不同台阶高度（0.15m、0.16m、0.17m、0.18m、0.19m）的攀爬性能，每个高度均进行了十次实验，相关结果如表4.1所示。




图 4.5 台阶行走步态的时序特征图

从实验结果可知，当台阶高度不超过 0.16m 时，机器人能够以较高的成功率稳定完成连续三级台阶的攀爬任务；而在台阶高度为 0.17m 时，成功率略有下降，出现了个别攀爬失败的情况。随着台阶高度进一步增加至 0.18m，成功率显著下降，仅有一半实验成功完成，表现出明显的不稳定性；在 0.19m 高度下，机器人则完全无法完成三级台阶的连续攀爬。因此，可以确定该机器人系统在本控制算法下的台阶攀爬极限高度为 0.18m，即在该高度仍具有一定成功率，但已经接近性能边界。

表 4.1 不同台阶高度下机器人连续攀爬 3 级台阶实验结果

指标	0.15m	0.16m	0.17m	0.18m	0.19m
测试频数	10	10	10	10	10
成功频数	10	10	9	5	0

除实验统计结果外，实验回放快照亦揭示了机器人在不同台阶高度下的运动表现特征。在 0.15m 与 0.16m 的台阶高度条件下，机器人整体动作较为稳定，能够在无需显著调整或仅需进行少量微调的情况下完成攀爬。而当台阶高度达到 0.17m 与 0.18m 时，机器人在抬腿过程中逐渐暴露出足部提升不足的问题，导致




图 4.6 退回现象步态时序特征图

在每一级台阶上均需进行较多次位置调整，甚至出现已登上前一级台阶后因落脚不稳而被迫退回的现象。在 0.19m 高度测试中，机器人足部提升能力已无法满足对台阶高度的跨越需求，致使其基本无法完成有效的攀爬。

如图4.6所示，退回现象在步态过程中表现得尤为明显。在 0.1 秒时刻，支撑脚的落脚点存在显著偏移，导致大部分足部区域超出当前支撑面边缘，引发踝关节处的力矩急剧增大，使得控制系统在维持平衡方面面临更高挑战。同时，受限於支撑脚临近边缘的位置，机器人在执行姿态调整与重心转移动作时，易与台阶边缘发生干涉，致使重心投影无法顺利前移，最终为了维持整体姿态稳定性，机器人只能回退一级台阶，从而导致攀爬任务失败。

依据国家标准对台阶高度的建议，通常以 0.15m 作为标准极限高度，超出该范围则被视为非标准场景。本实验通过对超过 0.15m 的多个台阶高度进行系统性测试，验证了所提出控制算法在实现贴近人类生活场景行走能力的同时，具备在非标准环境下应对挑战的潜力。值得指出的是，所使用机器人本体高度显著低于标准成年人的平均身高，仍能在此条件下完成最高至 0.18m 台阶的攀爬任务，充分体现了所构建系统在面对复杂场景时所具备的良好环境适应性与控制鲁棒性。

参考文献

- [1] Aggarwal J K, Cai Q. Human motion analysis: A review[J]. Computer vision and image understanding, 1999, 73(3): 428-440.
- [2] Prakash Gupta J, Dixit P, Singh N, et al. Analysis of gait pattern to recognize the human activities[M]. International Journal of Interactive Multimedia and Artificial Intelligence ..., 2014.
- [3] Nenchev D N, Konno A, Tsujita T. Humanoid robots: Modeling and control[M]. Butterworth-Heinemann, 2018.
- [4] Zhao L, Yu Z, Han L, et al. Compliant motion control of wheel-legged humanoid robot on rough terrains[J]. IEEE/ASME Transactions on Mechatronics, 2023, 29(3): 1949-1959.
- [5] Wikipedia contributors. Optimus (robot)[EB/OL]. 2024. [https://en.wikipedia.org/wiki/Optimus_\(robot\)](https://en.wikipedia.org/wiki/Optimus_(robot)).
- [6] Gong Y, Hartley R, Da X, et al. Feedback control of a cassie bipedal robot: Walking, standing, and riding a segway[C]//2019 American control conference (ACC). IEEE, 2019: 4559-4566.
- [7] Li Z, Peng X B, Abbeel P, et al. Reinforcement learning for versatile, dynamic, and robust bipedal locomotion control[J]. The International Journal of Robotics Research, 2024: 02783649241285161.
- [8] Li Z, Cheng X, Peng X B, et al. Reinforcement learning for robust parameterized locomotion control of bipedal robots[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2021: 2811-2817.
- [9] Garcia C E, Prett D M, Morari M. Model predictive control: Theory and practice—a survey [J]. Automatica, 1989, 25(3): 335-348.
- [10] Li Z, Peng X B, Abbeel P, et al. Robust and versatile bipedal jumping control through reinforcement learning[A]. 2023.
- [11] Rudin N, Hoeller D, Reist P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning[C]//Conference on Robot Learning. PMLR, 2022: 91-100.
- [12] Nashner L M, McCollum G. The organization of human postural movements: a formal basis and experimental synthesis[J]. Behavioral and brain sciences, 1985, 8(1): 135-150.
- [13] Winter D A. Overall principle of lower limb support during stance phase of gait[J]. Journal of biomechanics, 1980, 13(11): 923-927.

- [14] Nilsson J, Thorstensson A, Halbertsma J. Changes in leg movements and muscle activity with speed of locomotion and mode of progression in humans[J]. *Acta Physiologica Scandinavica*, 1985, 123(4): 457-475.
- [15] Gu X, Wang Y J, Chen J. Humanoid-gym: Reinforcement learning for humanoid robot with zero-shot sim2real transfer[A]. 2024.
- [16] Makoviychuk V, Wawrzyniak L, Guo Y, et al. Isaac gym: High performance gpu-based physics simulation for robot learning[A]. 2021.
- [17] Wang H, Wang Z, Ren J, et al. Beamdojo: Learning agile humanoid locomotion on sparse footholds[A]. 2025.