



清华大学

综合论文训练

基于人形机器人本体感觉的多地形 强化学习步态生成方法

系 别：自动化系

专 业：自动化

姓 名：李昭阳

指导教师：张 涛 教授

二〇二五年六月

关于论文使用授权的说明

本人完全了解清华大学有关保留、使用综合论文训练论文的规定，即：学校有权保留论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

作者签名：李昭阳

日期：2015.6.17

导师签名：张立青

日期：2015.6.17

摘 要

在复杂多变的地形环境中，人形机器人需依赖动态步态规划以实现稳定行走。然而，传统的基于模型的优化方法由于依赖简化的动力学假设，难以充分挖掘机器人潜在的运动能力；而基于强化学习的策略虽具有无模型优势，能够适应高度非线性的控制问题，但在应对多地形场景时仍面临优化目标冲突、训练效率低下以及策略可解释性不足等挑战。

针对上述问题，本文提出一种基于残差补偿的两阶段强化学习框架，并引入本体感知的地形分类机制，以提升人形机器人在多样地形下的步态规划适应性与鲁棒性。该方法通过主干策略网络学习通用的基础步态行为，同时构建多特征头残差网络用于实现地形特异性的动作补偿机制。为实现对地形类别的动态感知与判别，进一步设计了基于长短期记忆网络（LSTM）的本体感知地形分类器，该分类器利用机器人时序运动特征完成对当前地形类型的判断，并作为调控信号引导残差模块的精准激活，以实现更具针对性的策略调节。

为验证所提方法的有效性，本文构建了一个涵盖平坦地面、障碍物区域、崎岖路径、斜坡以及台阶等多种典型地形的仿真测试环境，并引入域随机化技术模拟现实中控制延时、地形扰动等不确定性因素。实验结果显示，与传统的单网络PPO策略相比，本方法在多地形环境下表现出更优的通行能力与环境适应性，能够以0.6 m/s的平均速度稳定完成复杂越野任务，连续攀爬台阶的能力提升至最高0.18 m。此外，通过消融实验与替代实验进一步验证了残差补偿结构在整个框架中的关键作用和专业设计的合理性。

本研究为面向多地形的人形机器人强化学习步态规划提供了一种具备模块化、可扩展性的技术路径，但仍存在极端地形场景验证不足以及未实现真实硬件部署等限制。未来工作将进一步探索算法在更复杂环境中的泛化能力，并致力于推动从仿真到真实系统的策略迁移研究，以加速人形机器人在实际应用中的技术落地与部署。

关键词：人形机器人；强化学习；本体感知；步态生成；地形分类

Abstract

In complex and variable terrain environments, humanoid robots require dynamic gait planning to achieve stable locomotion. However, traditional model-based optimization methods, which rely on simplified dynamic assumptions, often fail to fully exploit the robot’s potential mobility. On the other hand, reinforcement learning-based approaches, while advantageous in being model-free and capable of handling highly non-linear control problems, still face challenges such as conflicting optimization objectives, low training efficiency, and limited policy interpretability in multi-terrain scenarios.

To address these issues, this paper proposes a two-stage reinforcement learning framework based on residual compensation, integrated with a proprioception-driven terrain classification mechanism, to enhance the adaptability and robustness of humanoid gait planning across diverse terrains. The proposed method employs a backbone policy network to learn general fundamental gait behaviors, while a multi-head residual network is designed to realize terrain-specific action compensation. To enable dynamic perception and classification of terrain types, a proprioception-based terrain classifier is developed using a Long Short-Term Memory (LSTM) network. This classifier leverages the temporal motion features of the robot to identify the current terrain type and provides modulation signals to precisely activate the residual module, thereby enabling targeted policy adaptation.

To validate the effectiveness of the proposed approach, a simulation test environment was constructed, encompassing various typical terrains including flat ground, obstacle zones, rugged paths, slopes, and stairs. Domain randomization techniques were applied to simulate real-world uncertainties such as control delays and terrain disturbances. Experimental results demonstrate that, compared to conventional single-network PPO policies, the proposed method exhibits superior traversability and environmental adaptability in multi-terrain scenarios. It achieves stable performance in complex off-road tasks at an average speed of 0.6 m/s, and improves continuous stair-climbing capability up to 0.18 m. Furthermore, ablation and substitution experiments confirm the critical role and sound design of the residual compensation structure within the overall framework.

This study presents a modular and scalable technical pathway for reinforcement learning-based gait planning in multi-terrain humanoid locomotion. Nevertheless, limitations remain in terms of validation under extreme terrain conditions and the lack of deployment on physical hardware. Future work will focus on exploring the generalization capability of the algorithm in more complex environments and advancing policy transfer from simulation to real-world systems, thereby accelerating the practical deployment of humanoid robots.

Keywords: Humanoid Robot; Reinforcement Learning; Proprioception; Gait Generation; Terrain Classification

目 录

第 1 章 引言	1
1.1 研究背景和意义	1
1.1.1 人形机器人	1
1.1.2 人类步态行为	2
1.2 国内外研究现状	4
1.2.1 基于模型的人形机器人步态生成研究	5
1.2.2 基于学习的人形机器人步态生成研究	6
1.2.3 基于本体感知的地形预测方法	8
1.3 主要研究内容	9
1.4 论文结构	10
第 2 章 人形机器人的仿真系统搭建	11
2.1 仿真系统基础架构	11
2.2 仿真环境构建	12
2.3 仿真对象构建	14
2.3.1 动作空间	15
2.3.2 状态空间	16
2.3.3 域随机化	17
2.3.4 其他设置	18
2.4 小结	19
第 3 章 基于残差补偿的两阶段强化学习步态生成方法	20
3.1 强化学习算法简述	20
3.2 多特征头残差补偿机制	21
3.3 两阶段训练方法	22
3.4 算法有效性验证	23
3.4.1 测试仿真环境搭建	23
3.4.2 实验参数设置	24
3.4.3 实验内容设计	25

3.4.4 实验结果与分析	25
3.5 人形机器人行走策略训练	27
3.5.1 奖励设计	28
3.5.2 课程学习	30
3.6 小结	30
第 4 章 基于人形机器人本体感觉的步态选择方法	31
4.1 基于本体感觉的步态选择框架设计	31
4.2 数据构建与模型评估	32
4.2.1 数据采集	32
4.2.2 模型训练与实验	32
4.3 人形机器人步态实验分析	34
4.3.1 算法推理流程	34
4.3.2 多地形行走策略评估实验	35
4.3.3 台阶地形行走能力评估与消融实验	37
4.3.4 残差输出替代实验	42
4.4 小结	44
第 5 章 总结与展望	45
5.1 全文总结	45
5.2 展望	45
参考文献	46
附录 A 外文资料的书面翻译	51
致 谢	69
声 明	71

插图清单

图 1.1	宇树科技 H1（左）、G1（右）型号人形机器人.....	1
图 1.2	人体下肢主要肌肉、骨骼、关节示意图	3
图 1.3	人体步行周期示意图	3
图 1.4	人类步态参数研究	3
图 1.5	倒立摆简化模型示意图	5
图 1.6	模型预测控制与全身控制系统框图	5
图 1.7	摆动-支撑周期性奖励示意图 ^[49]	6
图 1.8	常见的人形机器人步态强化学习奖励表	7
图 1.9	基于参考轨迹残差增强的强化学习算法框图	7
图 2.1	单阶段 PPO 强化学习方法训练环境流程图	11
图 2.2	宇树 G1 机器人在平坦地形上训练	13
图 2.3	复杂训练环境地形示意图	13
图 3.1	Actor-Critic 方法结构框架图	20
图 3.2	基础策略学习阶段训练方法结构框架图	22
图 3.3	残差增强阶段训练方法结构框架图	23
图 3.4	“山地小车”仿真环境示意图	24
图 3.5	两阶段方法训练奖励曲线	26
图 3.6	单阶段 PPO 强化学习方法训练奖励曲线	27
图 4.1	算法推理流程框架图	34
图 4.2	五种连续地形综合测试场景	35
图 4.3	平坦地形与离散崎岖地形下行走过程中关节角度与关节力矩变化曲线	36
图 4.4	地形切换过程中关节角度与关节力矩变化曲线	37
图 4.5	平坦与台阶地形切换过程中关节角度与关节力矩变化曲线	38
图 4.6	台阶行走步态的时序特征图	39
图 4.7	退回现象步态时序特征图	40
图 4.8	台阶攀爬失败过程快照	41
图 4.9	斜坡地形残差输出替代应用于崎岖地形导致的躯干失衡步态回放 ...	42
图 4.10	离散崎岖地形中关节角曲线对比	43

附表清单

表 2.1 状态空间各组成变量 17

表 2.2 域随机化相关参数设定 18

表 3.1 状态空间变量 25

表 3.2 训练参数 28

表 3.3 正则化项奖励 29

表 3.4 姿态调控回报奖励 29

表 3.5 行为执行反馈奖励 30

表 4.1 基于状态观测量的不同模型分类选择性能对比 33

表 4.2 基于 LSTM 的不同数据源分类选择性能比较..... 33

表 4.3 不同台阶高度下机器人连续攀爬 3 级台阶实验结果 39

表 4.4 消融条件下机器人连续攀爬 3 级台阶实验结果 41

第 1 章 引言

1.1 研究背景和意义

人类的运动能力涵盖了广泛的范围^[1]，拥有适应各种任务所需的不同步态，例如站立、行走、快步走、小跑、奔跑和跳跃^[2]，这种适应性使人类能够在广泛的动作范围中表现出卓越的灵活性和机动性。人类生活中的环境主要为双足行走而设计，其丰富多样性使得人形机器人领域的总体目标是开发能够在这些环境中可靠运行的机器人。基于以上观点，进一步探讨人形机器人及人类步态行为。

1.1.1 人形机器人

人形机器人（Humanoid Robot）通常是指在外形和功能特征上模仿人类的机器人系统，其最显著的结构特征包括一个躯干、两条手臂和两条腿，部分系统还具备头部或拟人化的面部结构^[3]。尽管如此，人形机器人在具体实现上仍存在较大差异，尤其在末端执行器和下肢驱动形式方面。例如，一些人形机器人采用结构简化的手部设计，仅具备有限的抓取与操作能力；另有一些系统在腿部使用轮式驱动以简化运动控制并提高地面适应性^[4]，这类设计在一定程度上牺牲了类人性，但换来了较高的运动稳定性与能效比。



图 1.1 宇树科技 H1（左）、G1（右）型号人形机器人

近年来，随着控制算法、驱动技术、材料科学和人工智能的快速发展，人形机器人研究进入加速阶段，成为机器人学和智能系统领域的研究热点。多个知名科研机构与企业陆续发布了一系列具有代表性的研究成果和产品，推动了该领域

技术的持续演进。波士顿动力公司推出的 Atlas 机器人具备强大的动态运动能力，其完成跳跃、翻滚与复杂跑酷动作的演示，展示了当前人形机器人在运动控制方面的最高水平。Tesla 公司推出的 Optimus 机器人^[5]，以及 Figure 公司的类人机器人^[6]，则尝试通过模仿人类行为数据实现桌面操作、物体搬运等复杂任务的自主执行，在具身智能与任务学习领域提供了新的范式。

同时，研究型双足机器人 Cassie^[6-8] 及其人形版本 Digit^[7]，以其模块化设计与高自由度电机驱动系统，在多种复杂地形上实现了稳定行走，为灵巧性与环境适应性提供了兼顾的解决方案。中国机器人企业 Unitree Robotics 也相继推出了 H1 和 G1 两款人形机器人^[8]，其紧凑化设计和良好的性价比受到业界广泛关注（如图1.1所示）。Apptronik 公司推出了 Apollo 机器人，其采用全推杆电机驱动系统^[9]，致力于在动力性能与控制精度之间寻求平衡。同时，人工智能领先企业 OpenAI 在收购 1X 公司^[10]后，进一步推动了具身智能的研究计划，探索如何将通用人工智能模型嵌入人形机器人平台，实现感知—决策—控制的闭环系统^[11]。

综上所述，人形机器人正在成为连接人工智能算法与实际物理系统的重要桥梁。通过在结构设计、传感融合、智能控制以及任务学习等方面的持续探索，该领域有望加速推动智能体从虚拟空间向现实世界迁移，进而为多类应用场景提供更为普适且高效的解决方案。掌握人形机器人核心技术已成为未来人工智能硬件化、实体智能系统落地的突破口。

1.1.2 人类步态行为

人体下肢骨干主要包括髋关节、股骨、膝关节、胫骨与腓骨、踝关节和足，其中以髋、膝、踝三个关节提供主要自由度，骨干之间又由腹肌、椎旁肌、四头肌、腿筋肌、胫骨肌与腓肠肌等肌群相互连接^[12]（如图1.2）。肌肉、骨骼、关节三者相互协调，进而形成了复杂的运动行为。

人体下肢肌肉骨骼结构复杂，将其抽象为简化模型更利于研究。鉴于人体步态变化主要集中在行走方向（矢状面）的偏航角变化，研究者最初将踝关节和膝关节抽象为单轴铰，胫骨和股骨抽象为连杆，构建了经典的二维双摆模型。然而，二维模型无法提供翻滚和俯仰方向的信息，难以满足精确三维研究的需求。因此，在三维情况下，通常将双腿建模为多刚体模型，即将二维单轴铰链替换为多轴铰，二维连杆替换为刚性柱。随着计算机技术的发展以及对肌肉特性研究的不断深入，下肢模型逐渐完善，出现了模拟肌肉、韧带等的多连杆结构，同时也有考虑肌肉疲劳效应的特性模型。




图 1.2 人体下肢主要肌肉、骨骼、关节示意图





图 1.3 人体步行周期示意图



步行关节力矩（左上）、跑步关节力矩（右上）、步行关节角（左下）、跑步关节角（右下）

图 1.4 人类步态参数研究

对人体运动步态的研究可追溯至 1836 年。研究者普遍认为，正常步态具有明显的周期性特征。步行周期是指一侧足跟着地至该侧足跟再次着地的完整过程，其可进一步细分为支撑相和摆动相。如图1.3所示，支撑相是指脚接触地面并承受躯干重力的阶段，通常占步行周期的 60% 左右，又可分为单脚支撑相和双脚支撑相。步行速度与双脚支撑相的时间呈反比关系。摆动相则是指脚离开地面向前迈步直至再次落地的阶段，约占步行周期的 40%。对于单脚而言，在一个完整的步行周期中，会依次经历初接触、足底水平、重心转移、足跟抬起、足尖抬起、摆动至胫骨垂直地面以及再次接触等七个阶段。

在研究人类步态时，通常测量相关运动学和动力学参数。运动学参数包括周期时间、单步时间、占空比、步长、步宽、足夹角等；动力学参数包括关节力矩、下肢重心加速度、肌群活动肌电图等。例如，Winter 等人^[13]运用标准的连杆段动力学程序计算各关节力矩，研究绘制了青年男性行走和奔跑时，髋、膝、踝关节的力矩变化曲线如图1.4。Nilsson 等人^[14]使用 Selspot 光电系统检测记录了青年男性行走和奔跑步态的下肢关节角变化曲线如图1.4，揭示了肌肉活动与关节的运动关系。

人类的步态行为是一种高度优化的生物力学过程，由神经、骨骼、肌肉协调共同完成，在复杂多样的环境中展示出了极高的适应性，例如能在光滑、粗糙平面、斜面或楼梯上稳定行走。通过研究人类的步态行为，特别是总结出共性理论、抽象出简化模型，可以揭示双足生物运动的基本原理。将这些原理应用到人形机器人的设计中，可以开发出更精准有效的运动算法和控制策略。

综上所述，研究人形机器人相关步态规划算法能够提高人形机器人的操作潜力，拓展人形机器人的应用场景，使其能够胜任复杂地形和极端环境下的作业任务，同时在工业生产、农业作业以及室内外服务等多场景中发挥重要作用。

1.2 国内外研究现状

大多数人类运动步态有周期性或准周期性的特点^[15-16]，这为人形机器人运动控制器的设计提供了极大的便利。在过去几十年中，学术界已经开发了许多人形机器人及相应的控制算法，以实现周期性步态^[17-19]。然而，尽管取得了显著进展，人形机器人在复杂地形的运动能力仍无法与人类相提并论。因此，复杂地形稳定步态的实现已引起越来越多研究者的关注。通常有两种方法可以生成稳定的周期性步态，基于模型的方法和基于学习的方法。

1.2.1 基于模型的人形机器人步态生成研究

双足机器人的运动控制可被表述为一个最优控制 (OC) 问题^[20]，并将机器人的动力学模型作为运动约束条件。为了处理求解约束优化问题的计算复杂性，这种方法通常采用级联优化框架。该框架采用不同的建模选择，从生成长期参考轨迹开始，到低级运动控制和即时反应控制，每个阶段的控制频率逐渐提高^[21-22]。




图 1.5 倒立摆简化模型示意图

线性倒立摆模型 (LIPM) 是人形和四足机器人中应用最广泛的简化模型之一^[23-24]。Kajita 等人^[25]将机器人建模为固定高度的倒立摆，将复杂的动力学简化为一个质点质量，并使用预观控制方法结合零力矩点 (ZMP) 控制。基于 LIPM, Takenaka 等人^[26]将其扩展为可变高度倒立摆模型 (VHIP)，并分析了运动的发散分量 (DCM)，生成了周期性跑步步态。Han 等人^[27]结合 3D 弹簧倒立摆 (3D-SLIP) 模型与任务空间非线性最小二乘优化器，实现了 6.5 m/s 的稳定跑步。

单刚体模型 (SRBM) 在基于优化的方法中被广泛用于质心运动规划^[28-30]。通过手动指定接触顺序，并参考 SRBM 在线求解优化问题，Bellicoso 等人^[31]在四足机器人上实现了多种步态及平滑过渡。García 等人^[32]提出了结合 SRBM 和方向变量的 MPC 运动控制方法。




图 1.6 模型预测控制与全身控制系统框图

耦合振荡器模型通过模仿生物体的神经机制，在中央模式发生器 (CPG) 中生成可调节频率和幅度的步态周期，模拟了响应感官反馈和环境变化^[33-36]，生成了稳定的周期性步态。

这些模型除了对质心 (CoM) 和/或压力中心 (CoP) 等简化动力学进行在线优

化^[37-39]，还支持轨迹跟踪控制^[40-41]。此外，如全身控制 (WBC)^[42]这样的反应式控制器，将这些简化状态转换为关节级输入，能在不展开全阶动力学模型的情况下，以类似快速求解二次规划 (QP) 问题的运作方式，考虑各种约束条件^[43-44]。

然而，由于简化模型的局限性以及在线控制器无法重新规划全身动作，这种级联式最优控制方法无法充分发挥机器人的潜在敏捷性。同时，这些简化模型通常假设机器人某些关节是被动的或锁定的^[45]，只允许一种或有限的步态模式。这导致运动空间仅代表了机器人全部潜力的一小部分，限制了对所有驱动关节所提供的完整运动范围和灵活性的探索和利用。

1.2.2 基于学习的人形机器人步态生成研究

在近十年来，强化学习 (RL) 越来越多地应用于人形机器人控制算法，实现了如爬台阶^[45]和后空翻^[46]等复杂动作。基于学习的方法不需要精确的机器人建模，而是通过智能体与环境的交互学习运动控制策略^[47-48]，大大缩短了开发周期。通过在 GPU 上进行大规模并行计算，平地行走的训练时间已缩短至 5 分钟^[11]。




图 1.7 摆动-支撑周期性奖励示意图^[49]

强化学习更高效地生成了周期性步态。Wu 等人^[50]表明，通过使用简单的正弦信号来获得预期的摆动-支撑时序并将其作为观测的一部分，并设计奖赏函数以跟踪该时序，机器人可以实现固定频率的行走。Li 等人^[51]提出了傅里叶潜在动力学 (FLD) 方法，从人类运动中提取周期特征，通过傅里叶变换将动作捕捉的关节角度转化为频域信息，并利用解码器重建这些特征，以模仿原始人类动作。

除了直接在奖励函数中引入周期性的脚部抬起和落下，强化学习也能够在不依赖周期性参考信号的情况下生成自适应步态模式。Siekman 等人^[45]修改现有的平地训练 RL 框架，加入楼梯状地形的随机化，无需改变奖励函数，首次展示双足机器人仅使用本体感知穿越真实世界的楼梯。Wang 等人^[52]提出 BEAMDOJO

强化学习框架，用于解决人形机器人在稀疏立足点地形的移动问题，首次实现基于学习的方法在该类地形的细粒度立足点控制，展示了人形机器人在真实世界的敏捷移动能力。

Reward	Equation (r_i)	reward scale(μ_i)
Lin. velocity tracking	$\phi(\dot{P}_{xyz}^b - \text{CMD}_{xyz}, 5)$	1.2
Ang. velocity tracking	$\phi(\dot{P}_{\alpha\beta\gamma}^b - \text{CMD}_{\alpha\beta\gamma}, 5)$	1.0
Orientation tracking	$\phi(P_{\alpha\beta}^b, 5)$	1.0
Base height tracking	$\phi(P_z^b - 0.7, 100)$	0.5
Velocity mismatch	$\phi(\dot{P}_{z,\gamma,\beta}^b - \text{CMD}_{z,\gamma,\beta}, 5)$	0.5
Contact Pattern	$\phi(I_p(t) - I_d(t), \infty)$	1.0
Joint Position Tracking	$\phi(\theta - \theta_{\text{target}}, 2)$	1.5
Default Joint	$\phi(\theta_t - \theta_0, 2)$	0.2
Energy Cost	$ \tau \dot{\theta} $	-0.0001
Action Smoothness	$\ a_t - 2a_{t-1} + a_{t-2}\ _2$	-0.01
Large contact	$\max(F_{L,R} - 400, 0, 100)$	-0.01

图 1.8 常见的人形机器人步态强化学习奖励表

随着基于学习的方法的不断发展，将基于模型的方法与基于学习的方法相结合受到了业界的广泛关注。许多关于四足机器人的研究^[53]采用模型预测控制（MPC）生成参考运动，并将其作为基于强化学习的运动模仿的奖励信号。然而，MPC 的在线计算不仅会延长训练时间，还可能无法找到可行解。因此，跟踪离线生成轨迹的在线强化学习方法为多功能双足运动的实现提供了有效的解决方案^[54]。此外，已学习的策略可以为基于模型的方法提供良好的热启动或超参数建议，从而显著减少收敛到最优轨迹所需的迭代次数。




图 1.9 基于参考轨迹残差增强的强化学习算法框图

除了直接跟踪参考轨迹外，利用残差增强参考轨迹也是一种常用方法。早期关于动态运动基元的研究^[55]通过学习特定任务的力输出来修改参考轨迹，成功实现了人形机器人挥拍的动作。此后，Xie 等人^[56]通过轨迹增强强化学习实现了

灵活的双足运动。最近，运动操作技能也通过增强基于轨迹优化（TO）的参考轨迹得以实现^[57]。此外，除了关节层面的参考之外，还可以增强任务空间的参考。例如，Paredes 等人^[58]学习了一种运动策略，使从倒立摆模型得出的落脚点参考适应实际情况。

强化学习简单性和自主学习特性为探索人形机器人的运动能力和扩展步态空间提供了潜力。然而强化学习通常需要精心设计奖励函数来塑造策略行为，仅仅覆盖了运动能力的一小部分。另外，将学习到的策略部署到机器人硬件上时，常常会遇到模拟到现实的差距问题，这是由模拟器使用的不准确物理模型所导致的，也是一个亟待解决的课题。

1.2.3 基于本体感知的地形预测方法

在自主机器人系统中，视觉与激光雷达等外部传感器虽然具备较高的环境感知能力，但其在复杂或低能见度环境（如夜间、浓烟、雨雪等）下存在感知失效、遮挡严重、能耗高或成本大的问题。相较之下，基于本体感知的地形感知方法由于其对外界条件依赖性低、鲁棒性强等特点，近年来受到广泛关注。

Brooks 等人^[59]通过分析车载加速度计采集到的振动数据，采用波形描述并结合主成分分析（PCA）进行在线地形分类，将地形划分为砾石、泥土、沙地和未分类四类，在多个实验场景中实现了 96% 至 100% 的分类置信水平，验证了振动模式在地形识别中的判别能力。Dupont 等^[60]进一步提出了一种基于频率响应特征的振动分析方法，利用快速傅里叶变换（FFT）提取地形信号的频域特征，用于识别不同接触地面类型。该方法无需构建复杂模型，计算效率较高，适合在线部署。Giguère 等^[61]则针对传统触觉与视觉系统集成难度大、环境适应性差等问题，提出了一种安装于移动平台轮缘的触觉探针系统。该系统不依赖具体机器人结构，具有良好的可移植性，在地形分类任务中取得了 94.6% 的准确率，显示出本体感知在实际机器人平台上的应用潜力。

此外，Bai 等人^[62]结合多源传感器（如 IMU、力传感器等），提出了一种多模态融合的地形识别方法，将地形细分为砖块、沙地、平地、水泥与土壤五类，利用深度学习模型实现了更精细的分类能力。Nampoothiri 等^[63]则聚焦于利用 IMU 信号实现实时地形分类，其研究覆盖 23 种机器学习算法进行对比评估，在复杂导航任务中展示了良好的泛化能力和实时性。近期，Mariela 等^[64]提出了一种融合不确定性建模的神经网络方法，基于本体感觉信号有效提升了地形分类结果的可靠性与透明度，特别适用于太空探测等对可解释性要求较高的领域。

综上所述，基于本体感知的地形预测方法不依赖外部视觉或激光输入，而是通过对机器人内部状态变量的分析，实现地形类型的自动识别与预测。随着传感器精度提升及学习算法的发展，本体感知地形识别有望为复杂地形下机器人稳定运动控制与自适应策略切换提供更加可靠的信息支撑。

1.3 主要研究内容

多地形步态规划是双足机器人领域的一个复杂且关键的问题，即人形机器人要在不同的地形上稳定行走，包括但不限于平坦地面、崎岖地面、斜坡、台阶等。

目前人形机器人在多样地形上行走的策略，往往具有以下特点：

- **依赖参考轨迹：**机器人采用模型控制优化的行走方式通常高度依赖参考轨迹，使其在复杂的随机地形上难以灵活适应；
- **优化目标冲突：**机器人依赖单一强化学习策略神经网络实现跨地形泛化行走，不同地形的优化目标冲突易导致训练过程出现震荡或收敛至次优解；
- **缺乏可解释性：**强化学习策略的黑箱特性使得调优过程难以解释，无法保证单方向调优后对其他地形策略的持续记忆性。

基于以上特点，本研究旨在探索面向复杂多地形的人形机器人动态步态规划方法，通过融合残差补偿机制与本体感知地形分类策略，构建一个具备泛化能力与适应性的强化学习框架。

- **主干策略网络**学习跨地形通用的基础步态行为，并在无需依赖显式人工参考轨迹的前提下，提供稳定的运动策略作为底层支持，有效规避了传统模型优化方法中对精细轨迹规划的高度依赖。
- **残差补偿子网络**针对性对应不同地形，各子网络以地形分类结果为条件独立训练，使得策略优化过程具有明确的功能划分和互不干扰的目标指向，从而提升训练稳定性与最终策略性能。
- **本体感知地形分类器**实现对当前地形类型的精准识别，并作为控制信号引导对应残差模块的激活与更新，使得整体框架具备良好的可解释性与调试便利性。

针对多地形步态生成的方案可以为多任务强化学习研究提供重要的理论参考和实践启示。从整体来看，深入研究人形机器人的多地形步态规划问题，不仅能够提升机器人在实际应用中的适应性和效能，还将推动机器人技术的全面发展，为人形机器人领域的技术革新提供重要支撑。

1.4 论文结构

本文共包含 5 章，结构如下：

第 1 章阐述了开展人形机器人多地形强化学习步态规划研究的目的与意义，回顾了人形机器人及人类步态行为研究的背景，并对相关领域的研究现状进行了综述。

第 2 章围绕人形机器人多地形行走任务，系统阐述了仿真系统的基础架构，包括仿真平台的构建、环境的设置以及仿真对象的搭建过程，为后续的策略训练提供了实验基础。

第 3 章提出了一种创新的基于残差补偿的两阶段强化学习步态生成方法，并通过“山地小车”这一简化控制任务验证了该方法的有效性。

第 4 章介绍了一种基于人形机器人本体感觉的步态选择方法，系统对比了在不同分类输入和网络结构条件下的分类选择性能，并最终选取了最优的网络结构。随后，在多地形仿真场景中开展实验，全面评估并分析了所提出人形机器人步态策略在不同环境下的性能表现。

第 5 章对本文的研究工作进行了总结，回顾了研究的主要贡献，并对未来的研究方向提出了展望。

第 2 章 人形机器人的仿真系统搭建

本章主要探讨人形机器人的仿真系统搭建，旨在为后续的多地形行走策略研究提供可靠的仿真平台。通过复现基于单阶段 PPO 算法的训练环境，并结合 NVIDIA Isaac Gym 平台的高性能特性，构建了包含多样化地形和动态交互特征的仿真系统。本章详细介绍了仿真系统的架构设计、环境构建、仿真对象的建模与控制策略的初步设计，并探讨了域随机化技术在提升策略泛化能力中的应用。通过这些研究内容，本章旨在为后续章节中人形机器人多地形行走策略的优化与验证奠定坚实的基础。

2.1 仿真系统基础架构

在解决人形机器人多地形行走问题之前，本研究基于 RobotEra 开源项目^[65]，复现了使用单阶段 PPO 算法解决人形机器人行走问题的训练环境。其系统流程如图2.1。




图 2.1 单阶段 PPO 强化学习方法训练环境流程图

系统的各组成部分包括如下三个模块：

- **Simulator 1**: 用于强化学习训练过程的仿真平台，构建训练环境。
- **Simulator 2**: 用于策略验证与性能评估的独立仿真测试平台。

- **Robot:** 目标部署平台，为实际机器人系统，用于检验强化策略的最终效果。

该系统旨在克服仿真-真实差距，实现策略从仿真到真实机器人的迁移部署，其操作流程如下：

1. 为了实现真实-仿真映射，对真实机器人 **Robot** 进行了建模，导入其相关结构描述文件，并在 **Simulator 2** 中构建性能评估的测试环境。
2. 同样基于上述模型信息，在 **Simulator 1** 中构建用于训练的仿真场景。
3. 在完成训练后，将 **Simulator 1** 中获得的策略应用至 **Simulator 2** 中进行验证测试，确认策略在不同仿真环境中的表现一致性。
4. 若策略在测试仿真中表现可靠，则可进一步迁移至真实机器人平台，检验其在现实环境下的实际效果，即实现仿真-真实映射。

该系统的核心优势在于通过分阶段的仿真模拟部署，提高策略从虚拟环境到真实平台的泛化能力，其具体优点包括：

- 借助多样化的仿真环境进行策略验证，可提升模型在复杂或未见环境下的适应能力，降低模型对单一仿真场景的依赖，增强其在现实世界的鲁棒性。
- 通过在不同模拟器中对环境参数（如物理特性微调等）进行系统性测试，可深入分析环境不确定性对策略性能的影响，为实际部署前的策略稳定性提供理论支持。
- 相较于直接在真实机器人上进行试验，仿真平台具备更高的安全性与低成本特征，有助于在风险可控的前提下进行多轮优化与调试。

由于本研究不具备进行真实机器人策略迁移的条件，不涉及 **sim-to-real** 验证，训练和测试集中于机器人在 **simulator 1** 中的表现，但系统架构保留了相关接口以便于后续进一步研究。

2.2 仿真环境构建

本研究中的强化学习训练环境构建依托于 **NVIDIA** 推出的高性能仿真平台 **IsaacGym**^[66]，其具备全流程 **GPU** 加速特性，能够在保持高仿真精度的前提下显著提升训练效率。由于步态规划涉及多种地形适应与稳定控制策略的学习，通常需要海量的交互数据与长时间的训练过程，而 **IsaacGym** 的全 **GPU** 架构使得环境的并行化成为可能，从而允许在单次迭代中并发运行成千上万个环境实例，极大提升了样本生成速率与策略收敛速度。在物理建模方面，该平台集成的物理引擎能够细致还原机器人在多种复杂地形上行走时的动力学响应与接触力变化，确保





图 2.2 宇树 G1 机器人在平坦地形上训练



障碍物地形（上左）、离散崎岖地形（上右）、坡地地形（中）、台阶地形（下）

图 2.3 复杂训练环境地形示意图

了训练过程中所获得策略具备良好的现实可迁移性和鲁棒性，为多地形步态生成提供了可靠的仿真基础。

为了支持控制策略的多特征头网络训练，本研究在仿真系统中构建了多样化的行走环境，以充分模拟现实中可能出现的各种地形变化及其对机器人运动控制带来的挑战。本研究将行走环境划分为基础环境与复杂环境两类。其中，基础环境指代无障碍的平坦地形如图2.2所示，该类地形具有结构规则、表面连续的特点，主要用于训练机器人在理想条件下的基本稳定性与共性行走策略。而复杂环境则包括带有障碍物的地形、离散崎岖地形、坡地以及台阶等如图2.3所示，这些环境因地形结构不规则、接触面变化剧烈或存在高度差异，对人形机器人的动态平衡控制与足端落点策略提出了更高要求。

具体而言，障碍物地形通常包含若干固定或随机分布的立体障碍，机器人需具备应对突发地形干扰的躯干姿态调整能力，维持前进稳定性；离散崎岖地形由非连续接触面组成，考验机器人在不确定支撑条件下的动态稳定性与步态调整策略；坡地带来额外的重力分量投影变化，对机器人前向推进力与躯干俯仰控制形成挑战；而台阶地形则具有显著的高度突变，要求机器人能够准确感知落脚点位置，并在执行抬腿与落脚动作时确保重心转移的连贯性与安全性。

为进一步提升环境多样性与任务挑战性，仿真过程中对地形参数、初始状态扰动及外部干扰力进行了随机化设计。例如，在复杂地形中引入随机高度障碍、变化坡度角以及不规则布设的离散支撑面，模拟现实中地形不确定性对步态稳定性的冲击。同时，通过添加随机外力干扰，增强了训练策略对扰动的鲁棒性，有助于获得更具泛化能力的控制策略。这些机制共同构建了一个具备丰富动态交互特征的训练环境，为后续人形机器人多地形自适应行走策略的学习提供了坚实基础。

2.3 仿真对象构建

本研究选用由 Unitree Robotics 公司推出的 G1 人形机器人作为仿真对象，其具备高度集成的结构设计与较强的运动能力，适用于多种人形机器人步态规划与控制算法的验证。G1 机器人采用全身 17 自由度配置，其中双腿各具备 6 自由度，双臂各具备 3 自由度，另包含 1 个腰部自由度，具有人体对称的运动结构。该结构不仅能覆盖大多数人形机器人在行走、起伏和转向中的运动需求，也为本研究中基于本体感觉的步态规划算法提供了充分的动作空间。

G1 的整机高度为 1.27 m，自重约 47 kg，具备较高的动力输出能力：单关节峰值扭矩达到了 360 N·m，关节最大速度可达 40 rad/s，驱动采用高性能无刷电机搭配高精度谐波减速器。为了实现仿真中精确的运动建模与控制策略部署，本研究基于其官方公开的完整的 URDF 模型，搭建了强化学习仿真对象。

在步态规划过程中，足端轨迹的规划通常基于正运动学模型完成。通过正运动学可由关节空间变量映射得到末端在三维空间中的位置，从而实现足端轨迹跟踪，进而分析步态特征。设腿部关节角向量为 $\theta \in \mathbb{R}^6$ ，对应的足端位置可表示为：

$$\mathbf{p}_{\text{foot}} = f(\theta), \quad (2.1)$$

其中 $f(\cdot)$ 为正运动学函数，通常由一系列刚体变换矩阵组成。具体地，对每个关节使用齐次变换矩阵 $\mathbf{T}_i$ 表示，从髋部坐标系出发，足端在世界坐标系中的位置可通过链式乘积获得：

$$\mathbf{T}_{\text{foot}} = \prod_{i=1}^6 \mathbf{T}_i(\theta_i), \quad \mathbf{p}_{\text{foot}} = \mathbf{T}_{\text{foot}}(1 : 3, 4). \quad (2.2)$$

本研究构建了具备地形感知能力的人形机器人运动策略，采用两阶段强化学习方法训练控制器。每一阶段的强化学习问题均可建模为马尔可夫决策过程 (MDP)，形式化表示为 $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, r, \gamma \rangle$ ，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别表示状态空间与动作空间， $T(s' | s, a)$ 为状态转移概率函数， $r(s, a)$ 为奖励函数， $\gamma \in [0, 1]$ 为折扣因子。训练的目标是通过策略 $\pi(a_t | s_t)$ 最大化累积折扣回报，其定义如下：

$$\max_{\pi} J(\mathcal{M}, \pi) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right]. \quad (2.3)$$

考虑到实际机器人在感知层面存在一定的局限性，例如控制噪声、信息延迟以及观测缺失等问题，尽管在仿真环境中可以获取系统的完整状态信息，本研究在策略训练过程中，将每阶段任务进一步建模为部分可观测马尔可夫决策过程 (POMDP)，即训练过程中仿真对象仅基于部分观测量（如关节状态、足端接触信息等）进行决策，以更贴合真实系统的感知特性。这种建模方式不仅提高了策略对复杂地形和干扰的适应能力，也增强了其在现实机器人控制中的稳定性和实用性。

2.3.1 动作空间

为实现在人形机器人仿真对象关节运动的精细控制，本研究将控制策略的输出定义为关节角度相对于一组预设中性姿态的偏置量。中性姿态下各关节角度值

组成的向量称为初始关节配置，用于在动作输入为零时生成目标姿态。该配置涵盖了双腿的 12 个主要关节，具体数值如下：

$$q_{\text{init}} = \begin{bmatrix} 0, & 0, & -0.1, & 0.3, & -0.2, & 0, & 0, & 0, & -0.1, & 0.3, & -0.2, & 0 \end{bmatrix}^T$$

上述角度值依次对应左腿与右腿的：髋关节水平旋转（yaw）、髋关节侧向摆动（roll）、髋关节前后摆动（pitch）、膝关节、踝关节前后俯仰（pitch）以及踝关节侧向翻转（roll）六个自由度。

动作空间中每一个维度表示对对应关节角度的偏移量，其值域被约束在 $[-1, 1]$ rad 范围内，从而构成一个 12 维的动作向量 $a \in \mathbb{R}^{12}$ 。机器人在每个控制周期的期望关节角位置由以下公式计算：

$$\hat{q} = q_{\text{ref}} + \Delta q_{\text{act}}, \quad (2.4)$$

该期望角度被输入至式2.5表示的 PD 控制器，计算产生所需关节力矩并发送至仿真环境电机，实现精确的姿态调整。其中 K_p 和 K_d 是比例-微分控制参数对角矩阵。

$$\tau = K_p(\hat{q} - q) + K_d(\dot{\hat{q}} - \dot{q}) \quad (2.5)$$

值得指出的是，本文选择基于角度偏置进行策略输出而非直接预测绝对角度，其优点主要包括：

- 相较于直接学习绝对角度，学习相对偏移量能够显著降低策略搜索空间，有助于提升训练效率；
- 该表示形式具备更强的通用性与可迁移性，在不同机器人模型或任务环境之间迁移时，能保留原始姿态结构，仅需对偏置部分进行微调；
- 当前初始关节配置已接近静态稳定结构，因此仅需在此基础上施加微小调整以实现多样化动作，从而简化策略的学习目标。

该设计理念在近年来的多个研究工作中得到了验证，并已被广泛应用于人形机器人控制策略的构建中，具有良好的实用性与泛化能力。

2.3.2 状态空间

本研究中，状态空间的设计旨在为策略网络提供充分但不冗余的自身运动状态信息，从而支持其在多样环境中的鲁棒性与泛化能力。整体状态空间由 47 个维度构成，涵盖了机器人底座的角速度、重力方向投影、期望控制指令、关节状态、历史动作以及周期相位信息，具体变量构成详见表2.1。

该状态空间在构建过程中充分权衡了可观测性、系统稳定性与实际部署的可

实现性。通过引入关键变量如底座角速度、关节状态及历史动作输入等，使策略具备应对复杂动态变化的能力；同时，周期相位信息有助于策略在处理周期性任务（如步态控制）时保持时间一致性和结构性表达。

此外，为增强策略在不同仿真环境及未来真实系统中的迁移能力，Actor 状态空间中刻意排除了某些在现实中难以准确获取的观测量（例如高频接触力），仅保留了跨平台均可稳定感知的核心指标。但如表2.1所示，本研究为 Critic 模型引入了额外的特权信息，包括推力扰动、扫描高度图等。这些信息在模拟环境中可轻松获取，因而被用于辅助 Critic 的训练，以提升整体训练效率与策略收敛速度。

表 2.1 状态空间各组成变量

状态组件	维度	Actor 可见	Critic 可见
周期相位	2	✓	✓
控制命令	3	✓	✓
角速度	3	✓	✓
重力方向投影	3	✓	✓
关节角度偏差	12	✓	✓
关节速度	12	✓	✓
历史动作输入	12	✓	✓
摩擦系数	1		✓
即时奖励值	1		✓
足端接触状态	2		✓
底座线速度	3		✓
推力扰动	6		✓
电机输出力矩	12		✓

综上所述，Actor 网络所使用的状态空间在信息量与可实现性之间取得了良好平衡，而 Critic 模型则通过引入特权信息进一步增强了对任务结构的建模能力，从而提升了整体训练过程的效率与策略性能。

2.3.3 域随机化

域随机化技术在解决仿真与现实之间的迁移偏差问题上表现出显著成效，尤其在基于强化学习的人形机器人控制策略中展现了强大的适应能力。该方法通过在仿真环境中引入具有代表性的随机变量，在训练阶段主动模拟现实环境中的各

种不确定性，从而提升策略在复杂、动态且不可预知的真实场景中的泛化能力。借助强化学习无模型的优势以及神经网络的强表达能力，只要仿真中引入的随机扰动在分布上能够覆盖或接近现实环境的变化范围，便可在无需对真实系统精确建模的前提下，获得鲁棒性较强的控制策略。

在人形机器人控制任务中，由于系统结构复杂、控制精度要求高，策略能否成功迁移往往依赖于域随机化设计的合理性与全面性。为此，本研究在训练过程中对一系列关键因素进行了系统性的扰动处理，涵盖了躯干状态观测误差、观测与执行时延、质心偏移、重力加速度、地面摩擦系数和弹性系数等物理环境属性。上述参数均在每轮训练初始化及仿真对象失败重置时重新采样，并在每一轮完整的探索过程中保持不变，以确保策略在多样化训练环境中的一致性与稳定性。表2.2详述了各随机化参数的取值范围及实施方式。

表 2.2 域随机化相关参数设定

参数名称	理论值	施加方式	范围	分布
组件质量	各组件固定质量	比例	$[-5.0, 5.0]$	均匀
摩擦系数	0.8	比例	$[0.1, 2.0]$	均匀
质心偏移	0.0	叠加	$[-0.05, 0.05]$	均匀
控制时延	0.0	叠加	$[5, 40]$	均匀
动作延迟	0.0	叠加	$[0.0, 0.5]$	均匀
动作噪声	0.0	叠加	$[0.00, 0.02]$	均匀
外力干扰	0.0	叠加	$[-15.0, 15.0]$	均匀

2.3.4 其他设置

初始状态：理想的初始状态为机器人关节处于如节2.3.1中所述基准姿态，然而，考虑到实际应用中初始条件通常具有不可预知性与高度变异性，为提升仿真对象在复杂现实环境中的泛化能力，本研究在初始状态生成过程中引入了随机扰动机制。具体而言，在初始关节角位置上施加服从均匀分布 $U(-1, 1)$ 的扰动，同时在初始关节角速度上引入服从 $U(-0.5, 0.5)$ 的随机扰动。此种初始状态的随机化处理有助于增强仿真对象对状态空间多样性的探索能力，避免其训练过程局限于固定或有限的状态区域。例如，仿真对象可能从部分与地面接触或完全悬空的状态启动，从而促进其学习如何在复杂初始条件下实现稳定着地与动态平衡的能力。

提前终止：人形机器人的运动规划可以建模为一个无限时域的马尔可夫决策过程，所期望获得的策略应具备长期稳定运行的能力。为防止仿真对象在训练过程中陷入不可恢复的失败状态，仿真对象引入了提前终止机制：当机器人髋部与地面发生接触，即被判定为跌倒事件，系统将立即终止当前回合并重置环境状态。此机制不仅可加速训练过程、避免资源浪费，还显著提升了数据采集效率与样本质量，从而有助于获得更具表现力的策略模型。

2.4 小结

本章通过对人形机器人仿真系统搭建的详细研究，成功实现了一个具备高效率、高精度和强泛化能力的仿真平台。在仿真环境构建中，通过引入多样化地形和随机化机制，增强了策略对复杂环境的适应能力。同时，针对 G1 人形机器人设计的动作空间和状态空间，为策略学习提供了高效且实用的框架。此外，域随机化技术的应用进一步提升了策略的鲁棒性。本章的研究成果为后续章节中多地形行走策略的优化提供了坚实的仿真基础。

第 3 章 基于残差补偿的两阶段强化学习步态生成方法

本章聚焦于基于残差补偿的两阶段强化学习方法，旨在通过创新的算法设计和训练策略，提升人形机器人在复杂地形下的运动表现与策略迁移能力。首先，本章对强化学习算法进行了简述，重点介绍了 Actor-Critic 算法及其改进型近端策略优化（PPO）算法的基本原理和优势。在此基础上，提出了多特征头残差补偿机制，通过主干网络与特征头网络的协同作用，实现对复杂地形环境的动态适应。进一步，本章设计了两阶段训练方法，将通用步态策略学习与地形特异性残差适应过程分离，以提高训练效率和策略稳定性。最后，通过实验验证了算法的有效性，并在人形机器人平台上进行了行走策略训练，展示了该方法在多地形环境下的优越性能。

3.1 强化学习算法简述

强化学习是一种通过智能体与环境交互来学习最优行为策略的机器学习方法。智能体通过在环境中采取行动，以最大化累积奖励为目标，根据环境反馈的奖励来调整自己的行为策略，进而收敛到最优控制解。




图 3.1 Actor-Critic 方法结构框架图

如图3.1，Actor-Critic 算法将整个强化学习系统划分为两个核心组件：Actor 和 Critic。其中，Actor 负责根据当前的状态 s_t 和策略 π 来选择行动 a ，其目标是

通过不断调整策略参数 θ ，使得智能体在环境中采取的行动能够最大化长期累积奖励 r ；而 Critic 专注于对 Actor 所采取的行动及其产生的结果进行评估，它通过学习一个价值函数 $V(s_t)$ 来估计在当前状态下采取特定行动所能够获得的预期回报，为 Actor 提供关于策略改进方向的指导。

PPO 是在 Actor-Critic 方法基础上的一种改进型强化学习算法，相比于传统的策略梯度方法在更新策略时容易出现步长过大的问题，PPO 通过引入剪切概率比或信赖域惩罚项等机制，有效限制了新旧策略之间的差异，确保策略的更新更加平稳和可靠，在多个实际任务中表现出良好的性能与鲁棒性，成为当前强化学习领域中应用广泛且效果突出的策略优化方法之一。

3.2 多特征头残差补偿机制

在对人类在复杂多变地形上行走行为的观察与分析中发现，尽管行走环境的地形特征存在显著差异，但个体在行走过程中所呈现出的步态模式仍表现出一系列共性特征。这些共性特征涵盖了步态的多个关键要素，例如步态周期的相对稳定性、步态节律的内在协调性以及身体重心的动态平衡维持机制等。这些共性特征的存在表明，在行走过程中，人体运动系统在整体运动策略上呈现出高度的一致性，以确保在复杂地形条件下的行走稳定性和效率。然而，这种一致性并非意味着个体步态的绝对统一，而是在整体运动模式的基础上，个体在抬腿高度、踝关节角度等具体运动参数上会根据地形的具体特征和行走需求产生相应的适应性调整。

基于上述观察结果，并结合残差补偿机制（如图1.9）良好的可扩展性、灵活的特征融合能力以及对分布迁移的鲁棒性，本研究提出了一种残差强化学习框架。残差补偿机制能够有效叠加基础动作与特征动作，实现对复杂地形环境的动态适应。具体而言，该框架包括一个主干网络（backbone）和多个特征头（head）。其中，主干网络采用完整配置的 PPO 算法，输入环境特征、自身状态及参考轨迹等信息，输出基础动作，旨在学习步态的通用特征模式；特征头则采用结构简化的 PPO 网络，输入基础动作以及地形附加特殊信息（如视觉、深度信息等），输出针对性的动作补偿值，用以增强基础动作对特定地形环境的适应性。

通过引入多特征头残差补偿机制，可以针对不同地形条件分别设计奖励函数，使策略优化过程在各自任务需求下独立进行，有效缓解了多地形训练中潜在的优化目标冲突，显著提升了策略训练的稳定性与收敛效率。在此基础上，该机制能

能够在维持步态统一基础模式的前提下，根据地形特性实现细粒度的动态调整，既加速了训练过程，又增强了步态的拟人性与观赏性。进一步地，因各特征头与特定地形场景相对应，策略性能在不同环境中的表现具有明确可解释性，训练中若出现特定地形下性能不足的问题，可通过针对性强化相应特征头或调整奖励结构，快速实现策略优化与性能提升。

3.3 两阶段训练方法

为实现前文所提出的残差强化学习策略，并进一步提升人形机器人在复杂地形下的运动表现与策略迁移能力，本研究设计了一种两阶段的策略训练方法。该方法通过将通用步态策略的学习与地形特异性的残差适应过程进行分离，实现残差学习模块在稳定基础策略上的高效训练与有序集成。通过阶段化训练框架，先获取具备良好泛化能力的基础步态策略，再在此基础上引入并训练地形相关的残差模块，从而构建具备强鲁棒性与适应性的分层运动控制策略。

Training Stage I




图 3.2 基础策略学习阶段训练方法结构框架图

第一阶段：基础策略学习阶段，机器人在平坦地形环境中进行训练，采用标准的强化学习算法，仅使用一个主干策略网络（如图3.2）对其进行优化，以获得稳定可靠的基础步态行为。该阶段的目标是学习具备良好泛化能力的通用步态策略，为后续多样地形任务提供统一的运动先验。在此阶段不引入任何与地形相关的专用模块，确保所学策略对环境扰动保持鲁棒性。

第二阶段：残差增强阶段，固定主干策略网络的参数，在其输出基础上引入一个专用的残差特征头网络（如图3.3），并在特定复杂地形（如斜坡、不平整表面、障碍物、台阶等）环境中进行训练。该残差网络根据主干输出动作和环境特征输出修正动作，捕捉地形扰动对策略的影响，实现对基础策略的补偿与调整。




图 3.3 残差增强阶段训练方法结构框架图

通过对适应模块的独立训练，该策略结构能够在保持原始步态稳定性的基础上，有效增强对不同地形的适应能力。

该两阶段训练框架充分利用模块化策略设计的优势，使主干网络负责通用运动能力的学习，而残差头网络专注于地形感知与动态调整，从而实现高效、鲁棒的跨环境步态生成与迁移。

3.4 算法有效性验证


由于人形机器人的运动控制系统在结构和参数上都具有高度非线性与复杂耦合，直接以此作为强化学习系统的研究对象，会引入众多不确定因素，给算法验证与性能评估带来较大挑战。

OpenAI Gym 强化学习训练环境库中的“山地小车”（MountainCarContinuous-v0）作为经典的连续控制问题，具备明确的目标函数和较为简洁的动力学模型，常被用于验证各类强化学习方法在处理连续状态与动作空间问题上的有效性。通过该任务，可以对策略学习过程中的收敛性、稳定性及泛化能力进行直观且系统的评估，并为后续复杂场景中的算法迁移和性能提升提供理论与实践基础。

因此，本研究以“山地小车”环境作为实验平台，完成了强化学习系统的初步构建与有效性验证，具体过程如下。

3.4.1 测试仿真环境搭建

“山地小车”仿真环境对应一个确定性的马尔可夫决策过程，其中小车初始位置随机分布于平面或一个正弦波形的山谷底部。智能体可执行的动作为连续空间中的加速度控制，目标为通过合理加速策略，使小车到达右侧的目标状态。



平坦地形（左）、正弦山地地形（右）

图 3.4 “山地小车”仿真环境示意图

如图3.4，为了验证所提出的两阶段训练的多特征头残差补偿机制的有效性，本研究在实验中分别设置了两种场景：一是在平坦地形上的小车模型作为主干网络的训练场景，另一是在正弦山地结构中的小车模型作为残差特征头的训练场景。小车的运动学模型遵循如下状态转移动力学：

$$x_{t+1} = x_t + v_{t+1} \quad (3.1)$$

$$v_{t+1} = v_t + w_F \cdot F - w_g \cdot g \cdot \cos \theta_x \quad (3.2)$$

其中， F 表示小车所受动力，其取值限制在区间 $[-1, 1]$ 内； w_F 和 w_g 为恒定的缩放因子。 x_t 表示小车在时刻 t 的位置，其取值范围为 $[-1.2, 0.6]$ ； v_t 为对应时刻的小车速度，限制在区间 $[-0.07, 0.07]$ 内。当小车运动至轨道两端并与墙壁发生碰撞时，视为完全非弹性碰撞，其速度 v_t 将被重置为零。 g 为重力加速度， θ_x 表示小车当前位置处坡面的倾角，用以计算重力在坡面方向上的分量。

3.4.2 实验参数设置

本实验的策略训练在一台配备 NVIDIA GeForce RTX 3060 Laptop GPU 与 AMD Ryzen 7 CPU 的工作站上完成，保证了模拟交互与神经网络迭代的效率。

3.4.2.1 动作空间

策略输出小车的期望力 F ，动作空间是连续的，范围为 $[-1.0, 1.0]$ 。实际控制过程中，将动作 F 发送至环境系统中用于驱动车辆。

3.4.2.2 状态空间

状态空间为 2 维，包含小车的位置和速度，具体如表 3.1 所示：

表 3.1 状态空间变量

状态量	维数	备注
x	1	小车位置
$\dot{x}$	1	小车速度

3.4.2.3 奖励函数

奖励函数鼓励智能体尽快将小车移动到山顶终点位置（即目标状态 $x \geq 0.45$ ），奖励函数的表达式如式3.3所示：

$$R = \begin{cases} 100 - 0.1 \cdot a^2, & \text{若当前位置达到目标位置} \\ -0.1 \cdot a^2, & \text{否则} \end{cases} \quad (3.3)$$

其中， a 表示当前时刻智能体所输出的连续动作值，即施加在小车上的力大小，该动作值的正负分别表示向右或向左施加力的方向。

该奖励函数的设计意图如下：

- 惩罚较大动作幅度，约束输出的能耗；
- 惩罚回合持续时间长，引导策略尽早达到目标；
- 若小车达到目标位置（右侧山顶 $x \geq 0.45$ ），获得额外奖励 +100。

3.4.3 实验内容设计


由于基于本体感觉的地形分类方法采用的是结构成熟、性能稳定的 MLP 或 LSTM 模型，其有效性已有充分验证，故本研究仅初步验证两阶段多特征头残差补偿强化学习方法的有效性与优越性，设计并开展了如下两组实验：

- 实验一：在不同坡度弧度的正弦山地环境中进行训练与测试，分析智能体在不同地形下的任务完成情况，验证算法的有效性；
- 实验二：将所提方法与传统强化学习策略进行对比，基于训练过程中的收敛轮次评估其训练效率，从而验证该方法在收敛速度方面的优势。

3.4.4 实验结果与分析

本实验训练流程采用上述两阶段训练方法：第一阶段仅使用平坦地形环境对主干策略网络进行训练，促使模型学习基础动力学规律和通用控制策略；第二阶段则固定主干网络参数，仅对附加的残差特征头网络进行训练，并仅与正弦波地形环境交互，从而在保留主策略稳定的基础上实现对复杂地形的补偿与增强。

实验一：分别在不同坡度与弧度组合构成的正弦山地环境中训练和测试智能体，以评估所提出的两阶段多特征头残差补偿强化学习方法在适应复杂地形中的表现。如图3.5所示，主干网络在平坦地形（ $y = 0$ ）上完成训练后，残差特征头网络则在形如 $y = 0.45 \cos 3x$ 和 $y = 0.25 \cos 3x$ 的复杂地形中继续训练。实验结果表明，该方法不仅能够在复杂地形下保持良好的训练稳定性，还展现出较强的鲁棒性与适应能力。同时，智能体在完成第二阶段训练后，其控制策略更加精细，能够有效应对地形带来的动态不确定性，进一步提升了整体运动的连续性与稳定性。



平坦地形主干网络训练（左）、正弦山地地形残差特征头网络训练（右）

图 3.5 两阶段方法训练奖励曲线

实验二：对比了两阶段多特征头残差补偿策略与传统单网络 PPO 策略在相同训练环境中的收敛速度与性能表现。如图3.5与图3.6所示，传统 PPO 策略需从零开始在复杂地形中直接训练，通常需要约 20 轮才能收敛。而两阶段方法在完成主干策略网络 1 轮基础训练后，仅需约 7 轮即可完成特征头网络的训练，总训练轮次显著减少。分析表明，主干网络在平坦地形中所获得的基础策略不仅降低了策略搜索空间，也为特征头提供了参考动作轨迹，有效减少了无效探索区域，提升了训练效率。

综上，实验结果表明，所提出的两阶段多特征头残差补偿强化学习方法在复杂地形任务中展现出良好的训练稳定性、策略鲁棒性与地形适应能力。通过在平坦地形中预训练主干策略网络，有效引导了智能体学习通用控制规律，减少了在复杂地形中策略搜索的难度；随后在保留主策略稳定性的基础上引入残差特征头网络，进一步提升了对地形扰动的响应能力。与传统单网络 PPO 策略相比，该方法在训练轮次上显著减少，同时在策略收敛速度与最终性能方面均表现出优越性。实验验证了该结构化训练机制在多地形环境中的策略迁移能力和泛化性能，说明所提出的方法不仅有助于提升策略在复杂任务中的表现，也为后续实现强化




图 3.6 单阶段 PPO 强化学习方法训练奖励曲线

学习控制策略在多变环境下的快速部署与优化提供了可行路径和实验依据。

3.5 人形机器人行走策略训练

在完成算法有效性验证后，为在人形机器人平台验证基于残差补偿机制的强化学习方法，本研究设计了分层策略网络结构，包含主干网络与 5 个多特征头子网络两个组成部分。主干网络基于具备循环神经网络记忆机制的 Actor-Critic 结构设计，前馈部分首先通过一个具有 64 维隐藏状态、单层结构的 LSTM，以建模观测量输入时间序列中的时序相关性；随后，输出经过包含三层 MLP 的网络进行进一步特征提取，每层隐藏维度设定为 32，激活函数统一采用指数线性单元（ELU），以提升非线性表达能力并避免梯度消失问题。在 5 个多特征头结构中，每个特征头均为独立的 Actor-Critic 子网络，采用与主干网络结构相同的三层 MLP 结构，激活函数同样为 ELU。每个特征头的设计旨在适配不同环境特征或任务需求，从而增强策略网络对多样化输入的响应能力与泛化能力。初始化时，主干网络和特征头网络分别设置了初始噪声标准差为 0.8 和 1.0，以促进策略在训练早期的探索行为。模型相关详细参数如表3.2所示。

在训练过程中，智能体所在的仿真环境以 50Hz 的频率接收策略网络输出的动作指令，并同步返回相应的观测信息和奖励信号。与此同时，物理引擎和底层的 PD 控制模块以 200Hz 的速率持续运行，以确保动态响应的高精度和控制的稳定性。训练与测试工作在一台配备 NVIDIA GeForce RTX 4090（24GB）GPU 和 Intel Xeon Platinum 8352V @ 2.10GHz CPU 的工作站上进行，该硬件配置能够支持多并行仿真环境下的高效训练。

表 3.2 训练参数

参数	值
训练环境数量 n	4096
折扣因子 γ	0.99
GAE 平滑参数 τ	0.95
截断参数 ϵ	0.2
熵项系数	0.01
学习率	1×10^{-3}
学习轮次	5
损失函数中 Value Loss 权重	1.0

3.5.1 奖励设计

奖励函数 $R(s)$ 定义为多个子奖励因子的加权求和，最后经截断以确保非负，具体形式如式3.4所示：

$$R(s) = \max \left(\sum_j \omega_j r_j(s), 0 \right) \quad (3.4)$$

其中，各项 $r_j(s)$ 分别表示第 j 类子奖励，其在总体奖励中的影响由权重系数 ω_j 决定。

为适应不同地形在结构特征与动态稳定性要求方面的差异性，本研究基于残差补偿机制的强化学习方法，针对各类地形特征头设置了差异化的奖励因子权重，或设计了专属的奖励函数，以增强策略在特定地形上的适应能力与表现。

台阶地形由于其显著的几何不连续性以及对机器人动态平衡与精确落足的高度要求，成为强化学习奖励机制设计中具有代表性的关键场景，本文以下将以其为例进行阐述。在其对应的奖励函数中，本文通过提高期望的抬腿高度及其相关奖励项的权重，以增强机器人在应对台阶障碍时的抬腿能力。此外，参考 BeamDojo 方法^[52]，引入了落脚点位置检测机制，用以鼓励机器人在落足过程中将更多的脚部接触面积覆盖于台阶表面，从而提高落足稳定性。该项奖励的计算公式如下所示：

$$r_{\text{ContactPosi}} = - \sum_{i=1}^2 \sum_{j=1}^n \mathbf{1}\{d_{ij} < \epsilon\} \quad (3.5)$$

其中， d_{ij} 表示机器人第 i 条腿第 j 个接触点与其正下方地面之间的垂直距

离, ϵ 为设定的离地高度阈值, $\mathbf{1} \cdot$ 为指示函数, n 为接触检测点数量。当机器人足部落点接近台阶边缘时, 与地面距离较大的监测点数量相应增加, 从而导致惩罚项增大。该设计旨在通过对落足不稳定行为的惩罚, 引导策略趋向于选择更加稳定、安全的落足区域, 从而提升整体行走的鲁棒性与动态平衡能力。

为满足任务目标, 整个奖励系统可划分为三大模块: 正则化奖励、姿态调控回报、以及行为执行反馈。

正则化奖励部分旨在削弱策略中可能出现的高频震荡, 通过惩罚关节速度、加速度、关节扭矩, 以及动作变化速率, 有助于促使策略倾向于生成更加平滑且能量效率更高的动作轨迹。其设定参见表3.3。

表 3.3 正则化项奖励

奖励因子	描述说明	数学形式	主干权重	台阶特征头权重
r_{JointVel}	关节速度抑制项	$- \dot{q} ^2$	1×10^{-3}	1×10^{-4}
r_{JointAcc}	关节加速度惩罚	$- \ddot{q} ^2$	2.5×10^{-7}	2.5×10^{-7}
r_{Torque}	扭矩使用惩罚	$- \tau ^2$	1×10^{-7}	1×10^{-7}
$r_{\text{ActionRate}}$	动作变化幅度惩罚	$- a_t - a_{t-1} ^2$	1×10^{-2}	1×10^{-3}

姿态调控回报奖励主要提升机器人在外部扰动或动态环境下的自稳能力。该模块中的各项奖励因子, 如水平角速度惩罚、垂直速度惩罚、躯干高度约束、髋部相对位置控制及姿态稳定性等, 均针对实际执行中可能出现的姿态偏离问题进行抑制。与此同时, 加入关节限位检测作为惩罚项, 进一步增强了策略对物理约束的遵守能力, 从而提高了策略的可迁移性和可部署性。具体的奖励项如表3.4。

表 3.4 姿态调控回报奖励

奖励因子	描述说明	数学形式	主干权重	台阶特征头权重
r_{Alive}	存活奖励	$\mathbf{1}_{\text{alive}}$	0.15	0.35
r_{AngVelXY}	水平角速度惩罚	$- \omega_{xy} ^2$	0.05	0.05
r_{LinVelZ}	垂直方向速度惩罚	$- v_z $	2.0	0.0
$r_{\text{BaseHeight}}$	躯干高度偏离惩罚	$- h - h_{\text{ref}} $	10.0	0.0
$r_{\text{JointPosLimits}}$	关节位置限幅惩罚	$\mathbf{1}_{q \notin [q_{\min}, q_{\max}]}$	5.0	2.0
r_{HipPos}	髋部相对位置惩罚	$- p_{\text{hip}} - p_{\text{ref}} $	1.0	1.0
r_{Ori}	姿态稳定性惩罚	$- q_{\text{ori}} - q_{\text{target}} ^2$	1.0	1.0

行为执行反馈奖励则聚焦于引导机器人产生具有明确运动意图的行为表现。尤其是在动态地形下，机器人除了需要维持自身稳定外，还需准确实现目标速度的跟踪。故该模块引入了线速度与角速度的轨迹追踪奖励，确保运动方向和速度的准确性。此外，针对步态生成的稳定性，我们引入了抬脚高度奖励以及足部接触匹配项，以鼓励策略生成合理的摆动高度和接触节律，进一步提升步态执行的协调性与可控性。奖励因子构成如表3.5所示。

表 3.5 行为执行反馈奖励

奖励因子	描述说明	数学形式	主干权重	台阶特征头权重
r_{LinVel}	线速度追踪奖励	$- v_{\text{lin}} - v_{\text{lin}}^{\text{ref}} ^2$	1.0	3.0
r_{AngVel}	角速度追踪奖励	$- \omega_z - \omega_z^{\text{ref}} ^2$	0.5	1.5
r_{Contact}	接触相位奖励	$\mathbf{1}_{\text{contact}}$	0.18	0.3
$r_{\text{ContactPosi}}$	落脚点位置奖励	$-\sum \mathbf{1}\{d_{ij} < \epsilon\}$	0.0	0.8
$r_{\text{FeetSwingHeight}}$	抬脚高度追踪奖励	$- h_{\text{swing}} - h_{\text{ref}} $	5.0	30.0

3.5.2 课程学习

在特征头网络的训练过程中，本研究使用了课程学习的训练方法，地形复杂度及机器人的期望行走速度与角速度将随着训练进程逐步提升。具体而言，当机器人在当前地形条件与运动指令（包括线速度与角速度）下，能够完成超过一半的预设行走距离时，即视为该阶段学习任务完成，从而进入更高难度的地形或更高要求的运动指令进行训练；若未达成该标准，则任务将回退至相对低难度的地形或命令设置，以强化其在低级任务中的稳定性与鲁棒性。该机制旨在通过逐级递进的训练策略，提升机器人在多地形环境中的适应性与泛化能力。

3.6 小结

综上所述，本章通过对基于残差补偿的两阶段强化学习方法的系统研究，实现了在复杂地形下人形机器人运动控制策略的优化与提升。提出的多特征头残差补偿机制有效解决了复杂地形下的动态适应问题，显著提升了策略的鲁棒性和适应性；两阶段训练方法的设计进一步优化了训练过程，降低了策略搜索空间，提高了训练效率。有效性验证实验结果表明，该方法在不同地形条件下均展现出良好的性能，验证了其在多地形环境中的有效性和优越性。

第 4 章 基于人形机器人本体感觉的步态选择方法

在机器人自主导航领域，地形识别是实现适应性控制的关键环节。本研究提出了一种利用机器人本体感觉信息进行步态选择的方法，旨在通过分析机器人自身的内部状态反馈，实现对复杂地形的有效判别。本章围绕基于本体感觉的步态选择方法展开深入研究，首先介绍了步态选择框架的设计，包括数据采集、模型构建与训练过程。随后，通过对比不同神经网络模型的性能，验证了所提方法的有效性。最后，结合人形机器人在多地形环境中的实验，展示了该选择方法在实际应用中的可行性和优越性。

4.1 基于本体感觉的步态选择框架设计

在机器人适应多变地形环境的研究中，实现各类地形条件的有效辨识具有重要意义。为此，本研究提出了一种基于机器人本体感觉信息进行地形判别的分类方法。该方法旨在通过利用机器人自身的内部状态反馈，为多特征头结构提供可靠的步态选择依据，从而使控制策略能够依据地形环境进行动态调整。

第一阶段：在多个典型地形仿真环境中，分别均匀初始化大量机器人实例，确保覆盖不同初始姿态和状态。采集其在自然行走过程中的本体感觉数据，包括关节角度、关节速度、接触信息等关键观测量作为原始数据。为增强模型的鲁棒性与泛化能力，采集数据在加入高斯噪声扰动后进行标准化处理。随后根据机器人所处地形类型标注相应标签，构建带监督的训练数据集。

第二阶段：完成数据准备后，分别构建两种神经网络模型，以探索不同结构对步态选择的效果。一种模型基于多层感知机（MLP），采用堆叠的全连接层来学习输入特征与地形类别之间的非线性映射关系。MLP 能够处理单帧或聚合的本体感觉快照数据，从而捕捉机器人在某一瞬间各传感信号之间的交互特征。另一种模型基于长短期记忆网络（LSTM），用于处理时间序列数据。LSTM 具有记忆单元和门控机制，可以在序列中保留并更新历史信息，使其能够自动发现步态过程中的时序变化模式和动态特征，从而识别地形变化所导致的潜在时序依赖性。

在模型训练过程中，均采用交叉熵损失函数作为优化目标，这是多类别分类任务常用的损失指标。梯度优化方面，使用 Adam 优化器进行参数更新，以利用其自适应学习率特性加快收敛。训练过程中通过划分训练集和验证集，对模型性

能进行监控：对比不同模型在验证集上的分类准确率来评估其泛化能力，并根据准确率和训练稳定性选择最终的分类模型。为防止过拟合，采用早停等策略对训练过程进行控制，从而获得更可靠的选择器。

训练完成后，所得的步态选择器能够实时基于机器人自身的本体感觉数据判断当前所需的步态类型。通过将选择结果反馈给多特征头结构和残差策略模块，系统能够动态启用与该地形类型相匹配的控制策略分支。由此，机器人便可以根据实时感知到的地形信息合理分派残差策略模块，使其激活与否具有针对性，最终实现对不同地形条件的自适应控制。此外，分类得到的步态先验还可以进一步用于全身动力学规划或上半身机械臂操作参考，动态调整作业精度阈值。

4.2 数据构建与模型评估

4.2.1 数据采集

通过人形机器人多个已训练的子策略 π_T ，分别在对应的地形环境中执行控制命令，采集机器人在不同地形条件下的运行状态序列。采集的数据涵盖以下内容：

- 关节角度 (q)
- 机器人状态空间向量 (obs)
- 周围区域的地形高度信息 ($height$)

为了验证机器人在无外部视觉信息辅助下，仅依赖本体感觉实现地形感知与分类的能力，我们引入高度点云信息替代传统摄像头图像作为输入，用于构建对照实验。采集过程持续多个完整步态周期，以确保数据在时间和空间上的代表性。最终将数据根据地形类别标签进行标注与分类，构建训练数据集 $\mathcal{D} = (x_i, y_i)_{i=1}^N$ ，其中 x_i 表示由本体传感器获取的观测数据， y_i 为对应的地形类别标签。

4.2.2 模型训练与实验

基于前述构建的步态选择数据集，本研究设计并训练了两类神经网络模型：MLP 与 LSTM，以系统评估不同模型结构在地形识别任务中的性能表现及其适用性。

考虑到传统 MLP 模型在结构上缺乏对时间序列信息的建模能力，为增强其对时间动态特征的感知能力，我们将连续 10 帧的状态观测向量进行时序拼接，构造具有时间上下文的输入特征，从而在一定程度上弥补其在时序建模方面的不足。相比之下，LSTM 模型原生具备对时间序列数据的建模能力，能够捕捉状态

变化的时序依赖性，理论上更适合处理地形识别任务中隐含的动态模式特征。

为确保对比的公正性与结果的可复现性，所有模型均在相同的数据划分下进行训练与验证，并采用准确率（Accuracy）、精确率（Precision）与召回率（Recall）三项指标对分类性能进行全面评估。不同模型在地形识别任务中的性能对比如表4.1 所示。

表 4.1 基于状态观测量的不同模型分类选择性能对比

评价指标	多层感知机（MLP）	长短期记忆网络（LSTM）
准确率	69.58%	94.49%
精确率	70.36%	94.67%
召回率	69.71%	94.57%

从表中结果可以看出，LSTM 模型在各项评价指标上均显著优于 MLP 模型，体现了其对时间相关特征的建模优势。在准确率、精确率与召回率方面，LSTM 模型均超过 94%，相比之下，MLP 模型在此任务下的性能相对有限，表明仅依赖静态特征拼接不足以充分提取地形相关信息。

为了进一步探讨不同输入数据源对模型性能的影响，本研究以 LSTM 结构为基础，分别使用三类输入数据：仅包含机器人关节角信息（ q ）、完整的状态观测量（ obs ），以及引入地形高度信息作为对照组。相关性能统计见表4.2。

表 4.2 基于 LSTM 的不同数据源分类选择性能比较

评价指标	关节角（ q ）	状态观测量（ obs ）	地形高度信息（ $height$ ）对照组
准确率	83.47%	94.49%	97.39%
精确率	83.58%	94.67%	97.43%
召回率	83.31%	94.57%	97.39%

实验结果表明，状态观测量（ obs ）作为输入时，LSTM 模型在步态选择任务中展现出优异的性能表现，准确率达到 94.49%，仅略低于引入地形高度信息（ $height$ ）的对照组。在未使用任何外部视觉或高度传感信息的前提下，该模型依然能够准确识别多种地形类型，验证了本体感知数据中蕴含的地形判别信息。相比之下，仅使用关节角信息作为输入时，模型性能有所下降，但仍具有一定的地形区分能力。

综合考虑模型结构的性能表现、输入特征的实际获取成本及本研究关注的低

感知依赖场景，最终选取以状态观测量为输入的 LSTM 网络作为步态选择模块的实现方案。

4.3 人形机器人步态实验分析

4.3.1 算法推理流程

如图4.1，在策略执行阶段，系统首先将当前时刻的状态信息输入至已训练完成的主干策略网络，输出具有通用步态特征的基础动作。该动作随后进入由步态选择器驱动的激活模块，根据当前状态所隐含的本体感觉信息判别所处地形类别，从而动态选取与之对应的残差策略分支。在被激活的特定残差头模块中，基础动作将与地形特征信息共同构成输入，经网络前向传播计算得到动作残差。最终，系统通过将残差补偿项与基础动作进行融合，输出具备地形适应性的修正动作并将其发送至环境中执行，驱动机器人步态更新。环境反馈产生的新状态将闭环回传，为下一轮推理提供输入依据。




图 4.1 算法推理流程框架图

该推理流程在保持主干动作一致性的同时，实现了地形响应的动态调整，从而在复杂多变的场景中维持策略稳定性与控制精度。整体结构具备良好的模块解耦特性和控制透明性，残差补偿路径仅在目标地形激活时参与计算，既提升了计算效率，又增强了策略行为的可解释性与适配性。

4.3.2 多地形行走策略评估实验

本实验旨在评估人形机器人在多地形环境中的行走策略执行效果，实验设计了一个包含五种连续地形类型随机组合的综合测试场景，如图4.2所示（分类如节2.2）。在实验中，采用统一的主干网络并结合不同的专用残差输出头，在连续地形场景中进行行走测试。

实验结果表明，机器人能够以平均速度 0.6 m/s 稳定地完成整个多地形组合的连续行走任务。在大多数测试周期中，机器人表现出良好的平衡控制和步态连续性，能够顺利通过各类地形段。除极少数特殊情形（如突发干扰或地形突变导致局部失衡）外，机器人的行走轨迹基本沿着场景中心线展开，在未纠正的情况下，步态延中心线略有偏移，但整体表现出较高的路径保持能力与地形适应能力，验证了所提出行走策略在复杂环境下的有效性与通用性。





图 4.2 五种连续地形综合测试场景

为减少冗余陈述，本实验重点分析平面地形与离散崎岖地形两种典型环境下的行走表现，尤其关注行走过程中步态稳定性及控制策略的有效性。同时，为模拟真实环境中可能出现的地形突变，观测了地形切换场景下的步态表现，以进一步验证机器人在复杂地形间的适应能力。通过对比不同地形条件下的步态特征，实验为多地形适应性策略的评估提供了数据支持。

在具体实验设置中，选取了每条腿六自由度结构中的三个关键关节——髋关节 pitch 、膝关节 pitch 与踝关节 pitch ，作为主要观测对象。这三个位于矢状面方向的关节对直线行走中身体的前向推进、抬腿动作以及地面支撑起着决定性作

用，能够充分反映步态的周期性结构与受力变化特征。因此，记录并分析这三个关节在不同地形条件下的角度变化与力矩响应，有助于准确揭示机器人对地形扰动的动态反应过程以及控制策略的差异化调节能力。




平坦地形（左），离散崎岖地形（右）；关节角度（上），关节力矩（下）

图 4.3 平坦地形与离散崎岖地形下行走过程中关节角度与关节力矩变化曲线

图4.3展示了机器人在平坦地形与离散崎岖地形下行走过程中关节角度与关节力矩的时间序列变化曲线。结果显示，在平坦地形条件下，三个关节的角度曲线呈现出高度规律的周期波动，力矩变化曲线平滑且对称，表明机器人能够稳定维持均衡的步态控制状态，且未受到外部干扰的明显扰动，说明控制策略在结构对称性与运动节律性方面具备良好的执行效果。而在离散崎岖地形条件下，尽管机器人依然保持了相对稳定的周期性步态模式，但受地面起伏影响，力矩变化曲线相较于平坦地形呈现出一定程度的非线性波动，尤其在单腿支撑相与摆动相交替过程中，出现了轻微的力矩峰值抖动，反映出机器人在地形变化过程中需要通过调整内部控制策略以应对支撑不稳定所带来的力学扰动。此外，踝关节的角度曲线相较于髋关节与膝关节发生了较大变化，表明机器人在适应崎岖地形时，主要通过足部调节实现对地面不规则性的快速响应与动态稳定性维持。

为进一步验证控制策略在地形突变条件下的适应能力，实验引入了地形切换场景，即机器人从平坦地形过渡至离散崎岖地形的过程中，分析其步态调节与控制稳定性的动态演化过程。图4.4呈现了地形切换过程中三个关键关节的角度与

力矩变化情况。可以观察到，尽管地形特性发生了较为剧烈的变化，机器人在关节角度调节过程中仍保持了良好的连续性与平滑性，未出现突兀的姿态跳变或控制紊乱现象，力矩曲线在地形切换点处也未表现出剧烈的噪声或尖峰波动，表明策略具备较强的时序一致性与控制鲁棒性。该过程中的平滑过渡反映了控制系统具备较强的前馈调节能力与对环境变化的快速反馈响应，能够实现从策略层面到力控层面的多层次协调调节，从而保障机器人在非结构化地形中的持续稳定运动。



关节角度（左），关节力矩（右）

图 4.4 地形切换过程中关节角度与关节力矩变化曲线

实验结果表明，机器人在平坦地形下能够实现高度稳定的行走，其关节角度变化规律性强，力矩输出平稳；而在崎岖地形中，尽管地形扰动显著增加，机器人依然表现出较强的适应能力，步态结构随地形变化作出明显调整，控制策略展现出一定的鲁棒性。地形切换实验进一步验证了机器人具备动态调整步态以应对地形突变的能力，步态图中显示的姿态变化与力矩响应反映出控制系统的及时性与适应性。整体而言，本实验验证了所设计控制策略在多地形环境下的可行性，为后续多地形适应性行走系统的拓展和增强提供了重要参考与数据支撑。

4.3.3 台阶地形行走能力评估与消融实验

为了评估所提出的人形机器人行走算法在复杂地形下的极限能力，本文重点研究了台阶地形条件下的行走性能。台阶地形作为本研究划分的五类典型地形中最具挑战性的类型之一，其地形特征显著复杂，机器人在该地形上行走所需的步态调节幅度最大。因此，台阶地形不仅代表了本算法适应能力的上限边界，也可作为检验整套行走算法鲁棒性与泛化能力的重要测试平台。

4.3.3.1 台阶攀爬基础能力实验

本实验每级台阶的宽度为 0.4m，高度为 0.11m。为具体分析台阶行走过程中机器人步态的时序特征，本文选取了机器人攀爬一级台阶过程中的 0.7s 时间段，并对关键步态变化进行了快照分析，如图4.6所示。在 0.0s 时，机器人处于攀爬准备阶段，呈现单腿支撑状态；0.1s 时完成双腿支撑，标志着攀爬动作的初始化；0.2s 时，先摆动腿抬升至最高点；0.4s 时，先摆动腿完成落脚并进入支撑期，同时后摆动腿开始抬升；0.6s 时，后摆动腿抬至高点，机器人整体重心提升到位；至 0.7s 时，后摆动腿完成落地进入支撑，标志着换腿完成及该步态周期的结束。整个过程展示了机器人在面对大幅度高度变化地形时的动态步态调整能力。




图 4.5 平坦与台阶地形切换过程中关节角度与关节力矩变化曲线

为了进一步量化分析机器人从平地过渡至台阶地形过程中动力学状态的变化，本文记录了关键关节的角度与力矩变化情况，如图4.5所示。实验结果表明，在进入台阶地形后，机器人关节角度显著增大，尤其是髋关节与膝关节的摆动幅度增加，反映出为了完成台阶高度的抬腿动作，控制策略主动增强了腿部的抬升轨迹。同时，膝关节的力矩呈明显上升趋势，说明机器人在垂直方向上需要施加更大的力矩以抬升身体重心完成台阶攀爬，该过程体现了算法在大位移工作空间下的控制效能与机体协同能力。

4.3.3.2 台阶攀爬极限高度实验

在本实验中，以成功连续攀爬三级台阶为标准，分别测试了不同台阶高度（0.15m、0.16m、0.17m、0.18m、0.19m）的攀爬性能，每个高度均进行了十次实验，相关结果如表4.3所示。

从实验结果可知，当台阶高度不超过 0.16m 时，机器人能够以较高的成功率稳定完成连续三级台阶的攀爬任务；而在台阶高度为 0.17m 时，成功率略有下降，




图 4.6 台阶行走步态的时序特征图

出现了个别攀爬失败的情况。随着台阶高度进一步增加至 0.18m，成功率显著下降，仅有一半实验成功完成，表现出明显的不稳定性；在 0.19m 高度下，机器人则完全无法完成三级台阶的连续攀爬。因此，可以确定该机器人系统在本控制算法下的台阶攀爬极限高度为 0.18m，即在该高度仍具有一定成功率，但已经接近性能边界。

表 4.3 不同台阶高度下机器人连续攀爬 3 级台阶实验结果

指标	0.15m	0.16m	0.17m	0.18m	0.19m
测试频数	10	10	10	10	10
成功频数	10	10	9	5	0

除实验统计结果外，实验回放快照亦揭示了机器人在不同台阶高度下的运动表现特征。在 0.15m 与 0.16m 的台阶高度条件下，机器人整体动作较为稳定，能够在无需显著调整或仅需进行少量微调的情况下完成攀爬。而当台阶高度达到 0.17m 与 0.18m 时，机器人在抬腿过程中逐渐暴露出足部提升不足的问题，导致在每一级台阶上均需进行较多次位置调整，甚至出现已登上前一级台阶后因落脚不稳而被迫退回的现象。在 0.19m 高度测试中，机器人足部提升能力已无法满足




图 4.7 退回现象步态时序特征图

对台阶高度的跨越需求，致使其基本无法完成有效的攀爬。

如图4.7所示，退回现象在步态过程中表现得尤为明显。在 0.1 秒时刻，支撑脚的落脚点存在显著偏移，导致大部分足部区域超出当前支撑面边缘，引发踝关节处的力矩急剧增大，使得控制系统在维持平衡方面面临更高挑战。同时，受限於支撑脚临近边缘的位置，机器人在执行姿态调整与重心转移动作时，易与台阶边缘发生干涉，致使重心投影无法顺利前移，最终为了维持整体姿态稳定性，机器人只能回退一级台阶，从而导致攀爬任务失败。

依据国家标准对台阶高度的建议，通常以 0.15m 作为标准极限高度，超出该范围则被视为非标准场景。本实验通过对超过 0.15m 的多个台阶高度进行系统性测试，验证了所提出控制算法在实现贴近人类生活场景行走能力的同时，具备在非标准环境下应对挑战的潜力。值得指出的是，所使用机器人本体高度显著低于标准成年人的平均身高，仍能在此条件下完成最高至 0.18m 台阶的攀爬任务，充分体现了所构建系统在面对复杂场景时所具备的良好环境适应性与控制鲁棒性。

4.3.3.3 台阶攀爬消融对照实验

为验证本文提出的“主干网络 + 残差补偿输出头”结构在复杂地形任务中的有效性（以台阶地形为例），我们设计了消融对照实验。具体而言，移除残差补偿

输出头，仅保留主干策略网络，并在该条件下对模型重新训练。随后，我们在高度范围为 0.08 至 0.12 米的台阶上分别进行了 10 次三阶连续攀爬实验，以评估策略在不同高度下的任务完成能力。

表 4.4 消融条件下机器人连续攀爬 3 级台阶实验结果

台阶高度	0.08m	0.09m	0.10m	0.11m	0.12m
测试次数	10	10	10	10	10
成功次数	10	10	7	3	1

如表4.4所示，当台阶高度达到 0.10 米时，策略模型的成功率已显著下降；至 0.12 米时，几乎无法完成连续攀爬任务。这一结果表明，在缺乏残差补偿机制的情况下，主干策略网络在应对高台阶地形时存在明显的能力不足。

进一步分析其原因，台阶地形相较于平地或缓坡，具有更剧烈的高度突变特性，机器人在攀爬过程中需具备更高的抬腿能力以实现足部越障。然而，在现有奖励设计中，“能耗最小化”仍占较大权重，策略在训练过程中倾向于收敛至低幅度动作以降低能量开销，进而抑制了对高抬腿动作的学习。这一偏向使得在实际面对高台阶时，策略无法生成足够抬腿高度的步态模式，从而导致攀爬失败。




图 4.8 台阶攀爬失败过程快照

从实验回放快照（图4.8）中可进一步直观观察到该问题的表现。在 $0.2s$ 时，机器人前腿已接近其可实现的最大抬腿高度，并开始向前摆动准备跨越台阶；至 $0.25s$ ，足部因高度不足而被台阶边缘绊住，未能完成预期的越障动作；随后在 $0.3s$ ，由于动作受阻导致姿态扰动加剧，重心快速偏移，机器人失去平衡，最终攀爬失败。

综上所述，实验结果和回放分析均显示，残差补偿输出头在应对台阶等复杂地形时，能够有效增强策略的动作表达能力，提升对突变地形的适应性与任务完成率。因此，该结构在复杂场景下的部署中具有重要的实用价值与推广意义。

4.3.4 残差输出头替代实验

本小节设计并实施了残差输出头替代实验，旨在评估当特定地形所对应的残差输出头被其他非匹配的输出头替代时，策略在任务执行过程中的泛化能力。





图 4.9 斜坡地形残差输出头替代应用于崎岖地形导致的躯干失衡步态回放

以针对斜坡地形所训练得到的残差输出头替代应用于离散崎岖地形为例，实验结果表明：当崎岖地形的扰动程度较低、地形起伏较为平缓时，由于斜坡与崎岖地形在局部几何结构上存在一定相似性，且策略共享统一的主干网络，仍能够在一定程度上完成任务，表现出良好的基本通行能力。然而，随着地形复杂度显著提升，尤其是在存在大量突发性扰动（如非连续性深坑）的高难度场景中，由

于斜坡地形残差输出头在训练阶段未曾接触类似极端地形，缺乏应对剧烈不规则扰动的能力，策略表现出步态不稳定、躯干姿态失衡等问题，最终无法完成任务。如图4.9所示的步态回放快照，展示了策略失败的关键过程：机器人在 0.1 秒踏入深坑，0.2 秒摆动腿被地形卡住，0.3 秒尝试自救但抬腿高度不足，已错失最佳应对时机；0.35 秒支撑腿腾空，至 0.4 秒重心彻底失衡导致倒地。

进一步地，我们尝试将台阶地形对应的残差输出头替代崎岖地形的专用输出头。实验结果显示，尽管台阶地形为训练集中最具复杂性的场景，其所获得的残差策略展现出较强的泛化能力，在部分崎岖地形下仍能保持较高的稳定性并完成行走任务。然而，如图4.10所示，由于该策略在处理台阶高度变化时采用了更为激进的抬腿动作（表现为膝关节角变化幅度较大），该动作在相对低复杂度的崎岖地形中表现为动作冗余，导致能量消耗显著增加，进而降低整体运动效率。因此，尽管替代策略具备一定的适应能力，但其在任务执行性能上仍逊色于为崎岖地形精细设计的专用输出头。



专用输出头（左）、台阶输出头（右）

图 4.10 离散崎岖地形中关节角曲线对比

综上所述，残差输出头的交叉替代实验结果表明：虽然共享主干网络在提升策略跨地形泛化能力方面具有一定积极作用，但残差输出头在处理具体地形特征时仍表现出明显的任务适应性差异。当目标地形的扰动特性超出替代输出头的训练分布时，策略执行效果将明显下降，甚至出现任务失败的情况。此外，即便在复杂地形中训练得到的残差输出头具备较强的泛化能力，能够适应较简单地形任务，其策略行为中仍可能存在动作幅度冗余、能耗增加等问题，从而影响整体性能表现。上述结果进一步验证了多残差输出头结构在提升策略多任务适应性与任务特化性能方面的重要性和必要性。

4.4 小结

本章通过对基于本体感觉的步态选择方法的系统研究，取得了一系列重要成果。首先，设计了一种完整的步态选择框架，通过采集机器人在不同地形条件下的本体感觉数据，并结合神经网络模型，实现了对不同地形步态的高效选择。实验结果表明，LSTM 模型在步态选择任务中表现优异，其准确率、精确率和召回率均显著优于 MLP 模型。此外，通过人形机器人在多地形环境中的实验验证，进一步证明了该方法在实际应用中的鲁棒性，同时也验证了第3章中所述方法在解决人形机器人多地形行走问题中的有效性。本章的研究不仅为机器人的地形感知提供了新的思路，还为后续的自适应控制策略设计奠定了坚实的基础。未来的研究可以进一步优化模型结构，探索更多地形类型的应用场景，以提升机器人在复杂环境中的自主行走能力。

第 5 章 总结与展望

5.1 全文总结

本研究围绕人形机器人在复杂地形中的稳定行走问题，系统探讨了步态规划方法，并通过对基于模型与基于学习方法的文献综述，分析了二者在实际应用中的优劣。基于模型的方法依赖精确建模，具有较高控制精度与可解释性，但在复杂地形中受限于建模误差与轨迹计算复杂性；而基于学习的方法具备良好的泛化能力和自适应性，但面临优化困难与策略可解释性不足的问题。

为进一步探究强化学习在人形机器人步态规划中的更优解决方案，本文设计了一套完整的强化学习算法系统，并以经典的“山地小车”问题为基础，验证了所提出创新性强化学习框架的有效性与可扩展性，为策略从低维简单问题向高维复杂人形机器人任务的迁移提供了理论支撑与实践路径。

基于上述强化学习框架，本文实现了人形机器人在复杂地形中的稳定行走算法。通过持续优化算法性能，并在多种复杂地形仿真环境中进行系统测试，验证了所学习的策略在应对复杂地形挑战中的鲁棒性与适应性。进一步地，针对台阶地形代表性场景进行了重点分析，明确了现有策略的性能边界。最后，通过对残差输出头网络的消融实验和输出头替换实验，验证了该结构在提升策略性能方面的关键作用和专业表现。

综上所述，本文通过构建并验证一套新颖的强化学习框架，成功实现了人形机器人在复杂地形中的稳定行走策略，为强化学习在机器人步态控制中的应用提供了新的研究视角与技术路径，也为人形机器人在复杂真实环境中的广泛部署探索了新的技术方案。

5.2 展望

本研究所选用的地形类型相对基础，未能全面覆盖复杂环境对算法性能的挑战性检验。在后续研究中，可进一步引入更具挑战性的地形类型或地面状态，如梅花桩、窄路及深坑等，以增强多输出头策略在复杂场景中的专业性。

本研究仅在仿真环境中进行了验证，尚未在真实硬件平台上开展实验。因此，未来的工作将考虑将所提出的方法部署于实际人形机器人平台上，以评估其在真实物理环境下的鲁棒性与有效性。

参考文献

- [1] Aggarwal J K, Cai Q. Human motion analysis: A review[J]. Computer vision and image understanding, 1999, 73(3): 428-440.
- [2] Prakash Gupta J, Dixit P, Singh N, et al. Analysis of gait pattern to recognize the human activities[M]. International Journal of Interactive Multimedia and Artificial Intelligence ..., 2014.
- [3] Nenchev D N, Konno A, Tsujita T. Humanoid robots: Modeling and control[M]. Butterworth-Heinemann, 2018.
- [4] Zhao L, Yu Z, Han L, et al. Compliant motion control of wheel-legged humanoid robot on rough terrains[J]. IEEE/ASME Transactions on Mechatronics, 2023, 29(3): 1949-1959.
- [5] Wikipedia contributors. Optimus (robot)[EB/OL]. 2024. [https://en.wikipedia.org/wiki/Optimus_\(robot\)](https://en.wikipedia.org/wiki/Optimus_(robot)).
- [6] Gong Y, Hartley R, Da X, et al. Feedback control of a cassie bipedal robot: Walking, standing, and riding a segway[C]//2019 American control conference (ACC). IEEE, 2019: 4559-4566.
- [7] Li Z, Peng X B, Abbeel P, et al. Reinforcement learning for versatile, dynamic, and robust bipedal locomotion control[J]. The International Journal of Robotics Research, 2024: 02783649241285161.
- [8] Li Z, Cheng X, Peng X B, et al. Reinforcement learning for robust parameterized locomotion control of bipedal robots[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2021: 2811-2817.
- [9] Garcia C E, Prett D M, Morari M. Model predictive control: Theory and practice—a survey [J]. Automatica, 1989, 25(3): 335-348.
- [10] Li Z, Peng X B, Abbeel P, et al. Robust and versatile bipedal jumping control through reinforcement learning[A]. 2023.
- [11] Rudin N, Hoeller D, Reist P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning[C]//Conference on Robot Learning. PMLR, 2022: 91-100.
- [12] Nashner L M, McCollum G. The organization of human postural movements: a formal basis and experimental synthesis[J]. Behavioral and brain sciences, 1985, 8(1): 135-150.
- [13] Winter D A. Overall principle of lower limb support during stance phase of gait[J]. Journal of biomechanics, 1980, 13(11): 923-927.

- [14] Nilsson J, Thorstensson A, Halbertsma J. Changes in leg movements and muscle activity with speed of locomotion and mode of progression in humans[J]. *Acta Physiologica Scandinavica*, 1985, 123(4): 457-475.
- [15] Simon S R. Quantification of human motion: gait analysis—benefits and limitations to its application to clinical problems[J]. *Journal of biomechanics*, 2004, 37(12): 1869-1880.
- [16] Shahid S, Nandy A, Mondal S, et al. A study on human gait analysis[C]//*Proceedings of the Second International Conference on Computational Science, Engineering and Information Technology*. 2012: 358-364.
- [17] Sakagami Y, Watanabe R, Aoyama C, et al. The intelligent asimo: System overview and integration[C]//*IEEE/RSJ international conference on intelligent robots and systems: Vol. 3*. IEEE, 2002: 2478-2483.
- [18] Chignoli M, Kim D, Stanger-Jones E, et al. The mit humanoid robot: Design, motion planning, and control for acrobatic behaviors[C]//*2020 IEEE-RAS 20th International Conference on Humanoid Robots (Humanoids)*. IEEE, 2021: 1-8.
- [19] Kuindersma S, Deits R, Fallon M, et al. Optimization-based locomotion planning, estimation, and control design for the atlas humanoid robot[J]. *Autonomous robots*, 2016, 40: 429-455.
- [20] Wensing P M, Posa M, Hu Y, et al. Optimization-based control for dynamic legged robots[J]. *IEEE Transactions on Robotics*, 2023, 40: 43-63.
- [21] Chen H, Chen X, Dong C, et al. Online running pattern generation for humanoid robot with direct collocation of reference-tracking dynamics[J]. *IEEE/ASME Transactions on Mechatronics*, 2023, 29(3): 2091-2102.
- [22] Escande A, Mansard N, Wieber P B. Hierarchical quadratic programming: Fast online humanoid-robot motion generation[J]. *The International Journal of Robotics Research*, 2014, 33(7): 1006-1028.
- [23] Kajita S, Kanehiro F, Kaneko K, et al. The 3d linear inverted pendulum mode: A simple modeling for a biped walking pattern generation[C]//*Proceedings 2001 IEEE/RSJ International Conference on Intelligent Robots and Systems. Expanding the Societal Role of Robotics in the the Next Millennium (Cat. No. 01CH37180): Vol. 1*. IEEE, 2001: 239-246.
- [24] Kajita S, Morisawa M, Miura K, et al. Biped walking stabilization based on linear inverted pendulum tracking[C]//*2010 IEEE/RSJ International Conference on Intelligent Robots and Systems*. IEEE, 2010: 4489-4496.
- [25] Kajita S, Kanehiro F, Kaneko K, et al. Biped walking pattern generation by using preview control of zero-moment point[C]//*2003 IEEE international conference on robotics and automation (Cat. No. 03CH37422): Vol. 2*. IEEE, 2003: 1620-1626.

- [26] Takenaka T, Matsumoto T, Yoshiike T. Real time motion generation and control for biped robot-1 st report: Walking gait pattern generation[C]//2009 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2009: 1084-1091.
- [27] Han B, Yi H, Xu Z, et al. 3d-slip model based dynamic stability strategy for legged robots with impact disturbance rejection[J]. Scientific Reports, 2022, 12(1): 5892.
- [28] Wensing P M, Orin D E. Improved computation of the humanoid centroidal dynamics and application for whole-body control[J]. International Journal of Humanoid Robotics, 2016, 13 (01): 1550039.
- [29] Shen J, Hong D. Convex model predictive control of single rigid body model on so (3) for versatile dynamic legged motions[C]//2022 International Conference on Robotics and Automation (ICRA). IEEE, 2022: 6586-6592.
- [30] Batke R, Yu F, Dao J, et al. Optimizing bipedal maneuvers of single rigid-body models for reinforcement learning[C]//2022 IEEE-RAS 21st International Conference on Humanoid Robots (Humanoids). IEEE, 2022: 714-721.
- [31] Bellicoso C D, Jenelten F, Gehring C, et al. Dynamic locomotion through online nonlinear motion optimization for quadrupedal robots[J]. IEEE Robotics and Automation Letters, 2018, 3(3): 2261-2268.
- [32] García G, Griffin R, Pratt J. Mpc-based locomotion control of bipedal robots with line-feet contact using centroidal dynamics[C]//2020 IEEE-RAS 20th International Conference on Humanoid Robots (Humanoids). IEEE, 2021: 276-282.
- [33] Nassour J, Hénaff P, Benouezdou F, et al. Multi-layered multi-pattern cpg for adaptive locomotion of humanoid robots[J]. Biological cybernetics, 2014, 108: 291-303.
- [34] Or J. A hybrid cpg-zmp control system for stable walking of a simulated flexible spine humanoid robot[J]. Neural Networks, 2010, 23(3): 452-460.
- [35] Yao C, Liu C, Xia L, et al. Humanoid adaptive locomotion control through a bioinspired cpg-based controller[J]. Robotica, 2022, 40(3): 762-779.
- [36] Li C, Lowe R, Ziemke T. Humanoids learning to walk: a natural cpg-actor-critic architecture [J]. Frontiers in neurorobotics, 2013, 7: 5.
- [37] Vukobratović M, Borovac B. Zero-moment point—thirty five years of its life[J]. International journal of humanoid robotics, 2004, 1(01): 157-173.
- [38] Pratt J, Koolen T, De Boer T, et al. Capturability-based analysis and control of legged locomotion, part 2: Application to m2v2, a lower-body humanoid[J]. The international journal of robotics research, 2012, 31(10): 1117-1133.

- [39] Fernbach P, Tonneau S, Stasse O, et al. C-croc: Continuous and convex resolution of centroidal dynamic trajectories for legged robots in multicontact scenarios[J]. IEEE Transactions on Robotics, 2020, 36(3): 676-691.
- [40] Kuindersma S, Permenter F, Tedrake R. An efficiently solvable quadratic program for stabilizing dynamic locomotion[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2014: 2589-2594.
- [41] Daneshmand E, Khadiv M, Grimminger F, et al. Variable horizon mpc with swing foot dynamics for bipedal walking control[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 2349-2356.
- [42] Sentis L, Khatib O. A whole-body control framework for humanoids operating in human environments[C]//Proceedings 2006 IEEE International Conference on Robotics and Automation, 2006. ICRA 2006. IEEE, 2006: 2641-2648.
- [43] Moro F L, Sentis L. Whole-body control of humanoid robots[J]. Humanoid robotics: a reference, 2019: 1161-1183.
- [44] Bouyarmane K, Kheddar A. Using a multi-objective controller to synthesize simulated humanoid robot motion with changing contact configurations[C]//2011 IEEE/RSJ international conference on intelligent robots and systems. IEEE, 2011: 4414-4419.
- [45] Siekmann J, Green K, Warila J, et al. Blind bipedal stair traversal via sim-to-real reinforcement learning[A]. 2021.
- [46] Unitree Robotics. Unitree H1[EB/OL]. 2024. <https://www.bilibili.com/video/BV19p421U727/?vdsouce=82b909d5abbb8108ea2220646b7b0467>.
- [47] Peters J, Vijayakumar S, Schaal S. Reinforcement learning for humanoid robotics[C]//Proceedings of the third IEEE-RAS international conference on humanoid robots. 2003: 1-20.
- [48] Melo L C, Máximo M R O A. Learning humanoid robot running skills through proximal policy optimization[C]//2019 Latin american robotics symposium (LARS), 2019 Brazilian symposium on robotics (SBR) and 2019 workshop on robotics in education (WRE). IEEE, 2019: 37-42.
- [49] Zhang Q, Cui P, Yan D, et al. Whole-body humanoid robot locomotion with human reference[C]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2024: 11225-11231.
- [50] Wu Q, Zhang C, Liu Y. Custom sine waves are enough for imitation learning of bipedal gaits with different styles[C]//2022 IEEE International Conference on Mechatronics and Automation (ICMA). IEEE, 2022: 499-505.
- [51] Li C, Stanger-Jones E, Heim S, et al. Fld: Fourier latent dynamics for structured motion representation and learning[A]. 2024.

- [52] Wang H, Wang Z, Ren J, et al. Beamdojo: Learning agile humanoid locomotion on sparse footholds[A]. 2025.
- [53] Jenelten F, He J, Farshidian F, et al. Dtc: Deep tracking control[J]. Science Robotics, 2024, 9 (86): eadh5401.
- [54] Levine S, Koltun V. Guided policy search[C]//International conference on machine learning. PMLR, 2013: 1-9.
- [55] Ijspeert A, Nakanishi J, Schaal S. Learning attractor landscapes for learning motor primitives [J]. Advances in neural information processing systems, 2002, 15.
- [56] Xie Z, Berseth G, Clary P, et al. Feedback control for cassie with deep reinforcement learning[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018: 1241-1246.
- [57] Liu F, Gu Z, Cai Y, et al. Opt2skill: Imitating dynamically-feasible whole-body trajectories for versatile humanoid loco-manipulation[A]. 2024.
- [58] Paredes V C, Hereid A. Resolved motion control for 3d underactuated bipedal walking using linear inverted pendulum dynamics and neural adaptation[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2022: 6761-6767.
- [59] Brooks C A, Iagnemma K. Vibration-based terrain classification for planetary exploration rovers[J]. IEEE Transactions on Robotics, 2005, 21(6): 1185-1191.
- [60] Dupont E M, Moore C A, Collins E G, et al. Frequency response method for terrain classification in autonomous ground vehicles[J]. Autonomous Robots, 2008, 24: 337-347.
- [61] Giguere P, Dudek G. A simple tactile probe for surface identification by mobile robots[J]. IEEE Transactions on Robotics, 2011, 27(3): 534-544.
- [62] Bai C, Guo J, Guo L, et al. Deep multi-layer perception based terrain classification for planetary exploration rovers[J]. Sensors, 2019, 19(14): 3102.
- [63] Nampoothiri M H, Anand P G, Antony R. Real time terrain identification of autonomous robots using machine learning[J]. International Journal of Intelligent Robotics and Applications, 2020, 4(3): 265-277.
- [64] Alvarez M D L, Guo J, Domínguez R, et al. Terrain classification enhanced with uncertainty for space exploration robots from proprioceptive data[A]. 2024.
- [65] Gu X, Wang Y J, Chen J. Humanoid-gym: Reinforcement learning for humanoid robot with zero-shot sim2real transfer[A]. 2024.
- [66] Makoviychuk V, Wawrzyniak L, Guo Y, et al. Isaac gym: High performance gpu-based physics simulation for robot learning[A]. 2021.

附录 A 外文资料的书面翻译

盲式双足楼梯穿越：通过仿真到现实的强化学习

目录

A.1 摘要	52
A.2 介绍	52
A.3 强化学习公式	54
A.3.1 状态空间	55
A.3.2 动作空间	55
A.3.3 奖励函数	56
A.3.4 动力学随机化	56
A.3.5 策略表示与学习	57
A.4 地形随机化	57
A.5 结果	58
A.5.1 仿真	58
A.5.2 行为分析	61
A.6 结论	64
A.7 附录	65
A.7.1 奖励函数	65
参考文献.....	66

A.1 摘要

对于现实世界环境中的机器人运动来说，准确和精确的地形估计是一个难题。因此，拥有不依赖于精确估计到脆弱程度的系统是有用的。在本文中，我们通过研究双足机器人在没有任何外部感知或地形模型的情况下穿越类似楼梯地形的的问题，探索了这种方法的极限。对于这种盲视双足平台来说，由于意外的高程变化，问题显得困难（甚至对人类来说也是如此）。我们的主要贡献是展示，仿真到现实的强化学习（RL）能够在双足机器人 Cassie 上仅使用本体感觉反馈实现对类似楼梯地形的稳健运动。重要的是，这只需要修改现有的平地训练 RL 框架，以包括类似楼梯地形的随机化，而无需更改奖励函数。据我们所知，这是第一个能够仅使用本体感觉可靠地穿越各种现实世界楼梯和其他类似楼梯干扰的双足人形机器人控制器。本科生的外文资料书面翻译。

A.2 介绍

为了在现实世界中发挥作用，双足和仿人机器人需要能够上下楼梯和类似楼梯的地形，如凸起的平台或突然的垂直下降，这些是人类中心环境中的常见特征。能够稳健地导航这些环境对于确保机器人安全地与人类一起工作至关重要。在双足平台上实现这种稳健性并非易事；虽然其他平台如四足机器人由于与地面有多个接触点而具有固有的稳定性，并且能够像桌子一样停下来站立，但像 Cassie 这样的双足机器人完全依赖于动态稳定性（基本上总是处于跌倒状态）。在类似楼梯的环境中，这一点尤为明显，因为用仅有的两条腿从失误中恢复的难度很大。

相比之下，具有四足形态的机器人已经能够仅使用本体感觉来处理楼梯^[1-2]，而六足机器人甚至能够使用开环控制来上下楼梯^[3]。虽然平面双足机器人已被证明能够排除像大型意外的下落台阶这样的干扰^[4]，但在现实世界中使这类机器人能够处理楼梯的绝大多数方法都需要要么准确的视觉系统^[5-7]，要么在精心控制的实验室环境中操作^[8-10]，这意味着机器人通过已知的起始位置定位，或者楼梯与机器人形态同时设计。




图 A.1 在这项研究中，我们探索了盲式双足运动的极限。我们提出了一个训练流程，能够产生能够在现实世界中盲目上下楼梯的策略。这些策略学习了基于本体感受的反射动作，以抵御地面高度的重大干扰，从而在许多现实世界环境中展现出极高的鲁棒性。

然而，机器人必须能够在受控实验室条件之外操作，并处理现实世界中巨大的条件变化。这个目标与完全依赖外部感知传感器（如 RGB 和深度摄像头）进行准确地形估计并不兼容，因为这会在现实世界条件下引入脆弱性^[11]。例如，如果摄像头受到遮挡、雾霾或光照变化的影响，可能会变得不可靠。此外，将最先进的计算机视觉系统集成到高速控制器中在技术上是困难的，尤其是在像移动机器人这样的计算能力有限的平台上。出于实际考虑，基础控制器应尽可能稳健，同时尽量少依赖于对世界的信息。理想情况下，双足机器人应能够尽可能多地使用本体感觉穿越人类环境的广泛区域，同时依赖外部感知进行进一步的效率提升和高层次规划（并对错误的感知具有鲁棒性）。这就引出了一个问题：盲视双足机器人能有多稳健？

基于强化学习（RL）的方法已经开始在稳健的现实世界腿部运动中显示出显著的潜力^[1,12-13]。与依赖预定地面接触计划或基于力的事件检测的优化或启发式控制方法不同，RL 可以产生学习本体感觉反射和策略的控制策略，以应对训练期间暴露的各种干扰中的意外早接触或晚接触和粗糙地形。然而，这种方法的局限性尚不清楚，先前的工作尚未在涉及类似楼梯地形的干扰规模和多样性上得到证明。

在这项工作中，我们展示了通过现有 RL 框架，几乎不需要修改就可以学习到复杂类似楼梯地形的稳健本体感觉双足控制。特别是，唯一需要调整的是训练

期间使用的地形随机化，我们定义了一个分布，包括上升和下降楼梯的变化，包括接触平面的高度、宽度和坡度。在这个分布上学习，可以允许在未知楼梯上进行盲视运动，以及处理更一般的类似楼梯地形特征，例如原木、路缘、悬崖等。学习到的控制器在模拟和各种现实世界环境中得到演示。据我们所知，这是第一次进行此类演示，并建议继续探索稳健本体感觉双足控制的极限。

A.3 强化学习公式

我们遵循仿真到现实的强化学习（RL）方法来学习双足运动，并假设对 RL 有基本的了解。在一般的 RL 设置中，每个离散时间步 t ，机器人控制策略 π 接收当前状态 s_t 并返回动作 a_t ，该动作被应用并导致过渡到下一个状态 s_{t+1} 。状态转移动态对机器人来说是未知的，并且由环境条件（如地形类型）和机器人动态的组合所决定。此外，在训练期间，每个状态转移都与一个实值奖励 r_t 相关联。奖励由应用目标所决定，以鼓励在学习期间产生期望的行为。本文考虑的 RL 优化目标是通过与环境的交互来学习一个策略，该策略在有限视界 T 上最大化预期累积折扣奖励。也就是说，找到一个策略 π ，使其最大化：

$$J(\pi) = \mathbb{E} \left[\sum_{t=0}^T \gamma^t R_t \right] \quad (\text{A.1})$$

其中 $\gamma \in [0, 1]$ 是折扣因子， R_t 是从初始状态分布中抽取的状态，遵循 π 在时间 t 的奖励的随机变量。

对于复杂环境，强化学习通常需要大量的训练经验来识别一个好的策略。此外，对于双足运动，训练将涉及许多跌倒和碰撞，尤其是在训练初期。因此，在现实世界中从头开始训练是不切实际的，我们转而采用仿真到现实的强化学习范式。训练完全在模拟环境中进行，包括动态随机化（见下文），然后将得到的政策应用于现实世界。

在本节的其余部分，我们详细说明了本工作中使用的特定仿真到现实强化学习公式，该公式遵循了最近关于在平坦地形上学习不同双足步态的工作^[13]。令人惊讶的是，为了使策略学习适应本文中更复杂的类似楼梯地形，只需要进行最小的更改。特别是，唯一需要的主要修改是在第三部分后面讨论的，将类似楼梯的地形而不是大多数平坦地形的随机领域生成；不需要新的特定楼梯的奖励项。

A.3.1 状态空间

每个时间步输入到控制策略的状态 s_t 包括三个主要组成部分。首先，状态包含关于机器人瞬时物理状态的信息，包括骨盆的方向（以四元数格式表示）、骨盆的角速度、关节位置和关节速度。 s_t 的第二个组成部分由人类操作员发出的命令输入组成。这些命令在训练期间会进行随机化，以使策略在尝试以各种速度和接近角度穿越楼梯时获得广泛的经验。这种随机化的详细信息可以在表 A.1 中看到。

表 A.1 命令随机变化概率及范围

命令	变化概率	范围
前进速度	$\frac{1}{300}$	$[-0.3 \text{ m/s}, 1.5 \text{ m/s}]$
横向速度	$\frac{1}{300}$	$[-0.3 \text{ m/s}, 0.3 \text{ m/s}]$
转向速率	$\frac{1}{300}$	$[-90^\circ/\text{s}, 90^\circ/\text{s}]$

第三个组成部分包括两个循环时钟输入，每个输入对应机器人的一条腿， p :

$$p = \begin{cases} \sin(2\pi(\phi_t + 0.0)) \\ \sin(2\pi(\phi_t + 0.5)) \end{cases} \quad (\text{A.2})$$

这里 ϕ_t 是一个相位变量，它从 0 增加到 1，然后回滚到 0，以跟踪步态的当前相位。常数偏移量 0.0 和 0.5 是相位偏移，用于确保在运动过程中左右腿在相位上始终是直径相对的。

A.3.2 动作空间

控制策略在每个时间步（以 40Hz 运行）的输出动作 a_t 是一个 11 维向量，其中前 10 个条目对应于关节的 PD 目标，每个目标都输入到一个以 2KHz 运行的 PD 控制器中。先前的研究已经发现，在 PD 目标空间中学习动作比直接学习更高频率的激活命令更为有利^[14]。

a_t 的最后一个维度是一个时钟增量 δ_t （有关时钟的信息，请参见 II-A），它允许策略调节步态的步进频率。直观上，这允许控制器为特定的步态、命令和地形选择适当的步进频率。具体来说，状态表示中的相位变量 ϕ （见 II-A 节）在每个时间步 t 通过以下方式更新：

$$\phi_{t+1} = \text{fmod}(\phi_t + \delta_t, 1.0). \quad (\text{A.3})$$

这个增量被限定在一个范围内，使得策略可以选择将步态周期调节在名义步进频率的 0.5 倍到 1.5 倍之间（大约每 0.7 秒一个步态周期）。虽然这个组件包含在控制策略动作中，但它似乎对性能没有太大影响，并且学习到的策略在响应扰动时也不会太多地改变 δ_t 。我们怀疑未来的消融分析将显示它对于真实机器人的性能并不重要。

A.3.3 奖励函数

我们使用文献^[13]中介绍的方法来指定我们的奖励函数。简要回顾这种方法，我们希望有一个奖励框架，允许在某些情况下对策略进行惩罚，因为环境中的一些量在某些时候会很大，而在其他时候允许这些量很大。我们将脚力和脚速度指定为两个这样的量；惩罚脚力激励策略抬起脚，而惩罚脚速度激励策略将脚放置。我们在这些基础奖励项的基础上增加了额外的成本项，包括激励策略匹配平移速度和方向的成本。我们还采用成本来鼓励平滑动作、提高能效和减少骨盆晃动。有关所用奖励函数的详细解释，请参见附录。正如文献^[13]中所述，我们不依赖专家参考轨迹来学习行为。




图 A.2 为了确保在各种可能的类似楼梯地形上的鲁棒性，我们在模拟中每个场景开始时随机化生成楼梯的多个参数。这些参数包括楼梯的数量、每个楼梯的高度、每个楼梯的长度、楼梯顶部平台的长度，以及楼梯前后地面的坡度。

A.3.4 动力学随机化

为了克服在我们模拟的 Cassie 环境中可能存在的任何建模误差，我们在训练的每个情节开始时随机化几个重要的动力学量，如先前工作^[13,15]中所述。这些随机化参数列在表A.2中。

表 A.2 动力学随机化参数范围

参数	单位	范围
关节阻尼	Nms/rad	$[0.5, 3.5] \times \text{默认值}$
关节质量	kg	$[0.5, 1.7] \times \text{默认值}$
地面摩擦	—	$[0.5, 1.1]$
关节编码器偏移	rad	$[-0.05, 0.05]$
执行速率	Hz	$[37, 42]$

A.3.5 策略表示与学习

我们将控制策略表示为一个 LSTM 循环神经网络^[16]，具有两个维度为 128 的循环隐藏层。我们选择使用一个具有记忆功能的网络，因为先前的工作表明它在处理部分可观测环境方面有更高的熟练度^[15,17-18]。对于消融实验，涉及非记忆基础的控制策略，我们使用一个具有两个维度为 300 的标准前馈神经网络，采用 tanh 激活函数，使得参数数量大约等于 LSTM 网络的参数数量。

对于策略的模拟到真实训练，我们使用近端策略优化 (PPO)^[19]，这是一种无模型的深度强化学习算法。具体来说，我们使用一个 KL 阈值终止变体，其中每次策略更新时，都会计算更新后的策略与前一个策略之间的 KL 散度，如果散度过大，则中止更新。在训练过程中，我们使用镜像损失项^[20]以确保控制策略不会学习到不对称的步态。对于循环策略，我们从重放缓冲区中采样一批情节，如^[18]所述，而对于前馈策略，我们采样一批时间步。每个情节限制为 300 个时间步，这对应于大约 7.5 秒的模拟时间。

A.4 地形随机化

先前将强化学习 (RL) 应用于 Cassie 的工作要么在平坦地面上进行训练^[12,18]，要么在随机轻微倾斜的地面上进行训练^[13]。其他应用深度强化学习的研究探讨了采用逐渐增加难度的粗糙地形课程^[1]。为了简化目的，我们发现没有课程的情况下，通过与随机楼梯的交互进行训练就足以学习到稳健的行为。

为此，我们在每个 rollout 开始时随机化倾角和横滚轴上的倾斜角度的平面上进行训练。这个倾斜角度在 -0.03 弧度和 0.03 弧度之间。作为动态随机化的一部分，地面摩擦力也被随机化，增加了环境的潜在难度。楼梯的起始位置在每个 rollout 开始时随机化，这样可以使策略从楼梯顶部开始，或者楼梯在策略前方最

多 10 米的位置开始。这样做是为了确保策略能够在平坦或倾斜的地面上，以及楼梯上获得丰富的经验。

楼梯的尺寸在典型的城市规范尺寸内随机化，每步的升高在 10 厘米到 21 厘米之间，水平距离在 24 厘米到 30 厘米之间。楼梯的数量也被随机化，使得每组楼梯有 1 到 8 个单独的台阶。在每个台阶的升高和水平距离上添加少量噪声 (± 1 厘米)，使得楼梯永远不会完全均匀，以防止策略通过本体感知推断出楼梯的精确尺寸，进而过度拟合到完全均匀的楼梯上。

A.5 结果

我们训练了四组策略，每组包含五个用不同随机种子初始化的策略。首先，我们训练了一组简单的 LSTM 策略，这些策略具有楼梯地形随机化；在本节中，这些策略被称为 Stair LSTM。为了研究记忆的重要性，我们还训练了一组前馈策略，这些策略也具有楼梯地形随机化；我们将这些策略称为 Stair FF。我们还训练了一组没有楼梯地形随机化的策略，并将这些策略称为 Flat Ground LSTM，以研究本工作中引入的地形随机化的重要性。最后一组策略是用一个简单的额外二进制输入训练的，该输入告知策略一米范围内是否有楼梯，这些策略在这里被称为 Proximity LSTM，目的是为了研究向策略泄露关于世界的信息的好处。

每个策略都训练到从虚拟环境中采样了 3 亿个时间步，这些环境是用 MuJoCo^[21] 模拟的。我们为 PPO 算法选择的超参数包括一个大小为 50,000 个时间步的回放缓冲区，对于循环策略是一个包含 64 个轨迹的批次大小，对于前馈策略是一个包含 1024 个时间步的批次大小。每个回放缓冲区最多采样五个 epoch，如果 KL 散度达到了最大允许阈值 0.02，则提前终止优化。我们在每次迭代开始时清除我们的回放缓冲区。我们使用 Adam^[22] 优化器，对于演员和评论家都使用 0.0005 的学习率，它们是分别学习的，不共享参数。

A.5.1 仿真

成功上下楼梯的概率：为了理解记忆和地形随机化的重要性，我们评估了三组策略在成功爬升和下降一组楼梯的任务上的表现。在模拟中，我们比较了 Stair FF、Stair LSTM 和 Flat Ground LSTM 策略在这项任务上的表现。具体来说，我们进行了 150 次试验，测试策略能够成功爬上一组有五级台阶的楼梯的频率，每级台阶的踏步为 17 厘米，深度为 30 厘米（典型的现实世界中相对平缓的楼梯几何形状）。这应该能给我们一个估计，即每组控制策略在盲目接近时可靠地爬上一

段楼梯的能力。成功的定义是到达楼梯顶部而没有摔倒。我们同样对下楼梯的程序进行了 150 次试验，记录了每组策略能够到达底部而没有摔倒的比率。

图 4 显示了三种不同训练条件下的这些测试结果。我们注意到，Stair LSTM 策略具有最高的整体成功率。然而，成功率在很大程度上取决于接近速度。策略在低速时失败率较高，因为它们可能缺乏推动自己越过不良脚步放置的动量。在高速时，它们也经历了较高的失败率，可能是由于高速步态的动态性更强。Flat Ground LSTM 策略在训练期间从未见过类似楼梯的地形，无法补偿，并且在上升和下降时都经历了较高的失败率。尽管 Stair FF 策略在训练期间遇到了楼梯，但它们无法学习到有效处理楼梯的策略，这表明记忆可能是对楼梯状地形具有鲁棒性的重要机制。

能量效率比较：为了理解地形随机化训练的后果，我们还比较了 Flat Ground LSTM 策略、Stair LSTM 策略和 Proximity LSTM 策略之间的运输成本。运输成本 (CoT) 是腿式机器人、人类和动物效率的常见衡量标准。它是每单位距离使用的能量，按重量归一化以使单位无关。它定义为

$$\text{CoT} = \frac{E_m}{Mgd}, \quad (\text{A.4})$$

其中 E_m 是电机使用的能量， M 是机器人的总质量， g 是重力加速度， d 是行进的距离。Cassie 使用的能量是通过正向执行器工作和通过

$$E_m = \int_0^T \left(\sum_i \max(\tau_i \cdot \omega_i, 0) + \frac{\omega_i^2}{p_i^{\max}} \right) dt. \quad (\text{A.5})$$

这里 τ_i 是施加在电机 i 上的扭矩， ω_i 是其旋转速度。我们使用两个参数来定义扭矩方面的电阻损耗， $p_i^{\max}$ 是电机 i 的最大输入功率， $\omega_i^{\max}$ 是电机 i 的最大速度。在 1 m/s 的平坦地面上测试稳态 CoT 的结果可以在表A.3中看到。这些 CoT 的计算不包括来自计算和控制电子设备的额外功耗，因此它们不应该用来在机器人之间进行比较，而只应该在控制策略之间进行比较。



图 A.3 学习到的策略展现出对各种类似楼梯地形的高度盲目鲁棒性，并且能够可靠地上下人类环境中常见的典型尺寸楼梯。




图 A.4 我们评估了在 0.25 米/秒到 1.5 米/秒的命令速度下，成功上下楼梯而不跌倒的概率，共进行了 150 次试验。对于楼梯 LSTM 策略来说，似乎存在一个最佳的上楼梯速度和一个单独的最佳下楼梯速度。楼梯 FF（前馈）策略没有达到高性能，这意味着记忆可能是学习行为的一个重要组成部分。平地 LSTM 策略在训练中从未遇到过楼梯，几乎无法成功上楼梯，但在下楼梯时能够避免跌倒，取得了一定的成功。

表 A.3 不同策略组在平坦地面上以 1 m/s 行走的单位运输成本 (CoT)

策略组	平均 CoT	标准差 CoT
Proximity LSTM (楼梯)	0.47	0.0086
Stair LSTM	0.46	0.0323
Proximity LSTM (平坦)	0.39	0.0257
Flat Ground LSTM	0.38	0.0205

我们发现, Flat Ground LSTM 策略学习了在平坦地面上行走的最节能步态。Stair LSTM 策略学习了为了对楼梯具有鲁棒性而效率较低的平坦地面步态; 然而, 楼梯接近输入可以帮助 Proximity LSTM 恢复一些失去的能效, 通过允许学习控制器在楼梯准备步态和更节能的平坦地面步态之间切换。

A.5.2 行为分析


为了理解策略所采用的策略, 我们可以从实验生物学的角度受益。我们特别关注机器人在平坦地面上行走后首次接触台阶上或下的步态行为。首先, 我们将分析摆动腿的运动, 以了解机器人如何在台阶上或下放置其脚。一旦摆动脚接触到台阶上或下, 站立阶段施加在地面上的力可以调节, 以更好地为未来的步骤做准备。我们分析了在台阶上或下的情况下, 地面反作用力和总冲量的变化。

摆动脚运动: 为了理解楼梯地形对脚摆动路径的影响, 我们比较了平坦地面 LSTM 策略和楼梯 LSTM 策略在遇到台阶下降时的结果。下降步骤期间的脚摆动路径让我们看到, 如果遇到台阶上升或下降, 策略会将脚放在哪里。图 5a 显示了这两种策略相对于地面的脚摆动路径。我们可以看到, 楼梯 LSTM 策略采取了更高的步幅, 与平坦地面 LSTM 策略相比, 它提供了额外的间隙, 使其能够踏上大台阶。第二个有趣的观察是摆动脚的更陡峭路径。对于楼梯 LSTM 策略, 摆动脚仅向前移动 14 厘米, 而它处于可能遇到台阶上升的前缘的高度范围内。我们假设这是一种策略, 防止脚在台阶的前缘上过于用力, 导致机器人向前绊倒。


第二种理解腿摆动运动的观点是观察腿摆动回缩。在人类和双足鸟类中, 观察到摆动腿在站立结束时相对于身体向后摆动, 朝向地面。这有助于减少脚相对于地面的速度, 从而减少冲击, 并通过自动改变腿部触地角度来改善地面高度干扰的排斥。

我们的训练程序没有明确激励机器人表现出这些腿摆动回缩行为, 但我们确实看到它们在图 5b 中出现。这个图显示了腿摆动相对于身体的角度, 从腿摆动

的峰值到与最大步幅下降的接触。楼梯 LSTM 策略的腿摆动回缩速度比平坦地面 LSTM 策略更快。仅凭这些数据，我们无法说这种回缩曲线是否是最佳的，甚至是否是楼梯上改进性能的原因。然而，由于在楼梯训练中腿回缩曲线发生了显著变化，这是一个有趣的观察。



(a) Swing foot paths for the stair trained policy and the flat ground policy overlaid on example step ups and step downs.



(b) The leg angle between the robot body and the swing foot as the foot descends toward touchdown.

图 A.5 在以 1.0 米/秒的速度移动时，楼梯 LSTM 策略和平地 LSTM 策略的摆动脚运动进行了比较。由于在随机化楼梯上的训练，腿部摆动策略发生了显著变化。最显著的变化包括更高的脚部离地间隙、更陡的脚部下降角度以及更快的腿部角度回缩速度。

地面反作用力：一旦机器人的脚触地，由于双足运动的欠驱动特性，其控制能力受到限制。然而，机器人仍然通过地面反作用力有相当大的控制能力。为了了解楼梯 LSTM 策略如何对 10 厘米的台阶上升或下降做出反应，我们在图 6 中绘制了水平和垂直地面反作用力在矢状平面上的变化。在站立开始时，有一个大的力峰值，使正常力在站立期间变矮。这个峰值主要由模拟接触模型的调整定义，因此它不是理解策略行为的主要兴趣点。第一个有趣的观察是，在子图 A 中，我们看到最大名义腿力保持相对恒定，这是经过良好调整的腿摆动策略的预测结果。其次，我们看到在台阶下降时，双峰地面反作用力的第二个峰值增加，而在台阶上升时减少。在水平力（子图 B）中，我们看到振荡信号，其振荡频率与策略评估的频率相匹配。我们假设这是策略在控制骨盆姿态方面的工作。优先考虑身体姿态而不是前进速度，将类似于虚拟模型控制中明确优先考虑单次站立的行为。图 6 中的最后两个子图（C 和 D）显示了在站立阶段垂直和前进方向上的累

积冲量。我们可以看到，台阶上升施加了更大的垂直冲量，而台阶下降施加了较小的垂直冲量。这与机器人应该施加较小的垂直冲量以降低自身下降台阶的直觉相符，而不是提升自身上升台阶。水平冲量告诉我们机器人在站立阶段前进方向上加速或减速。我们看到台阶下降导致前进冲量显著增加，而台阶上升略微减少垂直冲量。这与从良好调整的摆动腿回缩策略中预测的行为一致。




图 A.6 楼梯 LSTM 策略在不同地面高度时的地面反作用力和累积冲量如下：峰值垂直力 (A)：冲击后峰值垂直力基本稳定，支撑后半段力会调节。这表明策略能在初次接触地面后维持稳定峰值，后续根据地面情况调整力大小。水平力 (B)：振荡与策略执行频率匹配，可能是通过调整水平力控制身体姿态以维持平衡。总垂直冲量 (C)：结果符合预期，上楼时冲量大，下楼时冲量小，与上下楼动作的直观理解相符，即上楼需克服重力，下楼需较小力。水平冲量 (D)：结果由腿部摆动回缩预测。下楼时脚向后移动，产生正水平冲量，表现为向前加速度，说明策略通过调整脚步位置和摆动控制身体速度和稳定性，适应地面高度变化。

硬件设计：当前策略在硬件上转移时没有遇到任何显著困难。我们能够使用随机选择的楼梯 LSTM 策略，带机器人在一所大型大学校园内行走，并尝试攀登我们遇到的楼梯。我们观察到稳健且纠错的行为，以及成功且可重复的楼梯攀登和下降。此外，我们注意到对不平坦地形、原木和路缘的稳健性，这些在训练中都没有被建模。策略同样对倾斜和可变形地形具有稳健性，这通过在湿草地上行走和上小山的演示得以证明。这些实验可以在我们提交的视频中看到，其中一个实验的静态图像可以在图 3 中看到。

除了在大学校园内测试一次性地形外，我们还在户外真实世界的楼梯上进行了十次上楼梯和十次下楼梯的试验。使用选定的楼梯 LSTM 策略，我们在上楼梯

时记录了 80% 的成功率，在下楼梯时记录了 100% 的成功率。这次试验的完整视频可以在我们提交的附件中看到。我们注意到，学习到的行为对错误具有稳健性，并且可以从错误中快速恢复，尽管策略并非完全不可破坏，如果犯下特别严重的错误，它仍然会跌倒。这个实验可以在我们的补充视频 4 中看到。盲视、前馈学习策略似乎依赖于坚固的楼梯面；在模拟中评估倾斜楼梯上的政策导致更高的失败率，这指出了这种方法的局限性。即使在训练中明确包含，倾斜楼梯在上升时往往会使政策绊倒。相比之下，具有随机倾斜步骤的楼梯（例如，每步都有独特的俯仰和横滚方向）似乎对上升或下降没有困难。同样，以一定角度接近和攀登楼梯似乎对策略来说不是问题。




图 A.7 通过在“支撑”阶段交替惩罚脚部力量来教导策略抬脚，在“摆动”阶段惩罚脚部速度来教导策略将脚放在地上，我们可以构建一个学习简单行走行为的基础。沿着前人工作的路径，我们将这些周期性系数定义为阶段的随机指示函数，并取其期望值。

A.6 结论

在这项工作中，我们论证了一个高度稳健但盲目的步行控制器的可取性，并展示了这样一个盲目的双足步行控制器能够攀登各种现实世界的楼梯。此外，我们注意到，产生这样的控制器只需要对现有的训练流程进行很少的修改，特别是不需要楼梯特定的奖励项；只需在环境中添加楼梯而无需进一步信息，就足以学习楼梯攀登的控制策略。这种学习能力的一个重要要求似乎是一种记忆机制，可能是由于在盲目行走未知地形的任务中部分可观察的性质。在未来的工作中，研究如何最有效地利用视觉来提高盲目双足机器人的效率和/或性能将是有趣的。此外，这项工作展示了盲目运动的惊人能力，并留下了关于极限在哪里的问题。

A.7 附录

A.7.1 奖励函数

为了简要回顾^[13]中采取的方法，我们希望利用步行过程中脚力和脚速度的互补性质，构建一个奖励函数，该函数将在步态的关键间隔内惩罚一个并允许另一个，反之亦然。我们使用概率框架来表示这些间隔时间的不确定性。更具体地说，我们使用一个二值随机指示函数 $I_i(\phi)$ 来表示每个量 q_i ，该函数在步态周期中的某个时间希望对其进行惩罚。这个指示函数在活跃期间可能为 1，在不活跃期间可能为 0。这个二值随机函数的分布通过 Von Mises 分布定义；有关更全面的描述，请参见^[18]。此外，我们不是在奖励中使用实际的随机变量，而是选择使用其期望值，以实现更稳定的学习；有关此期望的图示，请参见图 7。

我们的完整奖励函数如下：

$$R(x, \phi) = 1 - \mathbb{E}[\rho(s, \phi)] \quad (\text{A.6})$$

也就是说，我们的奖励是偏差与概率惩罚项 $\rho(s, \phi)$ 的期望值之间的差异，如^[13]中所述。有关使用的确切量和权重的详细信息，请参见表A.4。

表 A.4 成本项及其对应权重

权重	成本项 (Cost Component)
0.140	$1 - \mathbb{E}[\text{left force}(\phi) \cdot \exp(-0.1 I_2)]$
0.140	$1 - \mathbb{E}[\text{right force}(\phi) \cdot \exp(-0.1 I_2)]$
0.140	$1 - \mathbb{E}[\text{left velocity}(\phi) \cdot \exp(- I_2)]$
0.140	$1 - \mathbb{E}[\text{right velocity}(\phi) \cdot \exp(- I_2)]$
0.140	$1 - \exp(-\epsilon_o)$
0.140	$1 - \exp(- \dot{x}_{\text{desired}} - \dot{x}_{\text{actual}})$
0.078	$1 - \exp(- \dot{y}_{\text{desired}} - \dot{y}_{\text{actual}})$
0.028	$1 - \exp(-5 \cdot \alpha_z - \alpha_z)$
0.028	$1 - \exp(-0.05 \cdot \tau)$
0.028	$1 - \exp(-0.1(\ \phi_{\text{desired}}\ + \ \phi_{\text{actual}}\))$

我们定义 F_l 和 F_r 为施加在左脚和右脚上的平移力的向量， v_l 和 v_r 类似地为左脚和右脚速度的向量。为了保持稳定的方向，使用了一个方向误差 ϵ_o ，其等于：

$$\epsilon_o = 3(1 - \hat{q}^T q_{\text{body}})^2 + 10((1 - \hat{q}^T q_l)^2 + (1 - \hat{q}^T q_r)^2) \quad (\text{A.7})$$

其中 q_l 和 q_r 是左脚和右脚的四元数方向, q_{body} 是骨盆的四元数方向, $\hat{q}$ 是一个期望的方向 (为了我们的目的, 固定为总是面向前方)。量 $\dot{x}_{\text{desired}}$ 和 $\dot{y}_{\text{desired}}$ 对应于命令的平移速度, 而 $\dot{x}_{\text{actual}}$ 和 $\dot{y}_{\text{actual}}$ 是机器人的实际平移速度。项 $\dot{\theta}_{\text{desired}}$ 表示角速度, 而 $\dot{\theta}_{\text{actual}}$ 表示平移加速度; 这些项用于成本组件中, 以减少步行行为的摇晃。项 a_t 和 a_{t-1} 指的是当前时间步的动作和前一时间步的动作, 它们在成本组件中的使用是为了鼓励平滑的行为。项 τ 是施加在关节上的净力矩向量, 其在成本组件中的使用是为了鼓励能效高的步态。

参考文献

- [1] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. *Science Robotics*, 5(47):eabc5986, Oct 2020. ISSN 2470-9476. doi: 10.1126/scirobotics.abc5986.
- [2] Gerardo Blede, Matthew J Powell, Benjamin Katz, Jared Di Carlo, Patrick M Wensing, and Sangbae Kim. Mit cheetah 3: Design and control of a robust, dynamic quadruped robot. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, page 2245–2252. IEEE, 2018.
- [3] EZ Moore and M Buehler. Stable stair climbing in a simple hexapod robot. Technical report, McGill Research Centre for Intelligent Machines, 2001.
- [4] Hae-Won Park, Alireza Ramezani, and Jessy W Grizzle. A finite-state machine for accommodating unexpected large ground-height variations in bipedal robot walking. *IEEE Transactions on Robotics*, 29(2):331–345, 2012.
- [5] J-S Gutmann, Masaki Fukuchi, and Masahiro Fujita. Stair climbing for humanoid robots using stereo vision. In *2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, volume 2, page 1407–1413. IEEE, 2004.
- [6] Amos Albert, Michael Suppa, and Wilfried Gerth. Detection of stair dimensions for the path planning of a bipedal robot. In *2001 IEEE/ASME International Conference on Advanced Intelligent Mechatronics*, volume 2, page 1291–1296. IEEE, 2001.
- [7] Philipp Michel, Joel Chestnutt, Satoshi Kagami, Koichi Nishiwaki, James Kuffner, and Takeo Kanade. Gpu accelerated real-time 3d tracking for humanoid locomotion and stair climbing. In *2007 IEEE/RSJ International Conference on Intelligent Robots and Systems*, page 463–469. IEEE, 2007.
- [8] Stéphane Caron, Abderrahmane Kheddar, and Olivier Tempier. Stair climbing stabilization of the hrp-4 humanoid robot using whole-body admittance control. In *2019 International Conference on Robotics and Automation (ICRA)*, page 277–283. IEEE, 2019.

- [9] Agility Robotics. Cassie: Dynamic planning on stairs, n.d.
- [10] Giorgio Figliolini and Marco Ceccarelli. Climbing stairs with ep-war2 biped robot. In *Proceedings 2001 ICRA. IEEE International Conference on Robotics and Automation*, volume 4, page 4116–4121. IEEE, 2001.
- [11] Michele Focchi, Romeo Orsolino, Marco Camurri, Victor Barasuol, Carlos Mastalli, Darwin G. Caldwell, and Claudio Semini. *Heuristic Planning for Rough Terrain Locomotion in Presence of External Disturbances and Variable Perception Quality*, volume 132. Springer International Publishing, Cham, 2020. ISBN 978-3-030-22327-4. doi: 10.1007/978-3-030-22327-4_9.
- [12] Zhaoming Xie, Glen Berseth, Patrick Clary, Jonathan Hurst, and Michiel van de Panne. Feed-back control for cassie with deep reinforcement learning. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, page 1241–1246. IEEE, 2018.
- [13] Jonah Siekmann, Yesh Godse, Alan Fern, and Jonathan Hurst. Sim-to-real learning of all common bipedal gaits via periodic reward composition. In *IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021.
- [14] Xue Bin Peng and Michiel van de Panne. Learning locomotion skills using deeprl: Does the choice of action space matter? *CoRR*, abs/1611.01055, 2016.
- [15] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, page 3803 – 3810. IEEE, 2018. doi: 10.1109/ICRA.2018.8460528.
- [16] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- [17] Nicolas Heess, Jonathan J Hunt, Timothy P Lillicrap, and David Silver. Memory-based control with recurrent neural networks, 2015.
- [18] Jonah Siekmann, Srikar Valluri, Jeremy Dao, Lorenzo Bermillo, Helei Duan, Alan Fern, and Jonathan Hurst. Learning memory-based control for human-scale bipedal locomotion. In *Proceedings of Robotics: Science and Systems*, July 2020.
- [19] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms, 2017.
- [20] Farzad Adbolhosseini, Hung Yu Ling, Zhaoming Xie, Xue Bin Peng, and Michiel van de Panne. On learning symmetric locomotion. In *Proc. ACM SIGGRAPH Motion, Interaction, and Games (MIG 2019)*, 2019.

- [21] Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, page 5026–5033. IEEE, 2012.
- [22] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

书面翻译对应的原文索引

- [1] Jonah Siekmann, Kevin Green, John Warila, Alan Fern, and Jonathan Hurst. Blind bipedal stair traversal via sim-to-real reinforcement learning. *arXiv preprint arXiv:2105.08328*, 2021.

致 谢

时光荏苒，本科四年转瞬即逝，回首来时之路，心中满是感慨与感恩。在这段既充实又珍贵的求学旅程中，我深感幸运，能够遇到许多良师益友，他们让这段青春岁月更加难忘和有意义。

衷心感谢我的导师张涛教授在本科期间对我的耐心指导与悉心培养。从大一入学时的《新生导引课》，到大三开设的《智能机器人》课程，张教授一步步引领我熟悉清华的学习生活，激发我对机器人领域的浓厚兴趣；在毕业设计阶段，张教授更亲自担任我的论文指导教师，提出了许多中肯而宝贵的建议，使我在科研思维与学术表达方面受益良多。张教授严谨的治学态度、深厚的专业造诣与敏锐的学术洞察力，始终令我敬佩不已，并对我的成长产生了深远影响。

诚挚感谢未来研究生阶段的导师乔红院士在本研究方向上的专业指导与大力支持，她严谨治学、实事求是的科研作风和关心学生成长的态度，让我对即将开始的研究生阶段充满期待和信心；感谢本科期间班主任刘连臣老师的悉心关怀与耐心教诲；感谢胡坚明老师、北京大学工学院刘畅老师在科研道路上的引领与鼓励，为我在学术探索过程中提供了宝贵帮助。

感谢实验室的师兄师姐、学长学姐们的言传身教与无私帮助，使我在偌大的校园中始终感受到来自同行者的支持与温暖，结识了许多志同道合的科研伙伴。

感谢我的家人始终如一的关怀与陪伴。在我专注学业时，为我营造了温馨稳定的生活环境；在我困顿迷茫时，给予我坚定的鼓励与中肯的建议。特别感谢我的父母，二十余年来的养育之恩与悉心教导，使我得以在成长道路上不断前行。我将继续努力，不负他们的期望，并衷心祝愿他们健康平安、幸福常在。

感谢一路同行的同学们，是他们的陪伴让我的本科生活充实而难忘。特别感谢我的女朋友陈姝锟同学，她严谨认真的科研态度与积极乐观的生活信念潜移默化地影响着我，激励我不断追求进步。

最后，我想感谢坚持不懈的自己。本科四年，在迷茫与挑战面前，仍旧选择了拼搏、选择了前行。愿我胸怀凌云志，心有昭昭日，纵千难万险，亦不改初心。

路漫漫其修远兮，吾将上下而求索。行远自迩，笃行不怠；心向光明，步履不停。愿我不囿于一隅，不惧于风霜，不困于当下，不负于未来。努力为祖国至少健康工作五十年，为国家科技发展贡献力量。

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名： 李昭阳 日 期： 2021.6.17

综合论文训练记录表

学生姓名	李昭阳	学号	2021013445	班级	自 11														
论文题目	基于人形机器人本体感觉的多地形强化学习步态生成方法																		
主要内容以及进度安排	本项目的目标是，通过结合强化学习与本体感觉系统，实现一个自适应、多地形环境下的步态库生成与切换方法。该方法的核心是基于 Proximal Policy Optimization (PPO)算法训练步态库，利用本体感觉数据进行地形预测，并通过自适应的时变步态顺滑切换，提高机器人的稳定性和舒适性。其关键点和难点在于，如何构建多地形步态库的生成框架、如何进行地形预测和分类、以及如何平滑地切换不同步态，以保证机器人在各种复杂环境中的高效和稳定运动。																		
	<table><tr><th>内容</th><th>时间安排</th></tr><tr><td>搭建步态规划的模拟环境，继续调研强化学习算法</td><td>2024.12.01-2024.12.31</td></tr><tr><td>通过 PPO 强化学习算法训练步态库</td><td>2024.01.01-2025.02.15</td></tr><tr><td>设计并训练基于本体感觉的地形分类预测算法</td><td>2025.02.16-2025.03.15</td></tr><tr><td>对未预期的异常进行处理</td><td>2025.03.16-2025.03.31</td></tr><tr><td>仿真和实机实验</td><td>2025.04.01-2025.05.15</td></tr><tr><td>论文撰写</td><td>2025.05.16-2025.05.30</td></tr></table>					内容	时间安排	搭建步态规划的模拟环境，继续调研强化学习算法	2024.12.01-2024.12.31	通过 PPO 强化学习算法训练步态库	2024.01.01-2025.02.15	设计并训练基于本体感觉的地形分类预测算法	2025.02.16-2025.03.15	对未预期的异常进行处理	2025.03.16-2025.03.31	仿真和实机实验	2025.04.01-2025.05.15	论文撰写	2025.05.16-2025.05.30
	内容	时间安排																	
	搭建步态规划的模拟环境，继续调研强化学习算法	2024.12.01-2024.12.31																	
	通过 PPO 强化学习算法训练步态库	2024.01.01-2025.02.15																	
	设计并训练基于本体感觉的地形分类预测算法	2025.02.16-2025.03.15																	
	对未预期的异常进行处理	2025.03.16-2025.03.31																	
	仿真和实机实验	2025.04.01-2025.05.15																	
	论文撰写	2025.05.16-2025.05.30																	
	指导教师签字：李昭阳																		
考核组组长签字：王																			
2024年 11月 28日																			
中期考核意见	该生在中期阶段已完成仿真环境搭建工作和部分实验工作，并对整体任务有明确清晰的规划，考核意见良好。																		
	考核组组长签字：王																		
	2025年 3月 13日																		

指导教师评语	论文针对人形机器人多地形行走任务中依赖参考轨迹、优化目标冲突、缺乏可解释性等问题提出了一种基于本体感觉的多地形强化学习步态生成方法。 论文研究工作按照预期进度顺利推进，完成了预期的研究任务和工作内容。成功实现了预先设计的控制框架并在仿真平台上取得了较好的实验效果。总体工作符合预期，达到了综合论文训练的要求，同意组织答辩。 指导教师签字： <u>张立群</u> 2025年 5月29日
评阅教师评语	论文聚焦于提升人形机器人在复杂地形下的行走能力，创新提出一种融合本体感觉的多地形强化学习步态生成方案。该方案通过残差补偿策略与两阶段学习机制，有效攻克了多地形行走难题，实现机器人在不同地貌环境下的稳定移动。研究具有较大的理论创新和应用价值，达到了综合论文训练的要求，同意组织答辩。 评阅教师签字： <u>杨林</u> 2025年 5月29日
答辩小组评语	该同学在规定时间内，简明扼要地陈述了毕设的主要工作，准确得当地回答了答辩小组的问题。设计了基于残差补偿的两阶段强化学习步态生成算法和地形分类算法，具有一定的创新性。 答辩小组经过充分讨论，综合该生毕设工作和答辩表现，同意该同学通过毕业论文答辩。 答辩小组组长签字： <u>张立群</u> 2025年 6月17日

总成绩： B

教学负责人签字： AA

2025年 6月17日